Señales aleatorias

Ingeniería Electrónica de Comunicaciones

Eva Besada-Portas

Departamento de Arquitectura de Computadores y Automática.
Universidad Complutense de Madrid

Curso 2017-2018

Esquema

1. Objetivos
2. Introducción
3. Variables aleatorias
4. Señales aleatorias

Objetivos del tema

- Aprender a distinguir desde un punto de vista matemático el comportamiento de las señales deterministas y los diferentes tipos de señales aleatorias (estacionarias, ergódicas, proceso de Markov).

Objetivos del tema

- Aprender a distinguir desde un punto de vista matemático el comportamiento de las señales deterministas y los diferentes tipos de señales aleatorias (estacionarias, ergódicas, proceso de Markov).
- Definir matemáticamente las propiedades más relevantes de:

Objetivos del tema

- Aprender a distinguir desde un punto de vista matemático el comportamiento de las señales deterministas y los diferentes tipos de señales aleatorias (estacionarias, ergódicas, proceso de Markov).
- Definir matemáticamente las propiedades más relevantes de:
  - Variables aleatoria: distribución/densidad de probabilidad, valor medio, valor cuadrático medio, varianza, correlación

Objetivos del tema

- Aprender a distinguir desde un punto de vista matemático el comportamiento de las señales deterministas y los diferentes tipos de señales aleatorias (estacionarias, ergódicas, proceso de Markov).
- Definir matemáticamente las propiedades más relevantes de:
  - Variables aleatoria: distribución/densidad de probabilidad, valor medio, valor cuadrático medio, varianza, correlación
  - Señales aleatorias: valor medio, valor cuadrático medio, covarianza, autocorrelacionn y correlación cruzada, densidad espectral de potencia

Objetivos del tema

- Aprender a distinguir desde un punto de vista matemático el comportamiento de las señales deterministas y los diferentes tipos de señales aleatorias (estacionarias, ergódicas, proceso de Markov).
- Definir matemáticamente las propiedades más relevantes de:
  - Variables aleatoria: distribución/densidad de probabilidad, valor medio, valor cuadrático medio, varianza, correlación
  - Señales aleatorias: valor medio, valor cuadrático medio, covarianza, autocorrelacionn y correlación cruzada, densidad espectral de potencia
- Procesamiento de señales aleatorias a través de las técnicas de procesamiento de señales deterministas

Esquema

1 Objetivos

2 Introducción

3 Variables aleatorias

4 Señales aleatorias

Señales deterministas y estocásticas I

- Señales deterministas:

- Señales estocásticas/aleatorias:

Señales deterministas y estocásticas I

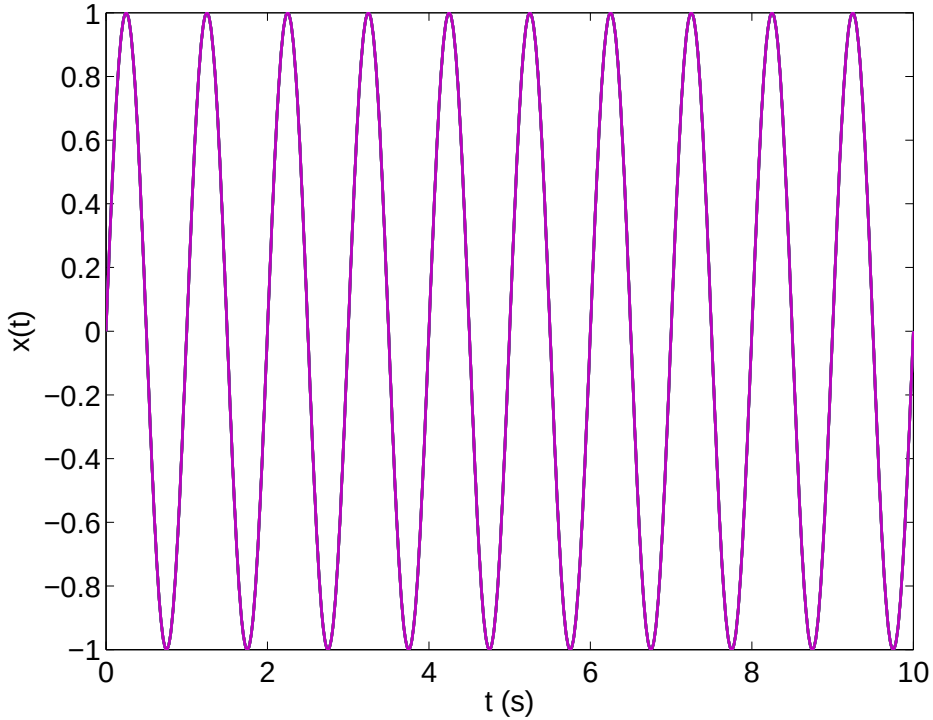
- Señales deterministas:
  - Se caracterizan por tomar el mismo valor para el mismo instante de tiempo.
  - Por lo tanto, se pueden representar a través de una única secuencia continua/discreta de valores.
  - Alternativamente, el valor de la señal en cada instante puede ser definido de forma explicita a través de una función matemática determinista que relaciona el valor de la señal con el valor de variable independiente (tiempo).
- Señales estocásticas/aleatorias:

Señales deterministas y estocásticas I

- Señales deterministas:
  - Se caracterizan por tomar el mismo valor para el mismo instante de tiempo.
  - Por lo tanto, se pueden representar a través de una única secuencia continua/discreta de valores.
  - Alternativamente, el valor de la señal en cada instante puede ser definido de forma explicita a través de una función matemática determinista que relaciona el valor de la señal con el valor de variable independiente (tiempo).
- Señales estocásticas/aleatorias:
  - Se caracterizan por no tomar el mismo valor para un mismo instante de tiempo.
  - Por lo tanto, su comportamiento se puede representar como una colección infinita de secuencias continuas/discretas de valores.
  - Alternativamente, el valor en cada instante es una variable aleatoria cuyo comportamiento puede ser definido a través de una función de probabilidad.

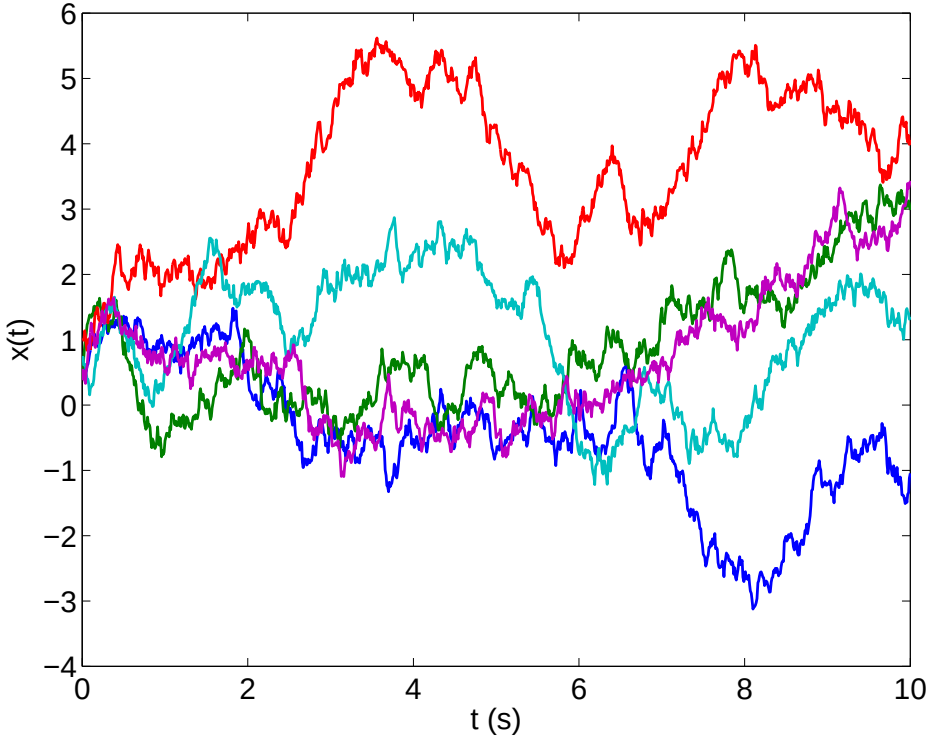
Señales deterministas y estocásticas II

Señal determinista:



$$x(t) = sen(wt)$$

Señal estocástica:



$$p(x(t_0), x(t_1), x(t_2), \ldots, x(t_\infty))$$

Señales deterministas y estocásticas III

- ¿Las señales reales son deterministas o estocásticas?

Señales deterministas y estocásticas III

- ¿Las señales reales son deterministas o estocásticas?
  - Se puede argumentar que no existen señales totalmente deterministas ya que puede existir algún fenómeno que no haya sido tenido en cuenta y por lo tanto, los valores de la señal no están totalmente determinados a priori.

Señales deterministas y estocásticas III

- ¿Las señales reales son deterministas o estocásticas?
  - Se puede argumentar que no existen señales totalmente deterministas ya que puede existir algún fenómeno que no haya sido tenido en cuenta y por lo tanto, los valores de la señal no están totalmente determinados a priori.
  - Igualmente, se puede considerar que todas las señales son intrínsecamente deterministas, y que su aleatoreidad únicamente se debe al desconocimiento parcial que tenemos del proceso que las genera.

Señales deterministas y estocásticas III

- ¿Las señales reales son deterministas o estocásticas?
  - Se puede argumentar que no existen señales totalmente deterministas ya que puede existir algún fenómeno que no haya sido tenido en cuenta y por lo tanto, los valores de la señal no están totalmente determinados a priori.
  - Igualmente, se puede considerar que todas las señales son intrínsecamente deterministas, y que su aleatoreidad únicamente se debe al desconocimiento parcial que tenemos del proceso que las genera.
  - La clasificación atiende más al tratamiento que se le desea dar a la señal que a la forma en que la señal ha sido generada.

Esquema

1. Objetivos
2. Introducción
3. Variables aleatorias
   - Una variable aleatoria
   - Múltiples variables aleatorias
4. Señales aleatorias

Esquema

1. Objetivos
2. Introducción
3. Variables aleatorias
   - Una variable aleatoria
   - Múltiples variables aleatorias
4. Señales aleatorias

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
  - Variable aleatoria continua:

[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
    - ★ Función de probabilidad de masa: $p_X(x_i) = Probabilidad(X = x_i)$
  - Variable aleatoria continua:

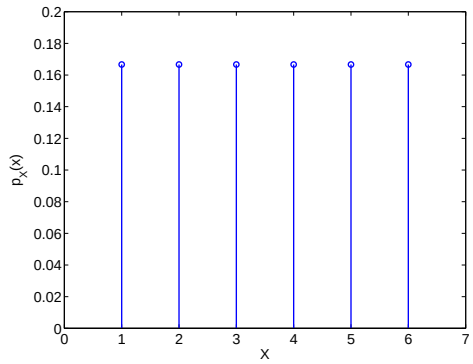
[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
    - ★ Función de probabilidad de masa: $p_X(x_i) = Probabilidad(X = x_i)$
  - Variable aleatoria continua:

Ejemplo discreto: X valores de un dado

$$p_X(x) = \frac{1}{6}$$



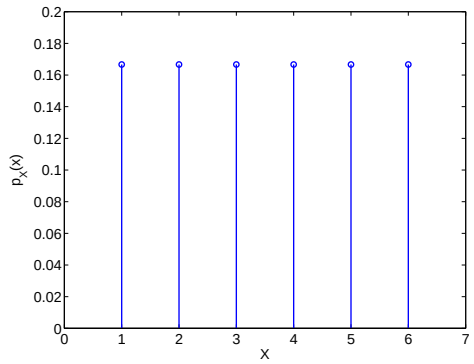
[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
    - ★ Función de probabilidad de masa: $p_X(x_i) = Probabilidad(X = x_i)$
  - Variable aleatoria continua:
    - ★ Distribución de probabilidad: $P_X(x) = Probabilidad(X \leq x)$
    - ★ Densidad de probabilidad: $p_X(x) = \frac{\partial P_X(x)}{\partial x}$
    - ★ $P_X(x) = \int_{-\infty}^{x} p_X(y)dy$

Ejemplo discreto: X valores de un dado

$$p_X(x) = \frac{1}{6}$$



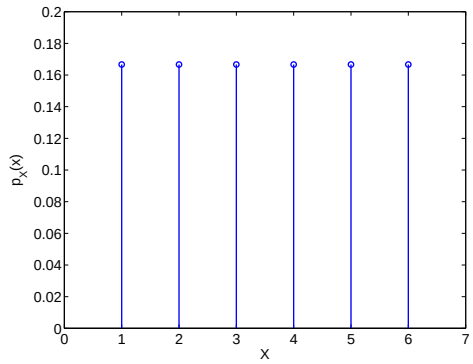
[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
    - ★ Función de probabilidad de masa: $p_X(x_i) = Probabilidad(X = x_i)$
  - Variable aleatoria continua:
    - ★ Distribución de probabilidad: $P_X(x) = Probabilidad(X \leq x)$
    - ★ Densidad de probabilidad: $p_X(x) = \frac{\partial P_X(x)}{\partial x}$
    - ★ $P_X(x) = \int_{-\infty}^{x} p_X(y)dy$

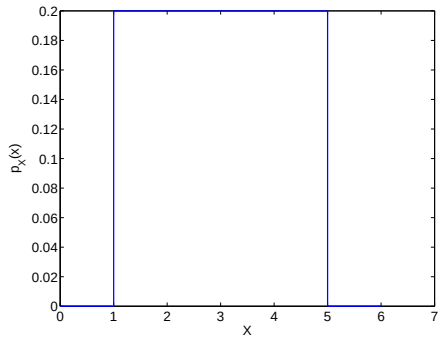
Ejemplo discreto: X valores de un dado

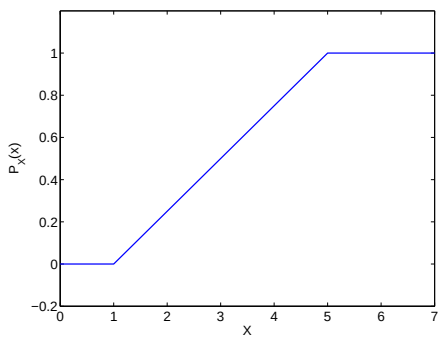
$p_X(x) = \frac{1}{6}$



Ejemplo continuo: X longitud de caminos

$p_X(x) = \mathcal{U}_{X\in[1,5]}(x)$





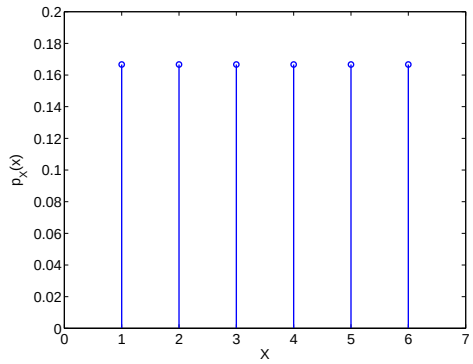
[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Las propiedades de una variable aleatoria[1] X se definen con un función de probabilidad:
  - Variable aleatoria discreta:
    - ★ Función de probabilidad de masa: $p_X(x_i) = Probabilidad(X = x_i)$
  - Variable aleatoria continua:
    - ★ Distribución de probabilidad: $P_X(x) = Probabilidad(X \leq x)$
    - ★ Densidad de probabilidad: $p_X(x) = \frac{\partial P_X(x)}{\partial x}$
    - ★ $P_X(x) = \int_{-\infty}^{x} p_X(y)dy$
  - Propiedades:
    - ★ $p_X(x) \geq 0 \rightarrow P_X(x)$ es una función creciente
    - ★ $\sum_{x \in X} p_X(x) = 1$ ó $P_X(\infty) = 1$

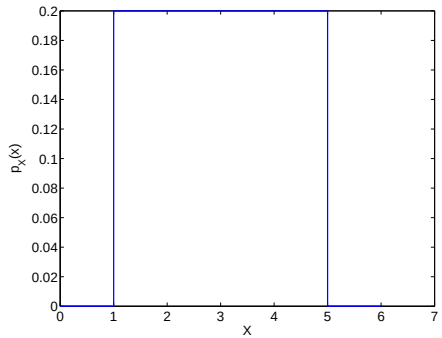
Ejemplo discreto: X valores de un dado

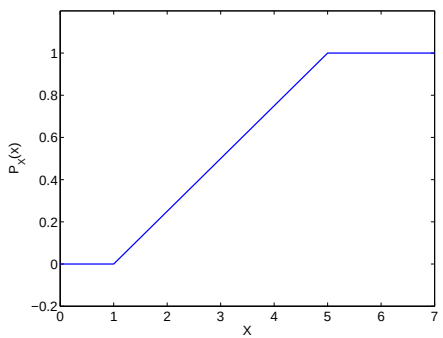
$p_X(x) = \frac{1}{6}$



Ejemplo continuo: X longitud de caminos

$p_X(x) = \mathcal{U}_{X \in [1,5]}(x)$





[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x - x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x) \sum_{x_i \in X} p_X(x_i)\delta(x - x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])
  - Valor medio: $\mu_X \triangleq E(X)$
  - Valor cuadrático medio: $E(X^2)$
  - Varianza[2]: $\sigma_X^2 \triangleq E((X - \mu_x)(X - \mu_x)) =$

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x - x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x) \sum_{x_i \in X} p_X(x_i)\delta(x - x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])
  - Valor medio: $\mu_X \triangleq E(X) = \int_{-\infty}^{\infty} xp_X(x)dx$
  - Valor cuadrático medio: $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x)dx$
  - Varianza[2]: $\sigma_X^2 \triangleq E((X-\mu_x)(X-\mu_x)) = \int_{-\infty}^{\infty}(x-\mu_x)(x-\mu_x)p_X(x)dx$

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x-x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x)\sum_{x_i \in X} p_X(x_i)\delta(x-x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

Estadísticos de una variable aleatoria

- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])
  - Valor medio: $\mu_X \triangleq E(X) = \int_{-\infty}^{\infty} xp_X(x)dx$
  - Valor cuadrático medio: $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x)dx$
  - Varianza[2]: $\sigma_X^2 \triangleq E((X-\mu_x)(X-\mu_x)) = \int_{-\infty}^{\infty}(x-\mu_x)(x-\mu_x)p_X(x)dx$

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x-x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x)\sum_{x_i \in X} p_X(x_i)\delta(x-x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

[2] Relación entre σ_X^2, μ_X y $E(X^2)$: $\sigma_X^2 = \int_{-\infty}^{\infty}(x^2 - 2\mu_X x + \mu_X^2)p_X(x)dx =$
$= E(X^2) - 2\mu_X \int_{-\infty}^{\infty} xp_X(x)dx + \mu_X^2 \int_{-\infty}^{\infty} p_X(x)dx = E(X^2) - 2\mu_X^2 + \mu_X^2$

Estadísticos de una variable aleatoria

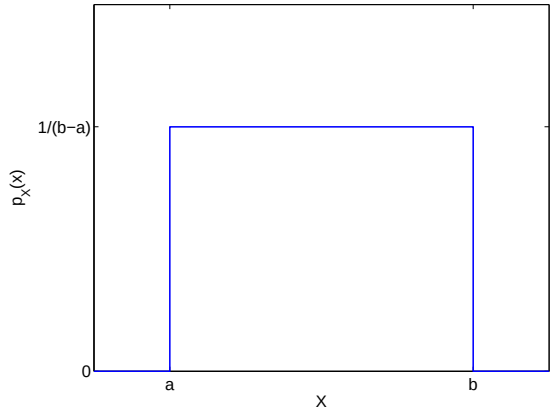
- Las características más relevantes de las señales aleatorias se calculan como el valor esperado de alguna función genérica g(x) respecto la función densidad de probabilidad:
  - Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx$
  - Discreto: $E(g(X)) = \sum_{x_i \in X} g(x_i)p_X(x_i)$
- Estadísticos/características habituales (expresiones continuas[1])
  - Valor medio: $\mu_X \triangleq E(X) = \int_{-\infty}^{\infty} xp_X(x)dx$
  - Valor cuadrático medio: $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x)dx$
  - Varianza[2]: $\sigma_X^2 \triangleq E((X-\mu_x)(X-\mu_x)) = \int_{-\infty}^{\infty}(x-\mu_x)(x-\mu_x)p_X(x)dx = E(X^2) - \mu_x^2$

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x - x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x) \sum_{x_i \in X} p_X(x_i)\delta(x-x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

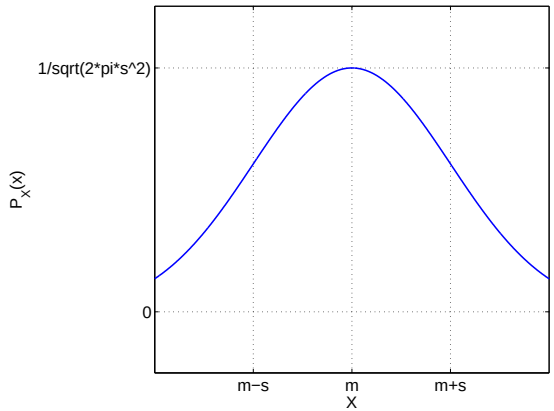
[2] Relación entre σ_X^2, μ_X y $E(X^2)$: $\sigma_X^2 = \int_{-\infty}^{\infty}(x^2 - 2\mu_X x + \mu_X^2)p_X(x)dx =$
$= E(X^2) - 2\mu_X \int_{-\infty}^{\infty} xp_X(x)dx + \mu_X^2 \int_{-\infty}^{\infty} p_X(x)dx = E(X^2) - 2\mu_X^2 + \mu_X^2$

Variables aleatorias comunes

- Variable aleatoria con una distribución uniforme:
  - $p_X(x) = \mathcal{U}_{X\in[a,b]}(x) = \begin{cases} \frac{1}{b-a} & x \in [a,b] \\ 0 & c.c. \end{cases}$
  - $\mu_X = \int_{-\infty}^{\infty} x p_X(x) dx = \int_a^b \frac{x}{b-a} dx = \frac{x^2}{2(b-a)}\Big|_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{b+a}{2}$
  - $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x) dx = \int_a^b \frac{x^2}{b-a} dx = \frac{x^3}{3(b-a)}\Big|_a^b = \frac{b^3-a^3}{3(b-a)} = \frac{b^2+a^2+ab}{3}$
  - $\sigma_X^2 = E(X^2) - \mu_X^2 = \frac{(b-a)^2}{12}$



- Variable aleatoria con una distribución gaussiana:
  - $p_X(x) = \mathcal{N}_X(x;\mu,\sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
  - $\mu_X = \int_{-\infty}^{\infty} x p_X(x) dx = \mu$
  - $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x) dx = \sigma^2 + \mu_X^2$
  - $\sigma_X^2 = E(X^2) - \mu_X^2 = \sigma^2$



Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:
    - ★ Probabilidad discreta $p_x(x_i)$ con $i \in [1 : N]$
      - Equiprobables con Matlab: `randi(#valores,filas,col)`
      - No equiprobables: método de la ruleta

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:
    - ★ Probabilidad discreta $p_x(x_i)$ con $i \in [1 : N]$
      - Equiprobables con Matlab: `randi(#valores,filas,col)`
      - No equiprobables: método de la ruleta
    - ★ Probabilidad uniforme $\mathcal{U}_{X\in[a,b]}(x)$
      - Matlab: `a+(b-a)rand(filas,col)`
      - Secuencias básicas: $x_{i+1} = (a * x_i + c) \mod m$.

        Ejemplo con $a = 65539, m = 2^{29}$

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:
    - ★ Probabilidad discreta $p_x(x_i)$ con $i \in [1 : N]$
      - Equiprobables con Matlab: `randi(#valores,filas,col)`
      - No equiprobables: método de la ruleta
    - ★ Probabilidad uniforme $\mathcal{U}_{X\in[a,b]}(x)$
      - Matlab: `a+(b-a)rand(filas,col)`
      - Secuencias básicas: $x_{i+1} = (a * x_i + c) \mod m$.
        Ejemplo con $a = 65539, m = 2^{29}$
    - ★ Probabilidad gaussiana $\mathcal{N}_X(x; \mu, \sigma)$
      - Matlab: μ+σ`randn(filas,col)`
      - Transformada de Box-Muller (a partir de la uniforme)

Muestreo de una variable aleatoria I

- La operación de muestreo de una variable aleatoria consiste en obtener sus valores (muestras) de acuerdo con la densidad de probabilidad elegida.
- Matemáticamente representaremos la función como: $x \sim p_X(x)$
- Las muestras se pueden generar:
  - Experimentalmente, excitando/observando la respuesta de un proceso aleatorio o de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:
    - ★ Probabilidad discreta $p_x(x_i)$ con $i \in [1 : N]$
      - Equiprobables con Matlab: `randi(#valores,filas,col)`
      - No equiprobables: método de la ruleta
    - ★ Probabilidad uniforme $\mathcal{U}_{X\in[a,b]}(x)$
      - Matlab: `a+(b-a)rand(filas,col)`
      - Secuencias básicas: $x_{i+1} = (a * x_i + c) \mod m$.
        Ejemplo con $a = 65539, m = 2^{29}$
    - ★ Probabilidad gaussiana $\mathcal{N}_X(x; \mu, \sigma)$
      - Matlab: μ+σ`randn(filas,col)`
      - Transformada de Box-Muller (a partir de la uniforme)
    - ★ Probabilidades genéricas:
      - Muestreo por rechazo, por importancia
      - Muestreo de mezclas

Muestreo de una variable aleatoria II

- Método de la ruleta:
  - $p(x_i)$
  - Muestreo variable auxiliar:
    $y \sim \mathcal{U}_{y\in[0,1]}(y)$
  - $x = \{j | \sum_{i=1}^{j-1} p(x_i) < y < \sum_{i=1}^{j} p(x_i)\}$

Muestreo de una variable aleatoria II

- Método de la ruleta:
  - $p(x_i)$
  - Muestreo variable auxiliar: $y \sim \mathcal{U}_{y\in[0,1]}(y)$
  - $x = \{j | \sum_{i=1}^{j-1} p(x_i) < y < \sum_{i=1}^{j} p(x_i)\}$

```
p=[0.1,0.3,0.2,0.4];
cump=cumsum(p);
N=1000;

for i=1:N
    v(i)=rand(1);
    x(i)=sum(v(i)>cump)+1;
end
```

Muestreo de una variable aleatoria II

- Método de la ruleta:
  - $p(x_i)$
  - Muestreo variable auxiliar:
    $y \sim \mathcal{U}_{y\in[0,1]}(y)$
  - $x = \{j | \sum_{i=1}^{j-1} p(x_i) < y < \sum_{i=1}^{j} p(x_i)\}$

```
p=[0.1,0.3,0.2,0.4];
cump=cumsum(p);
N=1000;

for i=1:N
    v(i)=rand(1);
    x(i)=sum(v(i)>cump)+1;
end
```

- Transformada de Box-Muller:
  - $\mathcal{N}(x, \mu=0, \sigma^2=1)$
  - Muestreo de 2 variables auxiliares:
    $y_1 \sim \mathcal{U}_{y\in[0,1]}(y)$
    $y_2 \sim \mathcal{U}_{y\in[0,1]}(y)$
  - Transformación de las muestras:
    $r = \sqrt{-2\log(y_1)}$
    $\theta = 2\pi y_2$
    $x_1 = r\cos(\theta)$
    $x_2 = r\sin(\theta)$
    Se genera un par, para hacer una guassiana de dos dimensiones o un complejo. Se puede usar solo uno.

Muestreo de una variable aleatoria II

- Método de la ruleta:
  - $p(x_i)$
  - Muestreo variable auxiliar:
    $y \sim \mathcal{U}_{y\in[0,1]}(y)$
  - $x = \{j | \sum_{i=1}^{j-1} p(x_i) < y < \sum_{i=1}^{j} p(x_i)\}$

```
p=[0.1,0.3,0.2,0.4];
cump=cumsum(p);
N=1000;

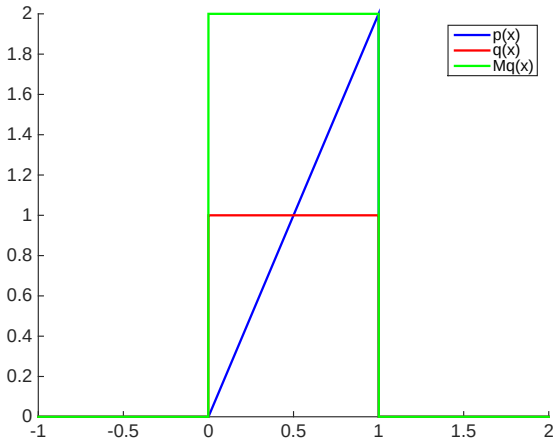
for i=1:N
    v(i)=rand(1);
    x(i)=sum(v(i)>cump)+1;
end
```

- Transformada de Box-Muller:
  - $\mathcal{N}(x, \mu=0, \sigma^2=1)$
  - Muestreo de 2 variables auxiliares:
    $y_1 \sim \mathcal{U}_{y\in[0,1]}(y)$
    $y_2 \sim \mathcal{U}_{y\in[0,1]}(y)$
  - Transformación de las muestras:
    $r = \sqrt{-2\log(y_1)}$
    $\theta = 2\pi y_2$
    $x_1 = r\cos(\theta)$
    $x_2 = r\sin(\theta)$
    Se genera un par, para hacer una guassiana de dos dimensiones o un complejo. Se puede usar solo uno.

```
N=10000;
y = rand(2,N);
r = sqrt(-2*log(y(1,:)));
theta = 2*pi*y(2,:);
x1 = r.*cos(theta); %x1 normal
x2 = r.*sin(theta); %x2 normal
%Sirve para generar una
%bidimensional (x1,x2) o
%complejo z=x1+jx2
```

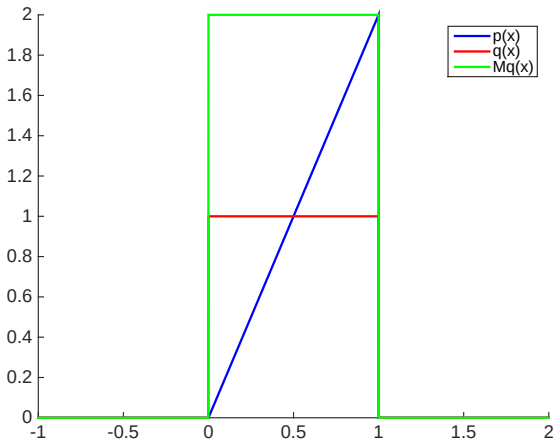
Muestreo de una variable aleatoria III

- Método de muestreo por rechazo:
  - Función de probabilidad genérica $p(x)$
  - Las muestras se obtienen de una $q(x)$ auxiliar que debe cumplir que para algún M que Mq(x)-p(x)>0. Este hecho fuerza a que tengan el mismo soporte (que $q(x) \neq 0$ sobre los mismos puntos x que $p(x) \neq 0$).
  - Las $x \sim q(x)$ son también muestras de $p(x)$ si se cumple que $yMq(x) < p(x)$ con $y \sim \mathcal{U}_{y \in [0,1]}(y)$



Muestreo de una variable aleatoria III

- Método de muestreo por rechazo:
  - Función de probabilidad genérica $p(x)$
  - Las muestras se obtienen de una $q(x)$ auxiliar que debe cumplir que para algún M que Mq(x)-p(x)>0. Este hecho fuerza a que tengan el mismo soporte (que $q(x) \neq 0$ sobre los mismos puntos x que $p(x) \neq 0$).
  - Las $x \sim q(x)$ son también muestras de $p(x)$ si se cumple que $yMq(x) < p(x)$ con $y \sim \mathcal{U}_{y\in[0,1]}(y)$




```
function x=MuestreoRechazo(N)

x=[];
M=2;  %Valor de M
hm=0;
while hm<N
  y=rand(N-hm,1);
  xp=rand(N-hm,1);  %Muestras q(x)
  l=find(y*M.*q(xp)-p(xp)<0)
  x=[x;xp(l)];
  hm=length(x)
end

function val=q(x)
%Densidad prob. q(x)
val=1;

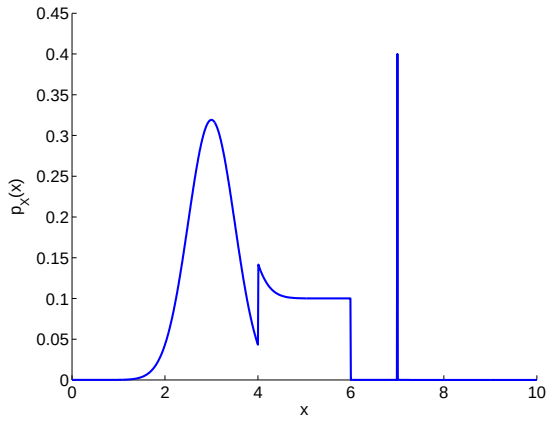
function val=p(x)
%Densidad prob.  p(x)
val=2*x;
```

Muestreo de una variable aleatoria IV

- Muestreo de una mezcla:
  - Función de probabilidad genérica $p(x) = \sum_{i=1}^{L} a_i p_i(x)$, con $\sum_{i=1}^{L} a_i = 1$
  - Para muestrearla, podemos seguir el siguiente proceso:
    - ★ Elegimos la componente de la mezcla (el valor de la i) utilizando la probabilidad discreta $q(i) = a_i$
    - ★ Muestreamos la x de la componente elegida $x \sim p_i(x)$

Muestreo de una variable aleatoria IV

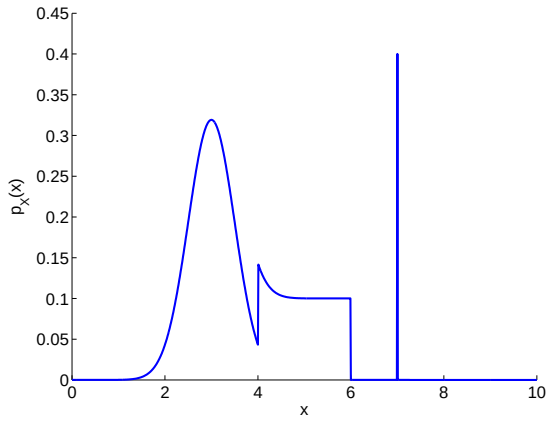
- Muestreo de una mezcla:
  - Función de probabilidad genérica $p(x) = \sum_{i=1}^{L} a_i p_i(x)$, con $\sum_{i=1}^{L} a_i = 1$
  - Para muestrearla, podemos seguir el siguiente proceso:
    - ★ Elegimos la componente de la mezcla (el valor de la i) utilizando la probabilidad discreta $q(i) = a_i$
    - ★ Muestreamos la x de la componente elegida $x \sim p_i(x)$



$$p_X(x) = 0{,}4\mathcal{N}(x, 3, 0{,}5) + 0{,}2\mathcal{U}_{[4,6]}(x) + 0{,}4\delta(x - 7)$$

Muestreo de una variable aleatoria IV

- Muestreo de una mezcla:
  - Función de probabilidad genérica $p(x) = \sum_{i=1}^{L} a_i p_i(x)$, con $\sum_{i=1}^{L} a_i = 1$
  - Para muestrearla, podemos seguir el siguiente proceso:
    - ★ Elegimos la componente de la mezcla (el valor de la i) utilizando la probabilidad discreta $q(i) = a_i$
    - ★ Muestreamos la x de la componente elegida $x \sim p_i(x)$




```
function [x,aux]=MuestreoMezcla(N)

q_i=[0.4,0.2,0.4];
qsum=cumsum(q_i);
for i=1:N
    %Muestreo ruleta
    index=sum(rand>qsum)+1;
    aux(i)=index;
    switch index
        case 1,
            %gaussiana
            x(i)=3+0.5*randn;
        case 2,
            %uniforme
            x(i)=4+2*rand;
        case 3,
          %Delta centrada en 7
            x(i)=7;
    end
end
```

$$p_X(x) = 0{,}4\mathcal{N}(x, 3, 0{,}5) + 0{,}2\mathcal{U}_{[4,6]}(x) + 0{,}4\delta(x-7)$$

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.
- La diferencia reside que en el primer caso no se dispone de una función de probabilidad y en el segundo si.

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.
- La diferencia reside que en el primer caso no se dispone de una función de probabilidad y en el segundo si.
- En el proceso de caracterización de las muestras se puede:

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.
- La diferencia reside que en el primer caso no se dispone de una función de probabilidad y en el segundo si.
- En el proceso de caracterización de las muestras se puede:
  - Intentar estimar la función de probabilidad:
    1. Determinar el tipo de función de probabilidad: histograma de las muestras
    2. Determinar los parámetros de la función de probabilidad: a partir de las muestras

Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.
- La diferencia reside que en el primer caso no se dispone de una función de probabilidad y en el segundo si.
- En el proceso de caracterización de las muestras se puede:
  - Intentar estimar la función de probabilidad:
    1. Determinar el tipo de función de probabilidad: histograma de las muestras
    2. Determinar los parámetros de la función de probabilidad: a partir de las muestras
  - Obtener el valor de los estadísticos a partir:
    - ★ De la muestras: Método de Monte-Carlo[1]
    - ★ De la función de probabilidad que se ha estimado.

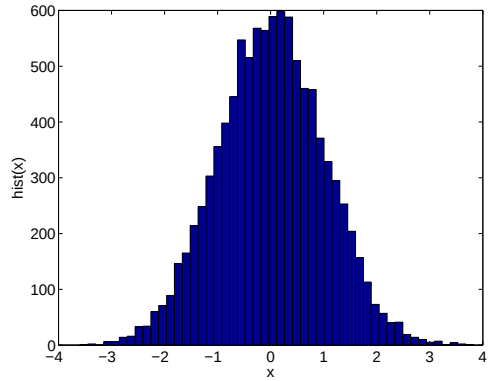
Caracterización de las muestras

- ¿Que hacer cuando nos proporcionan un conjunto de muestras sin su función de probabilidad?
- El proceso de caracterización de las muestras es conceptualmente análogo al proceso de caracterización de la función de probabilidad.
- La diferencia reside que en el primer caso no se dispone de una función de probabilidad y en el segundo si.
- En el proceso de caracterización de las muestras se puede:
  - Intentar estimar la función de probabilidad:
    1. Determinar el tipo de función de probabilidad: histograma de las muestras
    2. Determinar los parámetros de la función de probabilidad: a partir de las muestras
  - Obtener el valor de los estadísticos a partir:
    - ★ De la muestras: Método de Monte-Carlo[1]
    - ★ De la función de probabilidad que se ha estimado.

[1] Los métodos de Monte-Carlo también se utilizan para estimar los estadísticos de funciones de probabilidad conocidas de las que no se pueden calcular las integrales de forma cerrada. El proceso consiste en utilizar los métodos de muestreo para generar muestras de la función de probabilidad y luego el método de Monte-Carlo para estimar el estadístico sobre las muestras generadas.

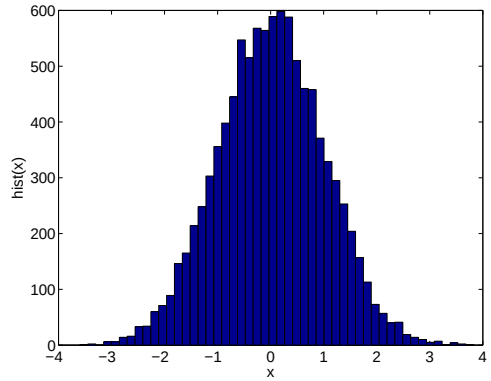
Histograma de un conjunto muestral I

- El histograma divide el espacio muestral en H segmentos (cubos/bins) continuos de igual tamaño y contabiliza el número de muestras que pertenecen a cada uno de los segmentos.



Histograma de un conjunto muestral I

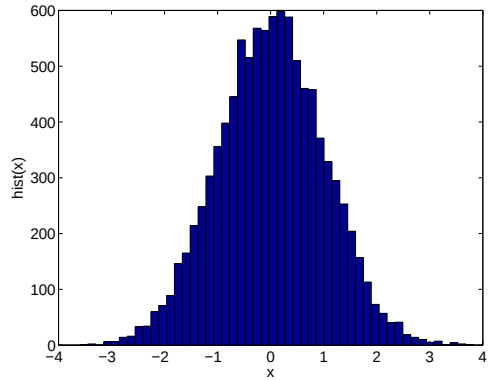
- El histograma divide el espacio muestral en H segmentos (cubos/bins) continuos de igual tamaño y contabiliza el número de muestras que pertenecen a cada uno de los segmentos.



- Podemos utilizarlos para realizar una representación aproximada de la probabilidad de las muestras, siempre y cuando se normalizan las cuentas del histograma de forma que:
  - La suma de los valores normalizados del histograma sea 1 para el caso de trabajar con variables aleatorias discretas.
  - El area recogida por el histograma normalizado sea igual a 1 para el caso de trabajar con variables aleatorias continuas.

Histograma de un conjunto muestral I

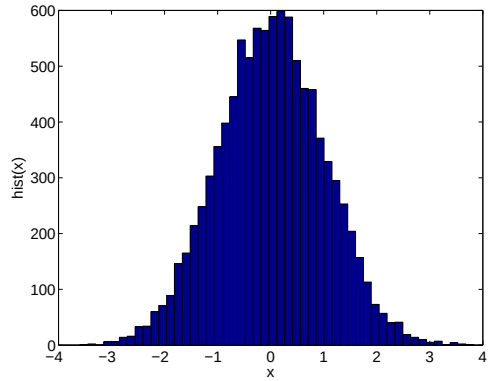
- El histograma divide el espacio muestral en H segmentos (cubos/bins) continuos de igual tamaño y contabiliza el número de muestras que pertenecen a cada uno de los segmentos.



- Podemos utilizarlos para realizar una representación aproximada de la probabilidad de las muestras, siempre y cuando se normalizan las cuentas del histograma de forma que:
  - La suma de los valores normalizados del histograma sea 1 para el caso de trabajar con variables aleatorias discretas.
  - El area recogida por el histograma normalizado sea igual a 1 para el caso de trabajar con variables aleatorias continuas.
- Una análisis de la forma del histograma (o del histograma normalizado), en la que obviemos los escalones introducidos por la segmentación del espacio muestral, nos puede permitir determinar en algunos casos el tipo de función de probabilidad al que pertenecen las muestras[1].

Histograma de un conjunto muestral I

- El histograma divide el espacio muestral en H segmentos (cubos/bins) continuos de igual tamaño y contabiliza el número de muestras que pertenecen a cada uno de los segmentos.



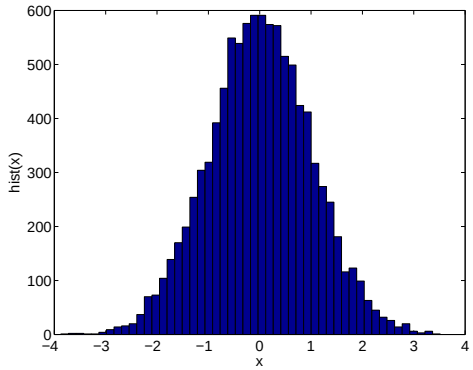
- Podemos utilizarlos para realizar una representación aproximada de la probabilidad de las muestras, siempre y cuando se normalizan las cuentas del histograma de forma que:
  - La suma de los valores normalizados del histograma sea 1 para el caso de trabajar con variables aleatorias discretas.
  - El area recogida por el histograma normalizado sea igual a 1 para el caso de trabajar con variables aleatorias continuas.
- Una análisis de la forma del histograma (o del histograma normalizado), en la que obviemos los escalones introducidos por la segmentación del espacio muestral, nos puede permitir determinar en algunos casos el tipo de función de probabilidad al que pertenecen las muestras[1].

[1] En el caso continuo, es conveniente hacer divisiones suficientemente pequeñas para que los escalones no escondan la función de probabilidad real de las muestras.

Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

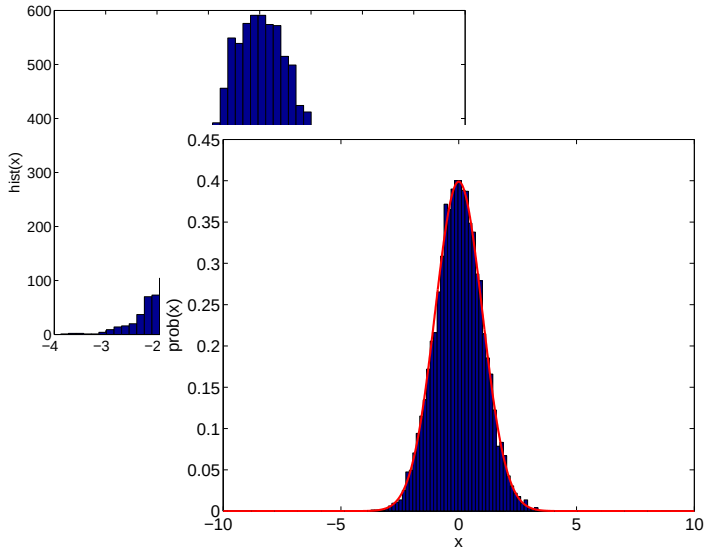
```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

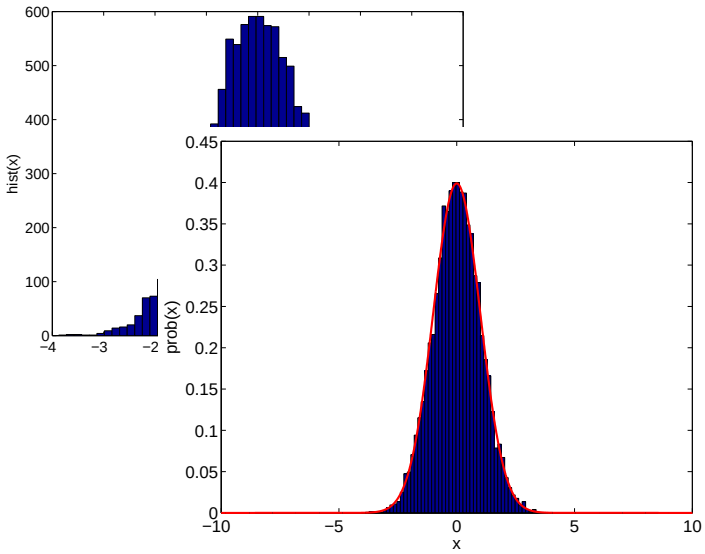
```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



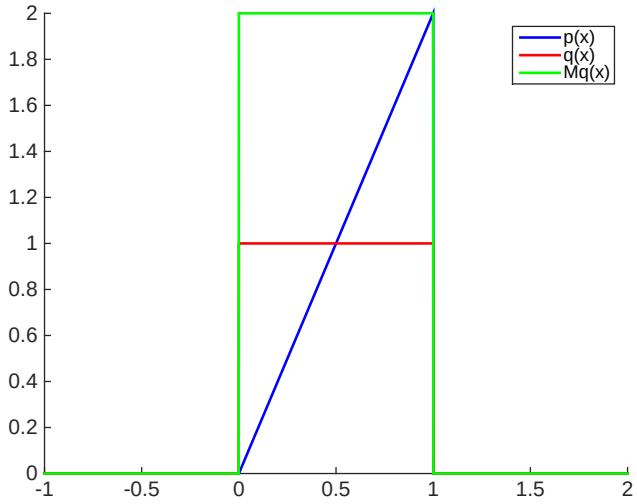
Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



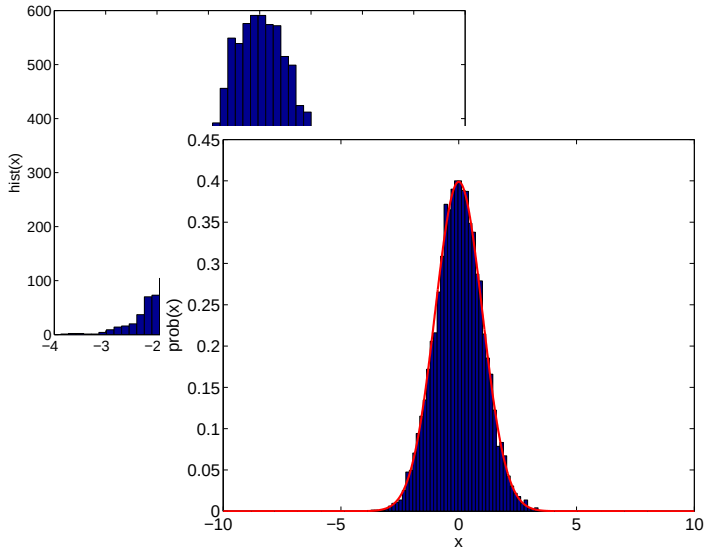
Histograma del ejemplo del rechazo



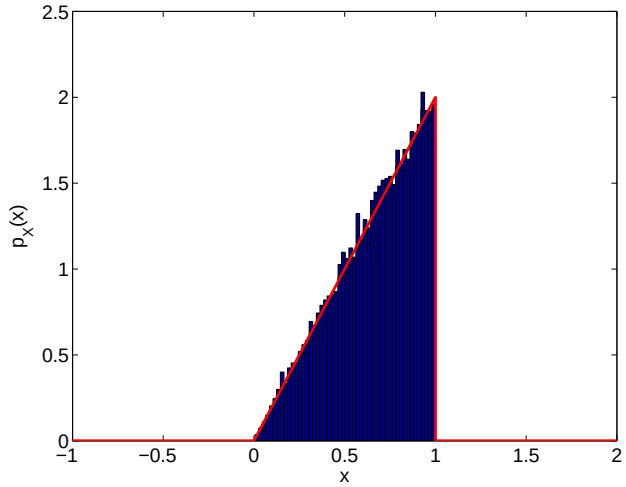
Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



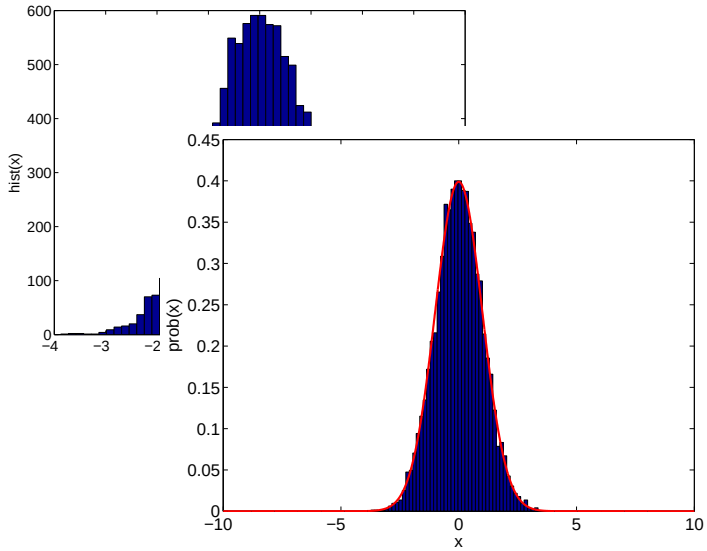
Histograma del ejemplo del rechazo



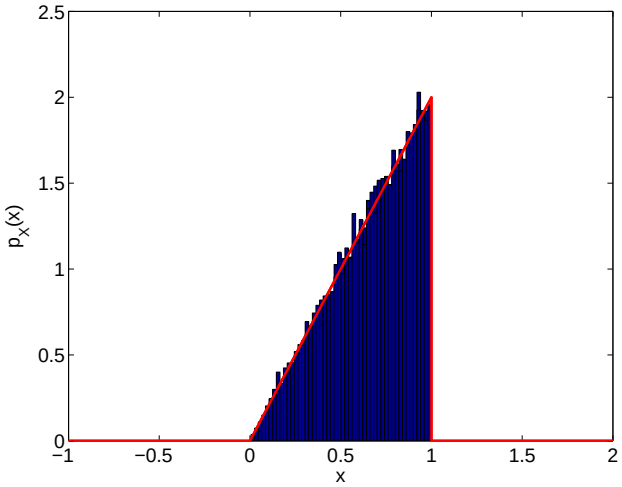
Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

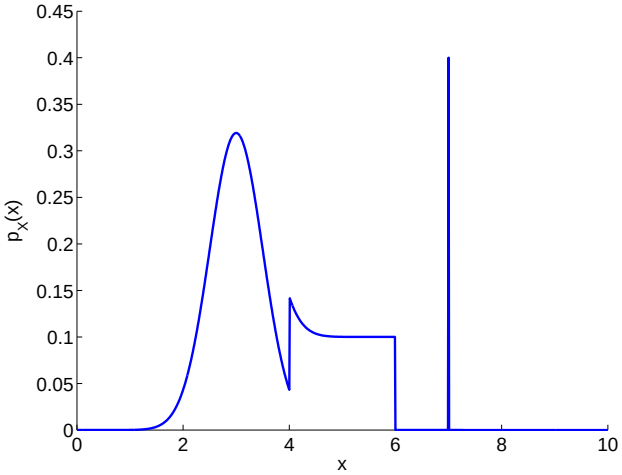
```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



Histograma del ejemplo del rechazo



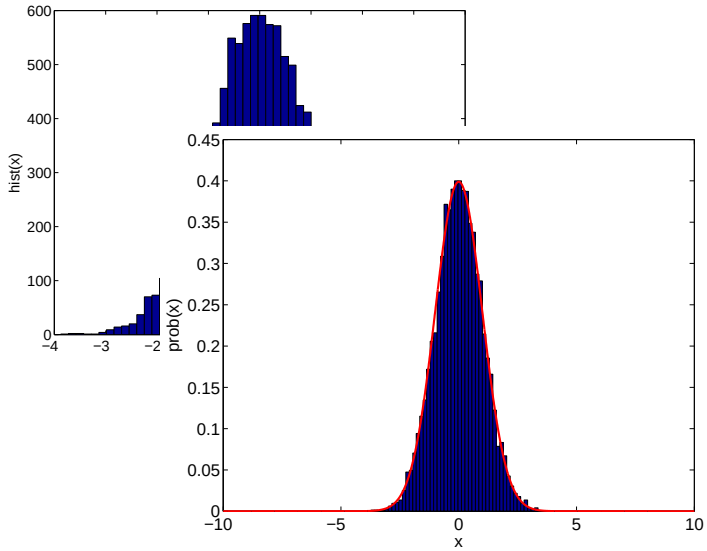
Histograma del ejemplo de la mezcla



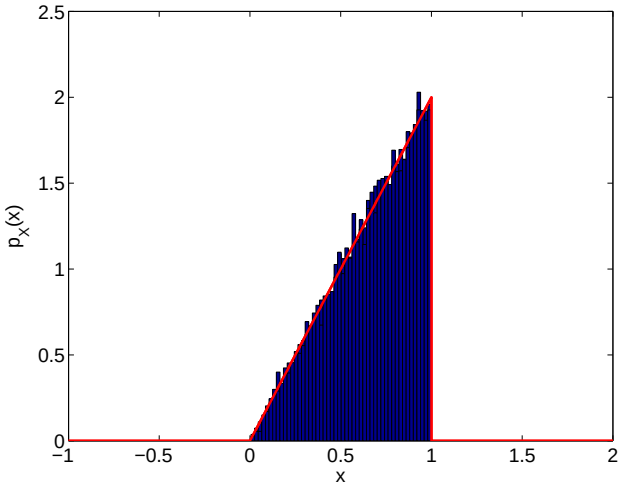
Histograma de un conjunto muestral II

Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

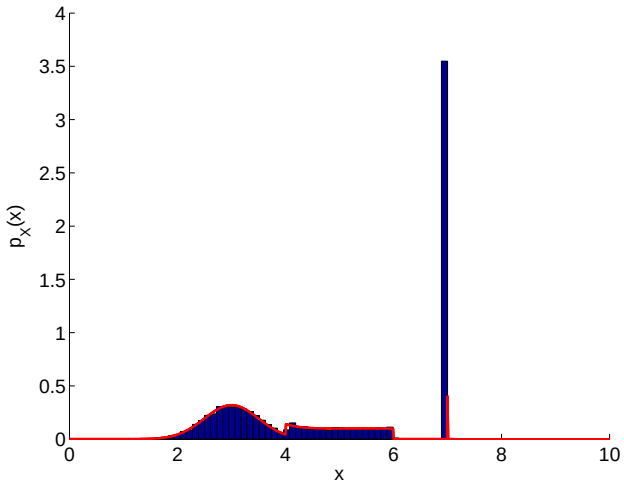
```
N=10000;  %10000 muestras
samples=randn(N,1);
hist(samples,50);  %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
 %Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
 %Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```



Histograma del ejemplo del rechazo



Histograma del ejemplo de la mezcla



Métodos de Monte-Carlo

- ¿Como podemos estimar el valor de los estadísticos a partir de las muestras directamente?

Métodos de Monte-Carlo

- ¿Como podemos estimar el valor de los estadísticos a partir de las muestras directamente?
- Podemos aproximar la probabilidad que representan las N muestras por: $p_X(x) = \frac{1}{N} \sum_{n=1}^{N} \delta(x - x_i)$.

Métodos de Monte-Carlo

- ¿Como podemos estimar el valor de los estadísticos a partir de las muestras directamente?
- Podemos aproximar la probabilidad que representan las N muestras por: $p_X(x) = \frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)$.
- A partir de esa fórmula, podemos obtener los estadísticos directamente:
  - $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx = \int_{-\infty}^{\infty} g(x)\frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)dx =$

Métodos de Monte-Carlo

- ¿Como podemos estimar el valor de los estadísticos a partir de las muestras directamente?
- Podemos aproximar la probabilidad que representan las N muestras por: $p_X(x) = \frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)$.
- A partir de esa fórmula, podemos obtener los estadísticos directamente:
  - $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx = \int_{-\infty}^{\infty} g(x)\frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)dx =$
    $= \frac{1}{N}\sum_{n=1}^{N} g(x_i)$
  - Valor medio: $\mu_X = E(X) = \frac{1}{N}\sum_{n=1}^{N} x_i$
  - Valor cuadrático medio: $E(X^2) = \frac{1}{N}\sum_{n=1}^{N} x_i^2$
  - Varianza: $\sigma_X^2 = E((X - \mu_X)^2) = \frac{1}{N}\sum_{n=1}^{N}(x_i - \mu_x)^2$

Métodos de Monte-Carlo

- ¿Como podemos estimar el valor de los estadísticos a partir de las muestras directamente?
- Podemos aproximar la probabilidad que representan las N muestras por: $p_X(x) = \frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)$.
- A partir de esa fórmula, podemos obtener los estadísticos directamente:
  - $E(g(X)) = \int_{-\infty}^{\infty} g(x)p_X(x)dx = \int_{-\infty}^{\infty} g(x)\frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)dx =$
    $= \frac{1}{N}\sum_{n=1}^{N} g(x_i)$
  - Valor medio: $\mu_X = E(X) = \frac{1}{N}\sum_{n=1}^{N} x_i$
  - Valor cuadrático medio: $E(X^2) = \frac{1}{N}\sum_{n=1}^{N} x_i^2$
  - Varianza: $\sigma_X^2 = E((X - \mu_X)^2) = \frac{1}{N}\sum_{n=1}^{N}(x_i - \mu_x)^2$
- Los estadísticos básicos se pueden calcular directamente con Matlab:
  - Valor medio: `mu=mean(samples)`
  - Varianza[1]: `sigma2=var(samples,1)`
  - Desviación estandard[1] (σ_X): `sigma=std(samples,1)`

[1] El segundo parámetro tiene que tomar el valor de 1 para que se calcule la varianza dividiendo los resultados entre N.

Esquema

1. Objetivos
2. Introducción
3. Variables aleatorias
   - Una variable aleatoria
   - Múltiples variables aleatorias
4. Señales aleatorias

Definición de múltiples variables aleatorias I

- Las propiedades de un conjunto $\{X_1, X_2, \ldots, X_M\}$ de variables aleatorias se definen a través de la función probabilidad[1] conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Las probabilidad conjunta se refiere al hecho de la probabilidad de la variable X_1 se encuentre en el estado x_1 y la variable X_2 se encuentre en el estado x_2 ... y la variable X_M se encuentre en el estado x_M.

[1] Aunque la definición de las variables aleatorias puede realizarse, al igual que en el caso de continuos, a través de diferentes funciones de probabilidad, vamos a utilizar la definición de probabilidad de masa y densidad de probabilidad.

Definición de múltiples variables aleatorias I

- Las propiedades de un conjunto $\{X_1, X_2, \ldots, X_M\}$ de variables aleatorias se definen a través de la función probabilidad[1] conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Las probabilidad conjunta se refiere al hecho de la probabilidad de la variable X_1 se encuentre en el estado x_1 y la variable X_2 se encuentre en el estado x_2 ... y la variable X_M se encuentre en el estado x_M.
- Operaciones básicas de probabilidades:
  - Regla de la cadena (existen $M!$ factorizaciones posibles):
    $$p_{\{X_1, \ldots, X_M\}}(x_1, \ldots, x_M) = p_{X_1}(x_1 | x_2, \ldots, x_M) p_{X_2}(x_2 | x_3, \ldots, x_M) \cdots p_{X_M}(x_M)$$

[1] Aunque la definición de las variables aleatorias puede realizarse, al igual que en el caso de continuos, a través de diferentes funciones de probabilidad, vamos a utilizar la definición de probabilidad de masa y densidad de probabilidad.

Definición de múltiples variables aleatorias I

- Las propiedades de un conjunto $\{X_1, X_2, \ldots, X_M\}$ de variables aleatorias se definen a través de la función probabilidad[1] conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Las probabilidad conjunta se refiere al hecho de la probabilidad de la variable X_1 se encuentre en el estado x_1 y la variable X_2 se encuentre en el estado x_2 ... y la variable X_M se encuentre en el estado x_M.
- Operaciones básicas de probabilidades:
  - Regla de la cadena (existen $M!$ factorizaciones posibles):
    $p_{\{X_1, \ldots, X_M\}}(x_1, \ldots, x_M) = p_{X_1}(x_1|x_2, \ldots, x_M) p_{X_2}(x_2|x_3, \ldots, x_M) \cdots p_{X_M}(x_M)$
  - Independencia condicional de X_a de X_b dados los valores de $\{x_1, \ldots, x_L\}$:
    $p(x_a|x_1, \ldots, x_L, x_b) = p(x_a|x_1, \ldots, x_L)$

[1] Aunque la definición de las variables aleatorias puede realizarse, al igual que en el caso de continuos, a través de diferentes funciones de probabilidad, vamos a utilizar la definición de probabilidad de masa y densidad de probabilidad.

Definición de múltiples variables aleatorias I

- Las propiedades de un conjunto $\{X_1, X_2, \ldots, X_M\}$ de variables aleatorias se definen a través de la función probabilidad[1] conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Las probabilidad conjunta se refiere al hecho de la probabilidad de la variable X_1 se encuentre en el estado x_1 y la variable X_2 se encuentre en el estado x_2 ... y la variable X_M se encuentre en el estado x_M.
- Operaciones básicas de probabilidades:
  - Regla de la cadena (existen $M!$ factorizaciones posibles):
    $p_{\{X_1, \ldots, X_M\}}(x_1, \ldots, x_M) = p_{X_1}(x_1|x_2, \ldots, x_M) p_{X_2}(x_2|x_3, \ldots, x_M) \cdots p_{X_M}(x_M)$
  - Independencia condicional de X_a de X_b dados los valores de $\{x_1, \ldots, x_L\}$:
    $p(x_a|x_1, \ldots, x_L, x_b) = p(x_a|x_1, \ldots, x_L)$
  - Independencia condicional de un conjunto de variables[2]:
    $p_{\{X_1, \ldots, X_M\}}(x_1, \ldots, x_M) = \prod_{i=1}^{M} p_{X_i}(x_i)$

[1] Aunque la definición de las variables aleatorias puede realizarse, al igual que en el caso de continuos, a través de diferentes funciones de probabilidad, vamos a utilizar la definición de probabilidad de masa y densidad de probabilidad.

[2] La expresión se obtiene a partir de la regla de la cadena y aplicando el hecho de que son probabilisticamente independientes todas de todas.

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{X_1, X_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{X_1, X_2\}}(x_1, x_2) dx_2$

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{X_1, X_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{X_1, X_2\}}(x_1, x_2) dx_2$
  - Teorema Bayes[1]: $p_{X_1}(x_1|x_2) = \frac{p_{X_2}(x_2|x_1) p_{X_1}(x_1)}{p_{X_2}(x_2)}$

[1] Se puede derivar a partir de la regla de la cadena para un conjunto de dos variables: $p(x_1, x_2) = p(x_1|x_2)p(x_2) = p(x_2|x_1)p(x_1)$

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{X_1,X_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{X_1,X_2\}}(x_1, x_2) dx_2$
  - Teorema Bayes[1]: $p_{X_1}(x_1|x_2) = \frac{p_{X_2}(x_2|x_1)p_{X_1}(x_1)}{p_{X_2}(x_2)}$

Ejemplo continuo: Representar la distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$

[1] Se puede derivar a partir de la regla de la cadena para un conjunto de dos variables: $p(x_1, x_2) = p(x_1|x_2)p(x_2) = p(x_2|x_1)p(x_1)$

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{X_1,X_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{X_1,X_2\}}(x_1, x_2) dx_2$
  - Teorema Bayes[1]: $p_{X_1}(x_1|x_2) = \frac{p_{X_2}(x_2|x_1)p_{X_1}(x_1)}{p_{X_2}(x_2)}$

Ejemplo continuo: Representar la distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$

$$p_{X_1}(x_1) = \begin{cases} \frac{1}{4-2} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

$$p_{X_2}(x_2|x_1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}}$$

$$p_{\{X_1,X_2\}}(x_1, x_2) = p(x_2|x_1)p(x_1) =$$

$$= \begin{cases} \frac{1}{2\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

[1] Se puede derivar a partir de la regla de la cadena para un conjunto de dos variables: $p(x_1, x_2) = p(x_1|x_2)p(x_2) = p(x_2|x_1)p(x_1)$

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{x_1,x_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{x_1,x_2\}}(x_1, x_2) dx_2$
  - Teorema Bayes[1]: $p_{X_1}(x_1|x_2) = \frac{p_{X_2}(x_2|x_1)p_{X_1}(x_1)}{p_{X_2}(x_2)}$

Ejemplo continuo: Representar la distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$

$$p_{X_1}(x_1) = \begin{cases} \frac{1}{4-2} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

$$p_{X_2}(x_2|x_1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}}$$

$$p_{\{X_1,X_2\}}(x_1, x_2) = p(x_2|x_1)p(x_1) =$$

$$= \begin{cases} \frac{1}{2\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

```
x1=0:0.1:10;x2=0:0.1:10;
[X1,X2]=meshgrid(x1,x2);
P=exp(-(X2-X1).^2/2)/sqrt(2*pi)/2
P(X1<2)=0;P(X1>4)=0;
mesh(X1,X2,P);
xlabel('x');ylabel('y');
```

[1] Se puede derivar a partir de la regla de la cadena para un conjunto de dos variables: $p(x_1, x_2) = p(x_1|x_2)p(x_2) = p(x_2|x_1)p(x_1)$

Definición de múltiples variables aleatorias II

- Operaciones básicas de probabilidades conjuntas:
  - Marginalización (probabilidad de un subconjunto):
    - ★ Variables discretas: $p_{X_1}(x_1) = \sum_{x_2 \in x_2} p_{\{x_1,x_2\}}(x_1, x_2)$
    - ★ Variables continuas: $p_{X_1}(x_1) = \int_{-\infty}^{\infty} p_{\{x_1,x_2\}}(x_1, x_2) dx_2$
  - Teorema Bayes[1]: $p_{X_1}(x_1|x_2) = \frac{p_{X_2}(x_2|x_1)p_{X_1}(x_1)}{p_{X_2}(x_2)}$

Ejemplo continuo: Representar la distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$

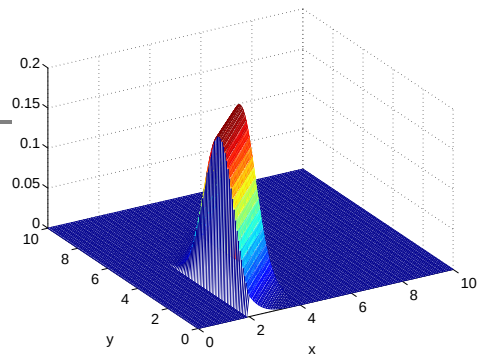
$$p_{X_1}(x_1) = \begin{cases} \frac{1}{4-2} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

$$p_{X_2}(x_2|x_1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}}$$

$$p_{\{X_1,X_2\}}(x_1, x_2) = p(x_2|x_1)p(x_1) =$$

$$= \begin{cases} \frac{1}{2\sqrt{2\pi}} e^{-\frac{(x_2-x_1)^2}{2}} & 2 \leq x_1 \leq 4 \\ 0 & c.c. \end{cases}$$

```
x1=0:0.1:10;x2=0:0.1:10;
[X1,X2]=meshgrid(x1,x2);
P=exp(-(X2-X1).^2/2)/sqrt(2*pi)/2
P(X1<2)=0;P(X1>4)=0;
mesh(X1,X2,P);
xlabel('x');ylabel('y');
```



[1] Se puede derivar a partir de la regla de la cadena para un conjunto de dos variables: $p(x_1, x_2) = p(x_1|x_2)p(x_2) = p(x_2|x_1)p(x_1)$

Estadísticos de conjuntos de variables aleatorias

- Suponemos un conjunto de variables aleatorias $\mathcal{X} = \{X_1, X_2, \ldots, X_M\}$ y su función de probabilidad conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Los estadísticos que se suelen utilizar son:

Estadísticos de conjuntos de variables aleatorias

- Suponemos un conjunto de variables aleatorias $\mathcal{X} = \{X_1, X_2, \ldots, X_M\}$ y su función de probabilidad conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Los estadísticos que se suelen utilizar son:
  - Los estadísticos de cada variable aleatoria por separado: son los mismos que los de una variable aleatoria (sobre la función de probabilidad marginal asociada a cada variable):
    - ★ $p_{X_i}(x_i) = \int\int\int_{-\infty}^{\infty} p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M) dx_1 \cdots dx_{i-1} dx_{i+1} dx_M$
    - ★ Media: $\mu_{X_i} = E(X_i) = \int_{-\infty}^{\infty} x_i p_{X_i}(x_i) dx_i$
    - ★ Valor cuadrático medio: $E(X_i^2) = \int_{-\infty}^{\infty} x_i^2 p_{X_i}(x_i) dx_i$
    - ★ Varianza: $\sigma_{x_i}^2 = E((X_i - \mu_{x_i})^2) = \int_{-\infty}^{\infty} (x_i - \mu_{x_i})^2 p_{X_i}(x_i) dx_i = E(X_i^2) - \mu_{X_i}^2$

Estadísticos de conjuntos de variables aleatorias

- Suponemos un conjunto de variables aleatorias $\mathcal{X} = \{X_1, X_2, \ldots, X_M\}$ y su función de probabilidad conjunta $p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M)$.
- Los estadísticos que se suelen utilizar son:
  - Los estadísticos de cada variable aleatoria por separado: son los mismos que los de una variable aleatoria (sobre la función de probabilidad marginal asociada a cada variable):
    - ★ $p_{X_i}(x_i) = \int\int\int_{-\infty}^{\infty} p_{\{X_1, X_2 \ldots, X_M\}}(x_1, x_2, \ldots, x_M) dx_1 \cdots dx_{i-1} dx_{i+1} dx_M$
    - ★ Media: $\mu_{X_i} = E(X_i) = \int_{-\infty}^{\infty} x_i p_{X_i}(x_i) dx_i$
    - ★ Valor cuadrático medio: $E(X_i^2) = \int_{-\infty}^{\infty} x_i^2 p_{X_i}(x_i) dx_i$
    - ★ Varianza: $\sigma_{x_i}^2 = E((X_i - \mu_{x_i})^2) = \int_{-\infty}^{\infty} (x_i - \mu_{x_i})^2 p_{X_i}(x_i) dx_i = E(X_i^2) - \mu_{X_i}^2$
  - Aparecen estadísticos de parejas de variables aleatorias (sobre la función de probabilidad marginal de cada par de variables):
    - ★ $p_{X_i X_j}(x_i, x_j) = \int_{-\infty}^{\infty} p_{\mathcal{X}}(x_1, x_2, \ldots, x_M) dx_{1:i-1} dx_{i+1:j-1} dx_{j+1:M}$
    - ★ Correlación cruzada: $\phi_{X_i X_j} = E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j$
    - ★ Covarianza: $\psi_{X_i X_j} = E((X_i - \mu_{X_i})(X_j - \mu_{X_j})) =$
      $= \int_{-\infty}^{\infty} (x_i - \mu_{x_i})(x_j - \mu_{x_j}) p_{X_i, X_j}(x_i, x_j) dx_i dx_j = \phi_{X_i X_j} - \mu_{X_i} \mu_{X_j}$
    - ★ Coeficiente de correlación: $\rho_{X_i X_j} = \frac{\psi_{X_i X_j}}{\sigma_{X_i} \sigma_{X_j}}$

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i) p_{X_j}(x_j) dx_i dx_j = \mu_{X_i}\mu_{X_j}$

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i) p_{X_j}(x_j) dx_i dx_j = \mu_{X_i}\mu_{X_j}$
  - No hay independencia lineal (o las variables están correlacionadas) $\rightarrow$ hay dependencia probabilística

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i) p_{X_j}(x_j) dx_i dx_j = \mu_{X_i}\mu_{X_j}$
  - No hay independencia lineal (o las variables están correlacionadas) $\rightarrow$ hay dependencia probabilística
  - Por lo tanto, la correlación cruzada de las señales ($E(X_i X_j) \neq \mu_{X_i}\mu_{X_j}$) sirve para determinar la existencia de la dependencia probabilística.

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i) p_{X_j}(x_j) dx_i dx_j = \mu_{X_i}\mu_{X_j}$
  - No hay independencia lineal (o las variables están correlacionadas) $\rightarrow$ hay dependencia probabilística
  - Por lo tanto, la correlación cruzada de las señales ($E(X_i X_j) \neq \mu_{X_i}\mu_{X_j}$) sirve para determinar la existencia de la dependencia probabilística.
- Independencia probabilística $\rightarrow \psi_{X_i X_j} = 0$ (covarianza nula)
  - $\psi_{X_i X_j} = E(X_i, X_j) - \mu_{X_i}\mu_{X_j} = \mu_{X_i}\mu_{X_j} - \mu_{X_i}\mu_{X_j}$

Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_i X_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_i X_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_i X_j}(x_i, x_j) dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i) p_{X_j}(x_j) dx_i dx_j = \mu_{X_i}\mu_{X_j}$
  - No hay independencia lineal (o las variables están correlacionadas) $\rightarrow$ hay dependencia probabilística
  - Por lo tanto, la correlación cruzada de las señales ($E(X_i X_j) \neq \mu_{X_i}\mu_{X_j}$) sirve para determinar la existencia de la dependencia probabilística.
- Independencia probabilística $\rightarrow \psi_{X_i X_j} = 0$ (covarianza nula)
  - $\psi_{X_i X_j} = E(X_i, X_j) - \mu_{X_i}\mu_{X_j} = \mu_{X_i}\mu_{X_j} - \mu_{X_i}\mu_{X_j}$
  - $\psi_{X_i X_j} \neq 0 \rightarrow$ Hay dependencia probabilística.

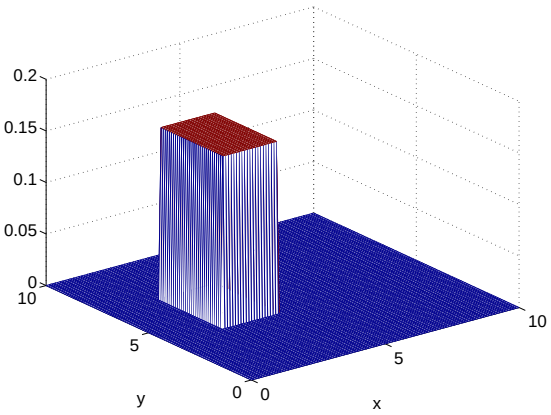
Propiedades de pares de variables aleatorias

- Independencia probabilística: $p(x_i, x_j) = p(x_i|x_j)p(x_j) = p(x_i)p(x_j)$
- Independencia lineal o falta de correlación cruzada: $E(X_iX_j) = \mu_{X_i}\mu_{X_j}$
  - Independencia probabilística $\rightarrow$ independencia lineal
    $E(X_iX_j) = \int_{-\infty}^{\infty} x_i x_j p_{X_iX_j}(x_i, x_j)dx_i dx_j = \int_{-\infty}^{\infty} x_i x_j p_{X_i}(x_i)p_{X_j}(x_j)dx_i dx_j = \mu_{X_i}\mu_{X_j}$
  - No hay independencia lineal (o las variables están correlacionadas) $\rightarrow$ hay dependencia probabilística
  - Por lo tanto, la correlación cruzada de las señales ($E(X_iX_j) \neq \mu_{X_i}\mu_{X_j}$) sirve para determinar la existencia de la dependencia probabilística.
- Independencia probabilística $\rightarrow \psi_{X_iX_j} = 0$ (covarianza nula)
  - $\psi_{X_iX_j} = E(X_i, X_j) - \mu_{X_i}\mu_{X_j} = \mu_{X_i}\mu_{X_j} - \mu_{X_i}\mu_{X_j}$
  - $\psi_{X_iX_j} \neq 0 \rightarrow$ Hay dependencia probabilística.
- Coeficiente de correlación:
  - Independencia probabilística $\rightarrow \rho_{X_iX_j} = 0$ (la covarianza es nula)
  - Dependencia lineal $\rightarrow \rho_{X_iX_j} = \pm 1$

Variables aleatorias comunes

- Conjunto de variables con una distribución uniforme: $p(x_1, \cdots, x_M) = \prod_{i=1:M} \mathcal{U}_{[a_i,b_i]}(x_i)$
  - Probabilísticamente independientes.
  - Mismas características individuales.
  - Características de los pares de variables (independencia condicional):
    - ★ Correlación cruzada:

      $\phi_{X_i X_j} = \mu_{X_i} \mu_{X_j} = \frac{b_i + a_i}{2} \frac{b_j + a_j}{2}$
    - ★ Covarianza: $\psi_{X_i X_j} = 0$



Variables aleatorias comunes

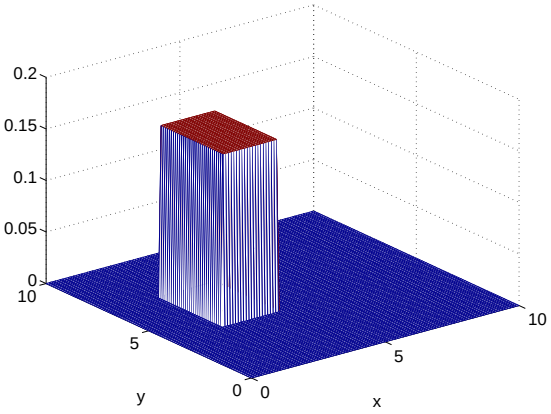
- Conjunto de variables con una distribución uniforme: $p(x_1, \cdots, x_M) = \prod_{i=1:M} \mathcal{U}_{[a_i,b_i]}(x_i)$
  - Probabilísticamente independientes.
  - Mismas características individuales.
  - Características de los pares de variables (independencia condicional):
    - ★ Correlación cruzada:

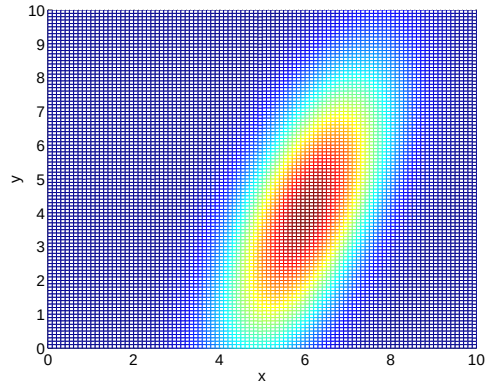
      $$\phi_{X_i X_j} = \mu_{X_i}\mu_{X_j} = \frac{b_i+a_i}{2}\frac{b_j+a_j}{2}$$

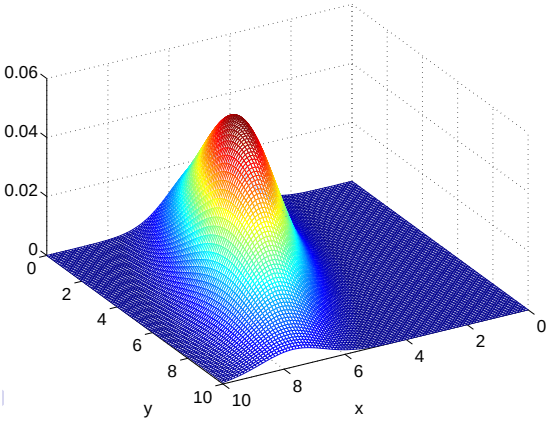
    - ★ Covarianza: $\psi_{X_i X_j} = 0$
- Conjunto de variables ($\boldsymbol{x} = [x_1, x_2, \ldots, x_M]$) con una distribución gaussiana:

  $$p(x_1, \cdots, x_M) = \frac{1}{\sqrt{(2\pi)^M |\boldsymbol{\Sigma}|}} e^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})^T}$$

  - $\boldsymbol{\mu} = [\mu_{X_1}, \mu_{X_2}, \cdots, \mu_{X_M}]$
  - $$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma^2_{X_1} & \psi_{X_1X_2} & \cdots & \psi_{X_1X_M} \\ \psi_{X_1X_2} & \sigma^2_{X_2} & \cdots & \psi_{X_2X_M} \\ \vdots & \vdots & \ddots & \vdots \\ \psi_{X_1X_M} & \psi_{X_2X_M} & \cdots & \sigma^2_{X_M} \end{bmatrix}$$



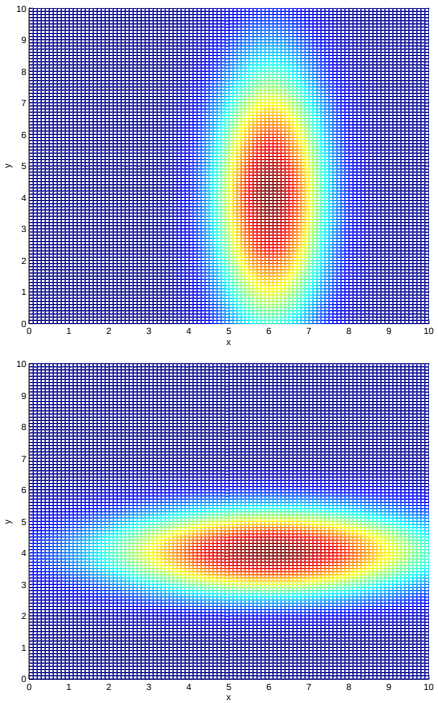




Variables aleatorias gaussianas

- La matriz de covarianza Σ representa un elipsoide M-dimensional, reorientado según los valores de la covarianza que existe entre los diferentes pares de variables.
- Σ se puede construir usando la expresión $\Sigma = \boldsymbol{RDR}'$, donde $\boldsymbol{R}$ es una matriz de rotación, y $\boldsymbol{D}$ es una matriz diagonal en la que en cada componente se coloca la varianza asociada a la dirección marcada con la matriz de rotación.
- Si tenemos la matriz Σ podemos calcular la descomposición con la orden de Matlab `svd: [R,D]=svd(Sigma).`

```
x1=0:0.1:10;x2=0:0.1:10;[X1,X2]=meshgrid(x1,x2);
P=zeros(size(X1));
ang=0;  %Orientacion
mu=[6,4];diag=[1 0;0 9];
rot=[cos(ang),sin(ang);
    -sin(ang),cos(ang)];
sigma=rot*diag*rot'
invsigma=inv(sigma);
coeff=1/2/pi/sqrt(det(sigma));
for i=1:length(x1)*length(x2)
    xvec=[X1(i),X2(i)]; xdif=xvec-[6,4];
    aux=xdif*invsigma*xdif';
    P(i)=coeff*exp(-aux/2);
end
mesh(X1,X2,P);xlabel('x');ylabel('y');
```



Muestreo de conjuntos variables aleatorias

- Si tenemos un conjunto de M variables distribuidas uniformemente, podemos aprovechar el hecho de que son independientes condicionalmente las unas de las otras y muestrear cada una de ellas de su distribución uniforme. Una muestra será formada por los conjuntos de M valores muestreados de cada distribución.
- Si tenemos un conjunto de M variables que tienen una distribución gaussiana conjunta, podemos muestrearlas a partir de la función randn, teniendo en cuenta el valor medio μ de cada variable y la matriz de covarianza $\Sigma = \boldsymbol{RDR}'$

```
mu = [1 2]; %Media
Sigma = [1 .5; .5 2]; %Covarianza
S = chol(Sigma); %''Raiz cuadrada''
x = repmat(mu,100,1) + randn(100,2)*S;
```

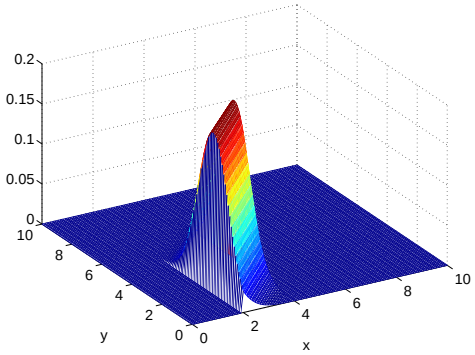
- En el caso de una distribución genérica, se utilizan métodos de simulación de Monte-Carlo. Por ejemplo, se puede hacer un muetreo ordenado, siguiendo una factorización de la distribución de probabilidad:
  $p(x_1, \ldots, x_M) = p(x_1)p(x_2|x_1)\cdots p(x_M|x_1, \cdots, x_{M-1})$.
  En esta factorización, se empezaría muestreando x_1, luego x_2 a partir del valor muestreado de x_1, y así sucesivamente.

Caracterización de las muestras

- Estimar la probabilidad conjunta de todas la variables es mucho más complicado que estimar la probabilidad de una única variable aleatoria.
  - Para simplificar el problema, se puede buscar una factorización de variables que explote las propiedades de independencia de los datos.
  - Ademas de obtener las independencias, es necesario saber que función de probabilidad captura a cada una de las variables. Lo que se suele hacer es suponer que pertenecen a una determinada familia.
- Estimar los estadísticos que hemos vistos a partir de las muestras es una labor más sencilla. Al igual que en el caso univariable se puede asimilar la probabilidad a diferentes deltas, y por lo tanto, estimar los estadísticos como sumatorios de funciones de las muestras. En el caso de los estadísticos bidimensionales, aparece un doble sumario externo (ya que es necesario realizar la integración/sumatorio respecto a las dos variables involucradas).
- Operaciones con Matlab:
  - Para que los cálculos se realicen sin problemas, es conveniente que los datos se encuentren recogidos en una matriz $\#_{datos} \cdot M$.
  - Media de cada variable: `mean(x);`
  - Matriz de covarianza: `cov(x,1);`
  - Matriz de coeficiente de correlación: `corr(x);`

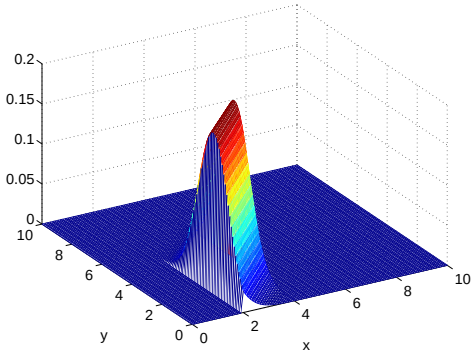
Ejemplo de muestreo y caracterizacion

Muestrear la función de distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$ y caracterizar las muestras obtenidas



Ejemplo de muestreo y caracterizacion

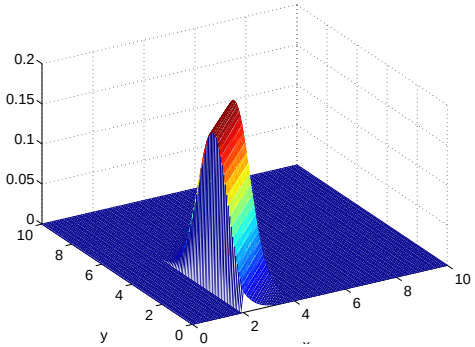
Muestrear la función de distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$ y caracterizar las muestras obtenidas

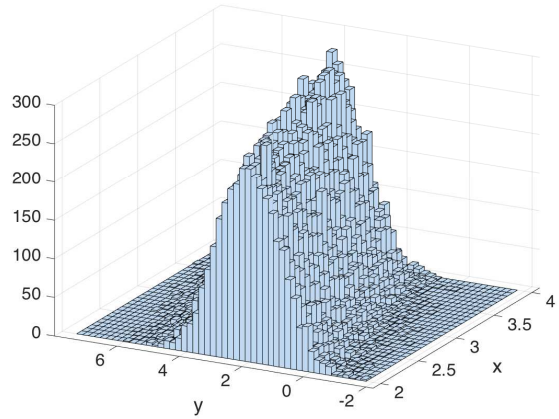



```
%Muestreo
N=100000;
x=2+2*rand(N,1);
y=x+randn(N,1);
samples=[x,y];
%Caracterizacion
%Histograma
hist3(samples,[30,50])
xlabel('x');ylabel('y')
%Estadisticos
m=mean(samples)  %Media
%Valor cuadratico medio
m2=mean(samples.*samples)
%Matriz de covarianza
sigma2=cov(samples,1)
%Correlacion cruzada
correlacion=mean(x.*y)
%Coeficiente de correlacion
rho=corr(samples)
```

Ejemplo de muestreo y caracterizacion

Muestrear la función de distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$ y caracterizar las muestras obtenidas

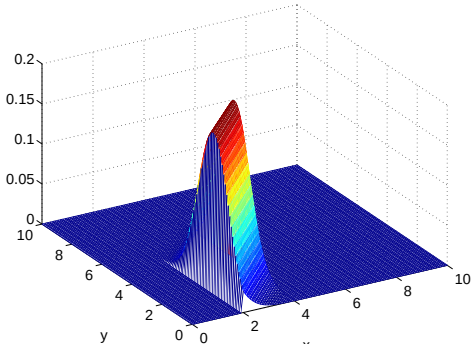




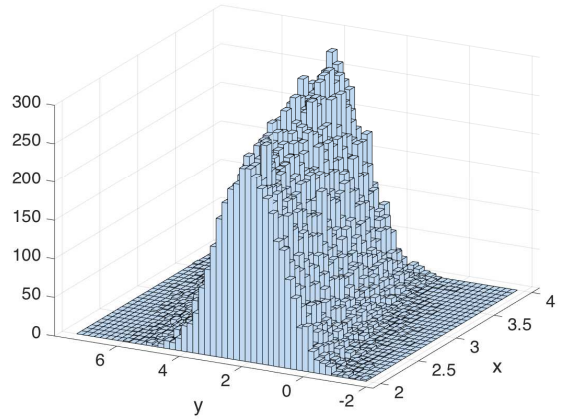

```
%Muestreo
N=100000;
x=2+2*rand(N,1);
y=x+randn(N,1);
samples=[x,y];
%Caracterizacion
%Histograma
hist3(samples,[30,50])
xlabel('x');ylabel('y')
%Estadisticos
m=mean(samples)  %Media
%Valor cuadratico medio
m2=mean(samples.*samples)
%Matriz de covarianza
sigma2=cov(samples,1)
%Correlacion cruzada
correlacion=mean(x.*y)
%Coeficiente de correlacion
rho=corr(samples)
```

Ejemplo de muestreo y caracterizacion

Muestrear la función de distribución conjunta de las variables $\{X_1, X_2\}$ a partir de $p_{X_1}(x_1) = \mathcal{U}_{[2,4]}(x_1)$ y la $p_{X_2}(x_2|x_1) = \mathcal{N}(x_2; x_1, 1)$ y caracterizar las muestras obtenidas




```
%Muestreo
N=100000;
x=2+2*rand(N,1);
y=x+randn(N,1);
samples=[x,y];
%Caracterizacion
%Histograma
hist3(samples,[30,50])
xlabel('x');ylabel('y')
%Estadisticos
m=mean(samples)  %Media
%Valor cuadratico medio
m2=mean(samples.*samples)
%Matriz de covarianza
sigma2=cov(samples,1)
%Correlacion cruzada
correlacion=mean(x.*y)
%Coeficiente de correlacion
rho=corr(samples)
```




```
m =[ 3.0012    3.0001]

sigma2 = [0.3348    0.3386
          0.3386    1.3423]

rho = [   1.0000    0.5051
          0.5051    1.0000]
```

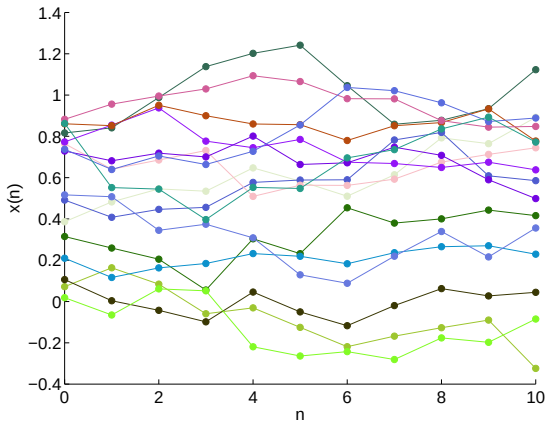
Esquema

1. Objetivos
2. Introducción
3. Variables aleatorias
4. Señales aleatorias

Señales aleatorias

- Una señal aleatoria ($x(t)$ ó $x(n)$) es aquella cuyo comportamiento en cada instante de tiempo (t ó n) se encuentra definido por una variable aleatoria asociada al instante de tiempo correspondiente ($X(t)$ ó $X(n)$).
- Al tener una variable aleatoria asociada a cada instante de tiempo, el comportamiento de la señal a lo largo del tiempo se puede definir
  - Con la función de probabilidad conjunta asociada a todas[1] las variables asociadas a la señal aleatoria
  - A partir de un número infinito de secuencias muestrales.
  - A partir de los estadísticos relacionados con las variables aleatorias

$$p(x(0), x(1), x(2), \ldots, x(10))$$



Ejemplos: $\mu_{x(n)}$, $\phi_{x(n)x(m)}$

[1] En principio, si la variable independiente es continua tendremos infinitas variables aleatorias, mientras que si la variable independiente es discreta tendremos tantas variables aleatorias como instantes de n estemos analizando.

Estadísticos de las señales aleatorias

- Los estadísticos de una señal aleatoria, o de un par de señales aleatorias, se calculan de la misma forma que se calcula los estadísticos de conjuntos de variables aleatorias:
  - Probabilidades necesarias:
    - ★ La probabilidad de la señal en cada instante: $p_{X(t)}(x(t)) \triangleq p_X(x,t)$.
    - ★ La probabilidad conjunta:
      De 1 señal en 2 instantes: $p_{X(t_1)X(t_2)}(x(t_1),x(t_2)) \triangleq p_X(x_1,t_1,x_2,t_2)$.
      De 2 señales en 2 instantes: $p_{X_i(t_i)X_j(t_j)}(x_i(t_i),x_j(t_j)) \triangleq p_{X_iX_j}(x_i,t_i,x_j,t_j)$.
  - Estadísticos habituales:
    - ★ Media: $\mu_X(t) \triangleq \mu_{X(t)} = \int_{-\infty}^{\infty} x(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} xp(x,t)dx$
    - ★ Valor cuadrático medio:
      $\Psi_X(t) \triangleq E(X^2(t)) = \int_{-\infty}^{\infty} x^2(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} x^2p(x,t)dx$
    - ★ Correlación cruzada: $\phi_{X_i,X_j}(t_i,t_j) \triangleq \phi_{X_i(t_i),X_j(t_j)} =$
      $\int_{-\infty}^{\infty} x_i(t_i)x_j(t_j)p(x_i(t_i),x_j(t_j))dx_i(t_i)dx_j(t_j) = \int_{-\infty}^{\infty} x_ix_jp(x_i,t_i,x_j,t_j)dx_idx_j$
    - ★ Autocorrelación:
      $\phi_{XX}(t_1,t_2) \triangleq \phi_{X(t_1),X(t_2)} = \int_{-\infty}^{\infty} x(t_1)x(t_2)p(x(t_1),x(t_2))dx(t_1)dx(t_2) =$
      $\int_{-\infty}^{\infty} x_1x_2p(x_1,t_1,x_2,t_2)dx_1dx_2$

Estas probabilidades se podrían obtener marginalizando de las conjuntas de la secuencia de la señal o de las secuencias de las señales las variables que no están involucradas en la probabilidad final.

Tipos de señales aleatorias I

- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$

Tipos de señales aleatorias I

- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$
  - Este hecho permite realizar una factorización muy conveniente:

$$p(x(0), x(1), \cdots, x(n)) =$$
$$= p(x(0)p(x(1)|x(0))p(x(2)|x(0), x(1)) \cdots p(x(n)|x(0), \cdots, x(n-1)) =$$
$$= p(x(0))p(x(1)|x(0))p(x(2)|x(1)) \cdots p(x(n)|x(n-1)) =$$
$$= p(x(0)) \prod_{i=1}^{n} p(x(n)|x(n-1))$$

Tipos de señales aleatorias I

- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$
  - Este hecho permite realizar una factorización muy conveniente:

    $p(x(0), x(1), \cdots, x(n)) =$

    $= p(x(0)p(x(1)|x(0))p(x(2)|x(0), x(1)) \cdots p(x(n)|x(0), \cdots, x(n-1)) =$

    $= p(x(0))p(x(1)|x(0))p(x(2)|x(1)) \cdots p(x(n)|x(n-1)) =$

    $= p(x(0)) \prod_{i=1}^{n} p(x(n)|x(n-1))$

Ejemplo: random walk gaussiano

$p(x(0)) = \mathcal{N}_X(x(0); 1; 0{,}1)$

$p(x(n)|x(n-1)) = \mathcal{N}_X(x(n); x(n-1); 0{,}25)$

Tipos de señales aleatorias I

- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$
  - Este hecho permite realizar una factorización muy conveniente:

$$p(x(0), x(1), \cdots, x(n)) =$$
$$= p(x(0)p(x(1)|x(0))p(x(2)|x(0), x(1)) \cdots p(x(n)|x(0), \cdots, x(n-1)) =$$
$$= p(x(0))p(x(1)|x(0))p(x(2)|x(1)) \cdots p(x(n)|x(n-1)) =$$
$$= p(x(0)) \prod_{i=1}^{n} p(x(n)|x(n-1))$$

Ejemplo: random walk gaussiano

$p(x(0)) = \mathcal{N}_X(x(0); 1; 0{,}1)$

$p(x(n)|x(n-1)) = \mathcal{N}_X(x(n); x(n-1); 0{,}25) \rightarrow x(n) = x(n-1) + sqrt(0{,}25) * randn$

Tipos de señales aleatorias I

- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$
  - Este hecho permite realizar una factorización muy conveniente:

$$p(x(0), x(1), \cdots, x(n)) =$$
$$= p(x(0)p(x(1)|x(0))p(x(2)|x(0), x(1)) \cdots p(x(n)|x(0), \cdots, x(n-1)) =$$
$$= p(x(0))p(x(1)|x(0))p(x(2)|x(1)) \cdots p(x(n)|x(n-1)) =$$
$$= p(x(0)) \prod_{i=1}^{n} p(x(n)|x(n-1))$$

Ejemplo: random walk gaussiano

$$p(x(0)) = \mathcal{N}_X(x(0); 1; 0{,}1)$$
$$p(x(n)|x(n-1)) = \mathcal{N}_X(x(n); x(n-1); 0{,}25) \rightarrow x(n) = x(n-1) + sqrt(0{,}25) * randn$$

```
n=0:1:10;
secuencias=[];
for l=1:50  %Bucle para varios procesos
x=0+sqrt(0.1)*randn(1);
for i=2:length(n)
    x(i)=x(:,i-1)+sqrt(0.25)*randn(1);
end
secuencias=[secuencias;x];
end
plot(n,secuencias,'LineWidth',2)
xlabel('n');ylabel('x(n)')
```

Tipos de señales aleatorias I

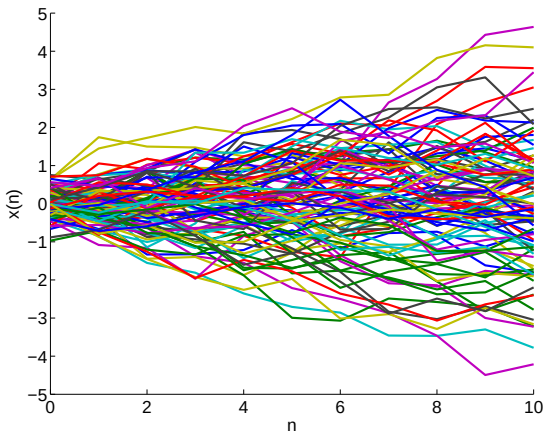
- Señal Markoviana Discreta de Orden I:
  - La probabilidad de la señal en un instante únicamente depende del valor de la variable en el instante anterior: $p(x(n)|x(n-1))$
  - Este hecho permite realizar una factorización muy conveniente:

$$p(x(0), x(1), \cdots, x(n)) =$$
$$= p(x(0)p(x(1)|x(0))p(x(2)|x(0), x(1)) \cdots p(x(n)|x(0), \cdots, x(n-1)) =$$
$$= p(x(0))p(x(1)|x(0))p(x(2)|x(1)) \cdots p(x(n)|x(n-1)) =$$
$$= p(x(0)) \prod_{i=1}^{n} p(x(n)|x(n-1))$$

Ejemplo: random walk gaussiano

$$p(x(0)) = \mathcal{N}_X(x(0); 1; 0{,}1)$$
$$p(x(n)|x(n-1)) = \mathcal{N}_X(x(n); x(n-1); 0{,}25) \rightarrow x(n) = x(n-1) + sqrt(0{,}25) * randn$$

```
n=0:1:10;
secuencias=[];
for l=1:50  %Bucle para varios procesos
x=0+sqrt(0.1)*randn(1);
for i=2:length(n)
    x(i)=x(:,i-1)+sqrt(0.25)*randn(1);
end
secuencias=[secuencias;x];
end
plot(n,secuencias,'LineWidth',2)
xlabel('n');ylabel('x(n)')
```



Tipos de señales aleatorias II

- Señal Markoviana Continua de Orden I:
  - Mientras que a la hora de modelar sistemas/señales discretos se utilizan los retardos para relacionar las variables, a la hora de modelar sistemas/señales continuos se utilizan las derivadas:

    Ejemplo discreto: $y(k) + y(k-1) + y(k-2) = x(k)$

    Ejemplo continuo: $\ddot{y}(t) + \dot{y}(t) + y(t) = x(t)$

Tipos de señales aleatorias II

- Señal Markoviana Continua de Orden I:
  - Mientras que a la hora de modelar sistemas/señales discretos se utilizan los retardos para relacionar las variables, a la hora de modelar sistemas/señales continuos se utilizan las derivadas:

    Ejemplo discreto: $y(k) + y(k-1) + y(k-2) = x(k)$

    Ejemplo continuo: $\ddot{y}(t) + \dot{y}(t) + y(t) = x(t)$
  - Por lo tanto, la relación probabilística que se establece en señales Markovianas discretas entre una señal y su versión retardada, en señales Markovianas continuas se establece entre la derivada de la señal y la señal sin derivar: $p(\dot{x}(t)|x(t))$

Tipos de señales aleatorias II

- Señal Markoviana Continua de Orden I:
  - Mientras que a la hora de modelar sistemas/señales discretos se utilizan los retardos para relacionar las variables, a la hora de modelar sistemas/señales continuos se utilizan las derivadas:

    Ejemplo discreto: $y(k) + y(k-1) + y(k-2) = x(k)$

    Ejemplo continuo: $\ddot{y}(t) + \dot{y}(t) + y(t) = x(t)$
  - Por lo tanto, la relación probabilística que se establece en señales Markovianas discretas entre una señal y su versión retardada, en señales Markovianas continuas se establece entre la derivada de la señal y la señal sin derivar: $p(\dot{x}(t)|x(t))$

    Ejemplo: proceso Markov gaussiano

    $p(x(0)) = \mathcal{N}_X(x(0); 1; 0{,}1)$

    $p(\dot{x}(t)|x(t)) = \mathcal{N}_X(\dot{x}(t); x(t); 0{,}25)$

    $\rightarrow \dot{x}(t) = x(t) + u(t)$ con $u(t) = \mathcal{N}_U(u, 0, 1)$

    Lo podríamos simular con lsim o Simulink, suponiendo un sistema de primer orden.

Tipos de señales aleatorias III

- Señales aleatorias estacionarias (en sentido amplio):

Tipos de señales aleatorias III

- Señales aleatorias estacionarias (en sentido amplio):
  - Son aquellas señales en las que la función de probabilidad no depende del tiempo: $p(x(t_1)) = p(x(t_2)) \triangleq p(x)$

Tipos de señales aleatorias III

- Señales aleatorias estacionarias (en sentido amplio):
  - Son aquellas señales en las que la función de probabilidad no depende del tiempo: $p(x(t_1)) = p(x(t_2)) \triangleq p(x)$
  - Este hecho implica que:
    - ★ Los estadísticos de una variable no dependen del tiempo:

      Media: $\mu_X(t) \triangleq \int_{-\infty}^{\infty} x(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} xp(x)dx = \mu_X$

      Valor cuadrático medio:

      $\Psi_X(t) = \int_{-\infty}^{\infty} x^2(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} x^2p(x)dx = \Psi_X$

      Varianza: $\sigma_X^2(t) = \Psi_X(t) - \mu_X^2(t) = \Psi_X - \mu_X^2 = \sigma_X^2$

Tipos de señales aleatorias III

- Señales aleatorias estacionarias (en sentido amplio):
  - Son aquellas señales en las que la función de probabilidad no depende del tiempo: $p(x(t_1)) = p(x(t_2)) \triangleq p(x)$
  - Este hecho implica que:
    - ★ Los estadísticos de una variable no dependen del tiempo:

      Media: $\mu_X(t) \triangleq \int_{-\infty}^{\infty} x(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} xp(x)dx = \mu_X$

      Valor cuadrático medio:

      $\Psi_X(t) = \int_{-\infty}^{\infty} x^2(t)p(x(t))dx(t) = \int_{-\infty}^{\infty} x^2p(x)dx = \Psi_X$

      Varianza: $\sigma_X^2(t) = \Psi_X(t) - \mu_X^2(t) = \Psi_X - \mu_X^2 = \sigma_X^2$
    - ★ Los estadísticos de dos variables dependen de la diferencia temporal:

      Correlación cruzada:

      $\phi_{X_i,X_j}(t_i, t_j) = \int_{-\infty}^{\infty} x_i(t_i)x_j(t_j)p(x_i(t_i), x_j(t_j))dx_i(t_i)dx_j(t_j) =$
      $\int_{-\infty}^{\infty} x_i(t)x_j(t+\tau)p(x_i(t), x_j(t+\tau))dx_i(t)dx_j(t+\tau) = \phi_{X_iX_j}(\tau)$

      Autocorrelación:

      $\phi_{XX}(t_1, t_2) = \int_{-\infty}^{\infty} x(t_1)x(t_2)p(x(t_1), x(t_2))dx(t_1)dx(t_2) =$
      $\int_{-\infty}^{\infty} x(t)x(t+\tau)p(x(t), x(t+\tau))dx(t)dx(t+\tau) = \phi_{XX}(\tau)$

Tipos de señales aleatorias IV

¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

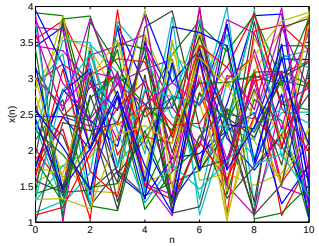
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Tipos de señales aleatorias IV

¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.

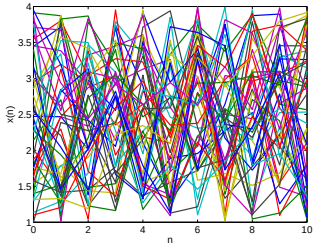


Tipos de señales aleatorias IV

¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.

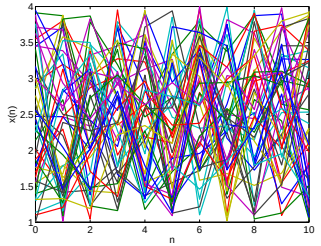


Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

Tipos de señales aleatorias IV

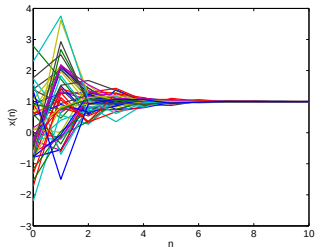
¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$



Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.

Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

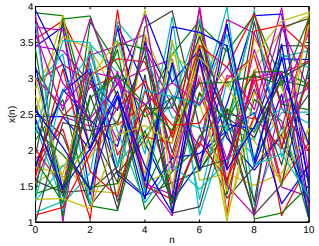


No, ya que aunque las variables son independientes la función de probabilidad cambia a lo largo del tiempo.

Tipos de señales aleatorias IV

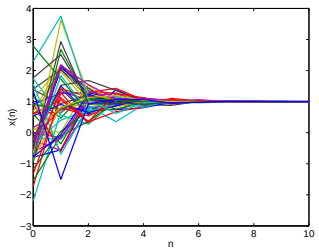
¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$



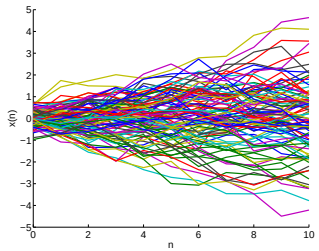
Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.

Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$



No, ya que aunque las variables son independientes la función de probabilidad cambia a lo largo del tiempo.

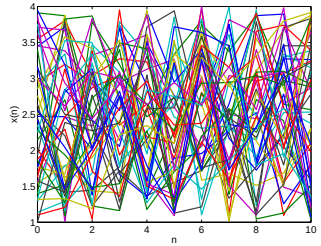
Ej3: ¿random walk gaussiano discreto propuesto?



Tipos de señales aleatorias IV

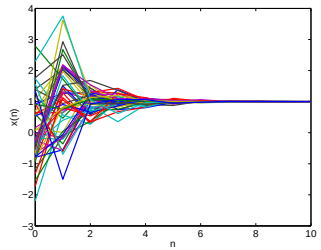
¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$



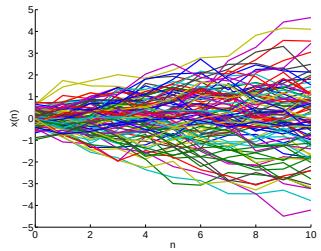
Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.

Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$



No, ya que aunque las variables son independientes la función de probabilidad cambia a lo largo del tiempo.

Ej3: ¿random walk gaussiano discreto propuesto?



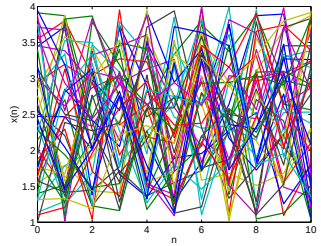
No, ya que la varianza del proceso (estadístico de una variable) aumenta a lo largo del tiempo.

Tipos de señales aleatorias IV

¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

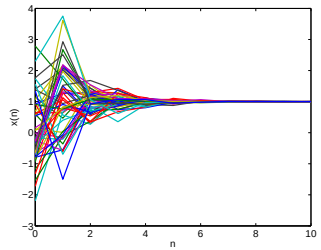
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.



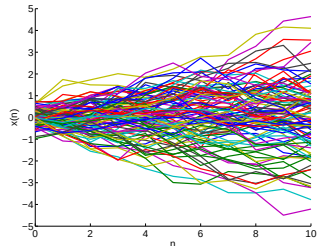
Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que aunque las variables son independientes la función de probabilidad cambia a lo largo del tiempo.

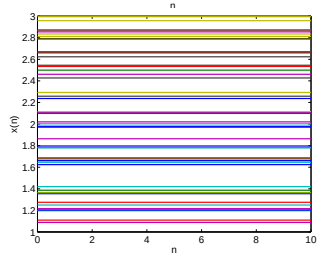


Ej3: ¿random walk gaussiano discreto propuesto?

No, ya que la varianza del proceso (estadístico de una variable) aumenta a lo largo del tiempo.



Ej4: Markoviano discreto $p(x(0)) = U_{[a,b]}(x(0))$ y $p(x(n)|x(n-1)) = \delta(x(n) - x(n-1))$

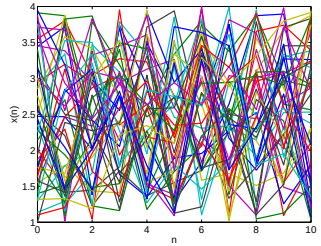


Tipos de señales aleatorias IV

¿Cuales de las señales siguientes son estacionarias (en sentido amplio)?

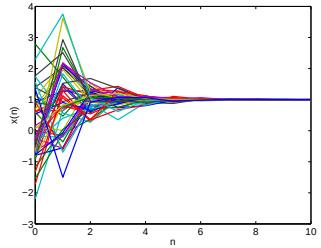
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que las variables son independientes y tienen la misma función de probabilidad a lo largo del tiempo.



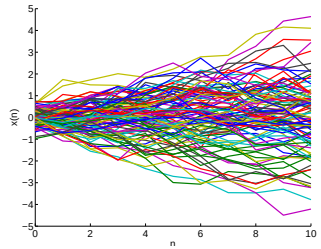
Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que aunque las variables son independientes la función de probabilidad cambia a lo largo del tiempo.



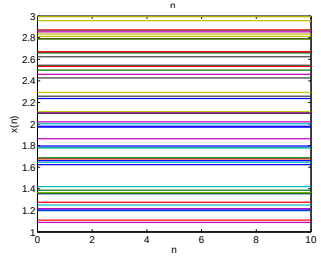
Ej3: ¿random walk gaussiano discreto propuesto?

No, ya que la varianza del proceso (estadístico de una variable) aumenta a lo largo del tiempo.



Ej4: Markoviano discreto $p(x(0)) = U_{[a,b]}(x(0))$ y $p(x(n)|x(n-1)) = \delta(x(n) - x(n-1))$

Si, ya que se puede demostrar que $p(x(n)) = U_{[a,b]}(x(n))$.



Tipos de señales aleatorias V

- Señales ergódicas:
  - Son señales aleatorias estacionarias cuyos estadísticos pueden ser caracterizados directamente a partir de una muestra (secuencia de valores) de la señal.

Tipos de señales aleatorias V

- Señales ergódicas:
  - Son señales aleatorias estacionarias cuyos estadísticos pueden ser caracterizados directamente a partir de una muestra (secuencia de valores) de la señal.
  - Es decir, en vez de tener que utilizar la función de probabilidad conjunta o las infinitas muestras de la señal en cada instante de tiempo, los estadísticos se pueden estimar a partir de los valores de una muestra de la señal real.

Tipos de señales aleatorias V

- Señales ergódicas:
  - Son señales aleatorias estacionarias cuyos estadísticos pueden ser caracterizados directamente a partir de una muestra (secuencia de valores) de la señal.
  - Es decir, en vez de tener que utilizar la función de probabilidad conjunta o las infinitas muestras de la señal en cada instante de tiempo, los estadísticos se pueden estimar a partir de los valores de una muestra de la señal real.
  - La redefinición de los estadísticos a partir de una muestra (secuencia de valores) de la señal no requiere de funciones de probabilidad, si no del cálculo de la media, ... y correlación de las señales directamente:
    - ★ Media: $\mu_X \triangleq \lim_{T\to\infty} \frac{1}{2T} \int_{-T}^{T} x(t)dt$
    - ★ Valor cuadrático medio: $\Psi_X \triangleq \lim_{T\to\infty} \frac{1}{2T} \int_{-T}^{T} x^2(t)dt$
    - ★ Correlación cruzada: $\phi_{X_i,X_j}(\tau) \triangleq \lim_{T\to\infty} \frac{1}{2T} \int_{-T}^{T} x_i(t)x_j(t+\tau)dt$
    - ★ Autocorrelación: $\phi_{XX}(\tau) \triangleq \lim_{T\to\infty} \frac{1}{2T} \int_{-T}^{T} x(t)x(t+\tau)dt$

Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

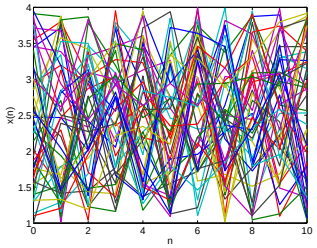
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.



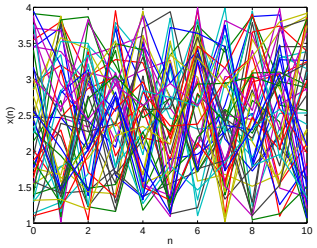
Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.

Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$



Tipos de señales aleatorias VI

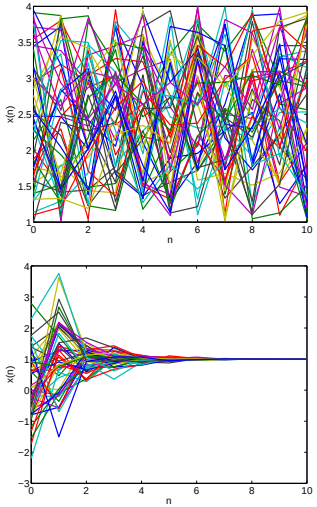
¿Cuales de las señales siguientes son ergódicas?

Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.

Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que no es estacionario.

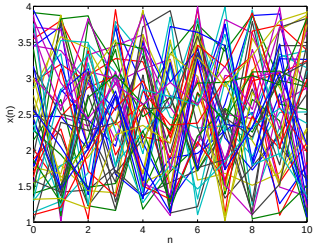


Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

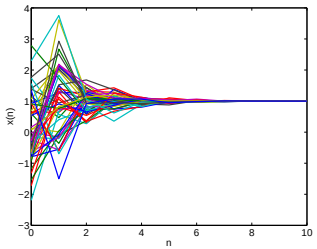
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.

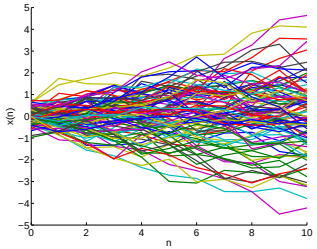


Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que no es estacionario.



Ej3: ¿random walk gaussiano discreto propuesto?

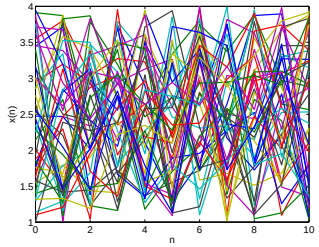


Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

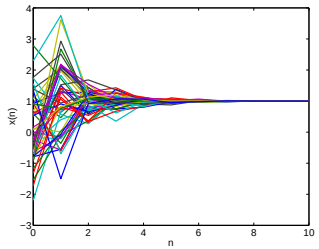
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.



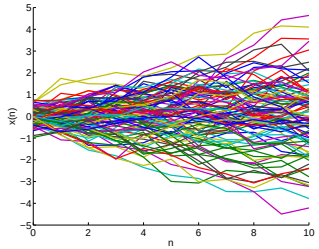
Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que no es estacionario.



Ej3: ¿random walk gaussiano discreto propuesto?

No, ya que no es estacionario.

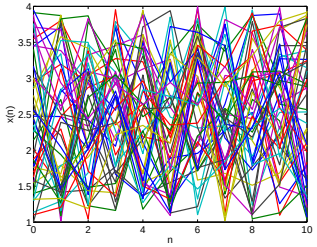


Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

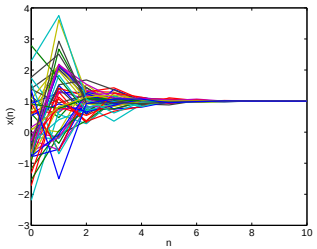
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.



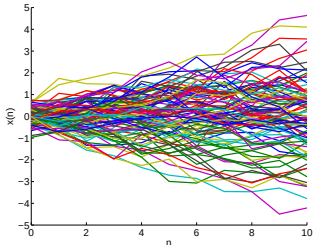
Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que no es estacionario.

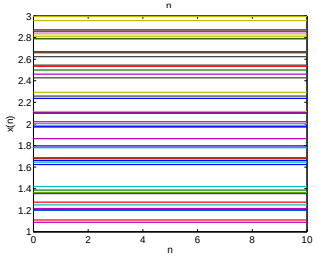


Ej3: ¿random walk gaussiano discreto propuesto?

No, ya que no es estacionario.



Ej4: Markoviano discreto $p(x(0)) = U_{[a,b]}(x(0))$ y $p(x(n)|x(n-1)) = \delta(x(n) - x(n-1))$

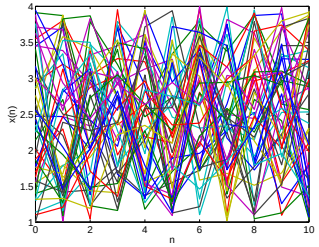


Tipos de señales aleatorias VI

¿Cuales de las señales siguientes son ergódicas?

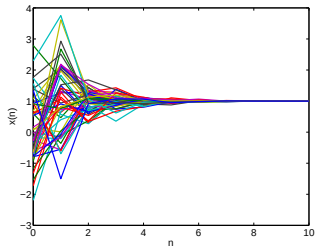
Ej1: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{U}_{[a,b]}(x(n))$

Si, ya que es estacionario y se puede obtener los estadísticos de una única secuencia de valores.



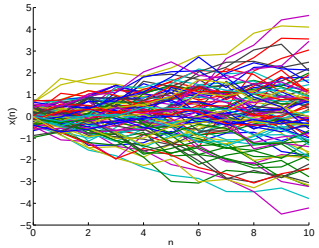
Ej2: ¿sistema discreto con variables $x(n)$ independientes y $p(x(n)) = \mathcal{N}_X(x(n); \mu_x, (0{,}5)^n)$

No, ya que no es estacionario.



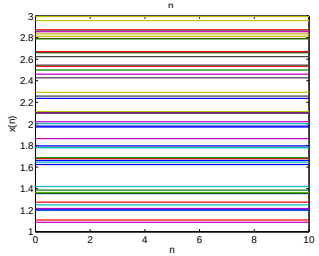
Ej3: ¿random walk gaussiano discreto propuesto?

No, ya que no es estacionario.



Ej4: Markoviano discreto $p(x(0)) = U_{[a,b]}(x(0))$ y $p(x(n)|x(n-1)) = \delta(x(n) - x(n-1))$

No, ya que una secuencia de valores no es representativa de la muestra (cada señal toma un valor constante).



Señales aleatorias estacionarias: Propiedades I

- Media (μ_X), Valor cuadrático medio (Ψ_X), y la varianza σ_X^2 son constantes en el tiempo.
- Correlación cruzada ($\phi_{XY}(\tau)$), autocorrelacion ($\phi_{XX}(\tau)$) y covarianza cruzada ($\phi_{XY}(\tau)$) dependen de la diferencia temporal τ.
- Relaciones con la autocorrelación:
  - La autocorrelación en el instante inicial es igual al valor cuadrático medio: $\phi_{XX}(0) = \Psi_X = E(X^2)$.
    $\Psi_X = E(X^2) = \int x^2(t)p(x(t))dx(t)$
    $\phi_{XX}(\tau) = \int x(t)x(t+\tau)p(x(t), x(t+\tau))dx(t)$
  - $\phi_{XX}(\infty) = |\mu_X|^2$.
  - $\phi_{XX}(0) > \phi_{XX}(\tau)$ (el máximo de la autocorrelación está en cero)
  - Estas propiedades nos pueden permitir saber si la señal tiene una componente determinista o no:
    - ★ Si no la tiene deberá tender al valor medio según pasa el tiempo.
    - ★ Si la tiene la autocorrelación tendrá un comportamiento diferente.
    - ★ Aun más, en el caso en que la señal tenga un comportamiento determinista periódico, la autocorrelación también mostrará el comportamiento periódico.

Señales aleatorias estacionarias: Propiedades II

Ejemplos de autocorrelación de señales ergódicas (usadas como casos de estacionarias porque permiten cálculos a partir de una secuencia de valores).

- `[phixy,lags]=xcorr(x,y,limk,'unbiased')`: cálculo de la correlación[1] cruzada de las señales x e y.
- `[phixy,lags]=xcorr(x,limk,'unbiased')`: cálculo de la autocorrelación[1] de la señal x.

[1] `liml` se utiliza para limitar los valores de la k sobre los que se calcula la correlación y la autocorrelación. Los límites temporales están $\tau = \pm T_s limk$.

Señales aleatorias estacionarias: Propiedades II

Ejemplos de autocorrelación de señales ergódicas (usadas como casos de estacionarias porque permiten cálculos a partir de una secuencia de valores).

- `[phixy,lags]=xcorr(x,y,limk,'unbiased')`: cálculo de la correlación[1] cruzada de las señales x e y.
- `[phixy,lags]=xcorr(x,limk,'unbiased')`: cálculo de la autocorrelación[1] de la señal x.

Ej1: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{N}(x(t); 5, 1)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=5+randn(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```

[1] `liml` se utiliza para limitar los valores de la k sobre los que se calcula la correlación y la autocorrelación. Los límites temporales están $\tau = \pm T_s limk$.

Señales aleatorias estacionarias: Propiedades II

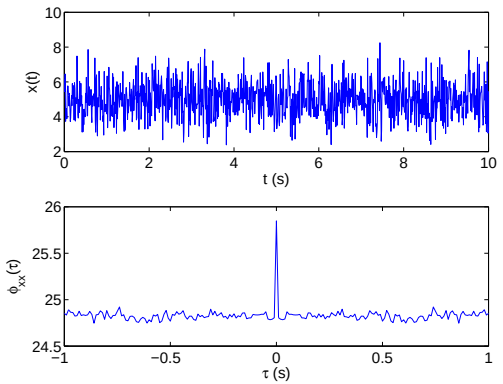
Ejemplos de autocorrelación de señales ergódicas (usadas como casos de estacionarias porque permiten cálculos a partir de una secuencia de valores).

- `[phixy,lags]=xcorr(x,y,limk,'unbiased')`: cálculo de la correlación[1] cruzada de las señales x e y.
- `[phixy,lags]=xcorr(x,limk,'unbiased')`: cálculo de la autocorrelación[1] de la señal x.

Ej1: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{N}(x(t); 5, 1)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=5+randn(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```



$$\phi_{XX}(0) = \Psi_X = \sigma_X^2 + \mu_X^2 = 26$$
$$\phi_{XX}(\infty) \to \mu_X^2 = 25$$

[1] `liml` se utiliza para limitar los valores de la k sobre los que se calcula la correlación y la autocorrelación. Los límites temporales están $\tau = \pm T_s limk$.

Señales aleatorias estacionarias: Propiedades III

Ej2: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{U}_{[2,6]}(x(t))$

Lo discretizamos con periodo $T_s = 0{,}01$

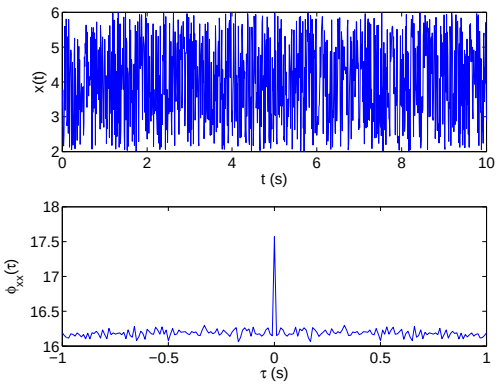
```
Ts=0.01;t=0:Ts:10;
x=2+4*rand(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```

Señales aleatorias estacionarias: Propiedades III

Ej2: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{U}_{[2,6]}(x(t))$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=2+4*rand(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```



$$\phi_{XX}(0) = \Psi_X = \frac{b^2+a^2+ab}{3} = 17{,}3$$

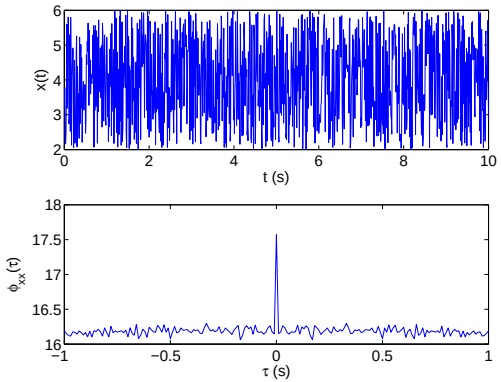
$$\phi_{XX}(\infty) \to \mu_X^2 = \left(\frac{b+a}{2}\right)^2 = 16$$

Señales aleatorias estacionarias: Propiedades III

Ej2: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{U}_{[2,6]}(x(t))$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=2+4*rand(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```



$$\phi_{XX}(0) = \Psi_X = \frac{b^2+a^2+ab}{3} = 17{,}3$$

$$\phi_{XX}(\infty) \to \mu_X^2 = \left(\frac{b+a}{2}\right)^2 = 16$$

Ej3: Sistema continuo determinista con $x(t) = sen(2\pi Ft)$ con $F = 10$ Hz.

Lo discretizamos con periodo $T_s = 0{,}01$

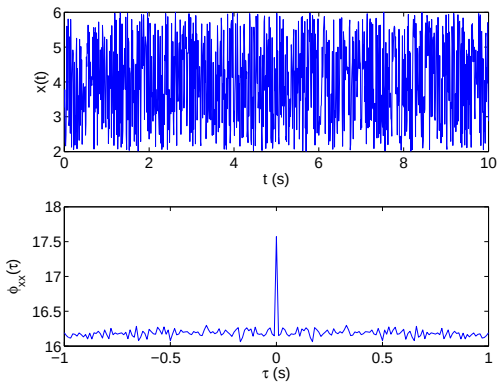
```
Ts=0.01;t=0:Ts:10;
x=sin(2*pi*F*t); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```

Señales aleatorias estacionarias: Propiedades III

Ej2: Sistema continuo con variables $x(t)$ independientes y $p(x(t)) = \mathcal{U}_{[2,6]}(x(t))$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=2+4*rand(size(t)); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```



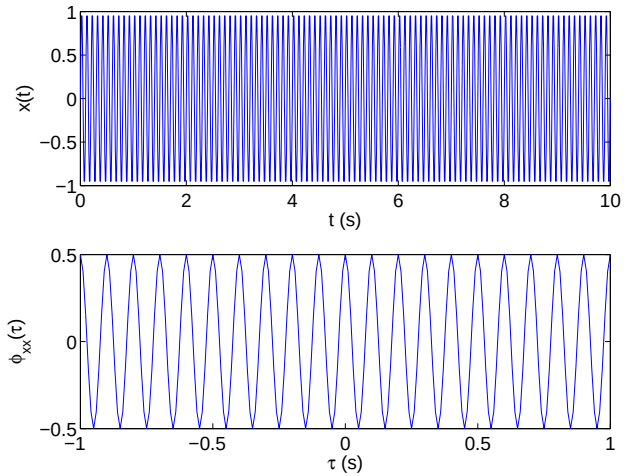
$$\phi_{XX}(0) = \Psi_X = \frac{b^2+a^2+ab}{3} = 17{,}3$$

$$\phi_{XX}(\infty) \to \mu_X^2 = \left(\frac{b+a}{2}\right)^2 = 16$$

Ej3: Sistema continuo determinista con $x(t) = sen(2\pi Ft)$ con $F = 10$ Hz.

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sin(2*pi*F*t); %Señal (modificar)
subplot(2,1,1);plot(t,x);
xlabel('t (s)');ylabel('x(t)');
[xc,lags]=xcorr(x,100,'unbias');
subplot(2,1,2);plot(lags*Ts,xc);
xlabel('\tau (s)');ylabel('\phi_{xx}(\tau)');
```



Señales aleatorias estacionarias: Propiedades IV

- Relaciones con la correlación cruzada:
  - No tiene necesariamente un máximo en $\tau = 0$
  - $\phi_{XY}(\tau) = \phi_{YX}(-\tau)$
  - $|\phi_{XY}(\tau)|^2 \leq \phi_{XX}(0)\phi_{YY}(0)$
  - $|\phi_{XY}(\tau)|^2 \leq \frac{1}{2}[\phi_{XX}(0) + \phi_{YY}(0)]$
  - Si las variables son independientes $\phi_{XY}(0) = \mu_X \mu_Y$.
- Utilidades adicionales de la función de correlación cruzada:
  - Determinar retardos entre señales: esto se debe a que en la zona en la que se superpongan la señal original y la señal retardada aparece un máximo en la señal de correlación cruzada. A veces el pico no es lo suficientemente significativo para para poder determinar el retardo.
  - Determinación de caminos de transmisión con diferentes retardos.
  - Recuperar señales con ruido (podemos calcular la correlación de la señal original sin ruido con la que viene con ruido y determinar los picos donde se superponen).

Señales aleatorias estacionarias: Propiedades V

Ejemplos de aplicación de correlación cruzada de señales.

Ej1: Calcular el desfase de las señales $x(t) = sinc(t-2)$ y $y(t) = sinc(t-3)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3);  %Cambiar señales
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```

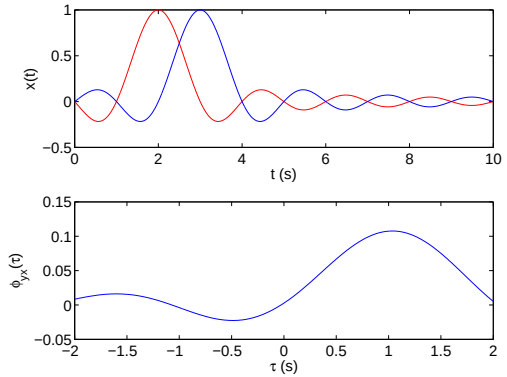
Señales aleatorias estacionarias: Propiedades V

Ejemplos de aplicación de correlación cruzada de señales.

Ej1: Calcular el desfase de las señales $x(t) = sinc(t-2)$ y $y(t) = sinc(t-3)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3);  %Cambiar señales
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```



Máximo en $\tau = 1$, tiempo que está retardada la señal.

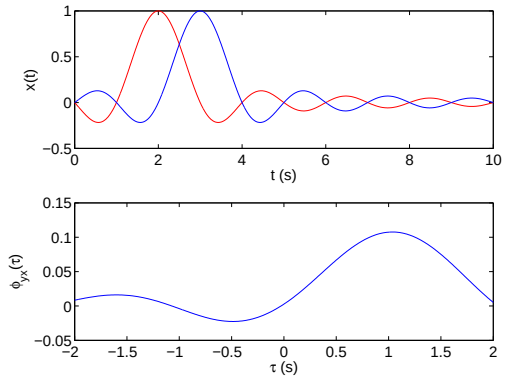
Señales aleatorias estacionarias: Propiedades V

Ejemplos de aplicación de correlación cruzada de señales.

Ej1: Calcular el desfase de las señales $x(t) = sinc(t-2)$ y $y(t) = sinc(t-3)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3);  %Cambiar señales
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```



Máximo en $\tau = 1$, tiempo que está retardada la señal.

Ej2: Localizar la señal $x(t) = sinc(t-2)$ en $y(t) = sinc(t-3) + u(t)$ con $u(t) \sim \mathcal{N}_U(u, 0, 4)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3)+2*randn(size(t));
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```

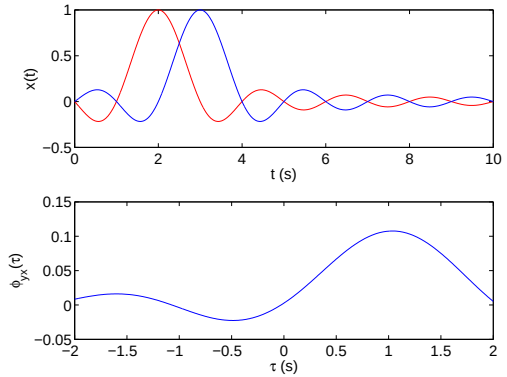
Señales aleatorias estacionarias: Propiedades V

Ejemplos de aplicación de correlación cruzada de señales.

Ej1: Calcular el desfase de las señales $x(t) = sinc(t-2)$ y $y(t) = sinc(t-3)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3);  %Cambiar señales
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```

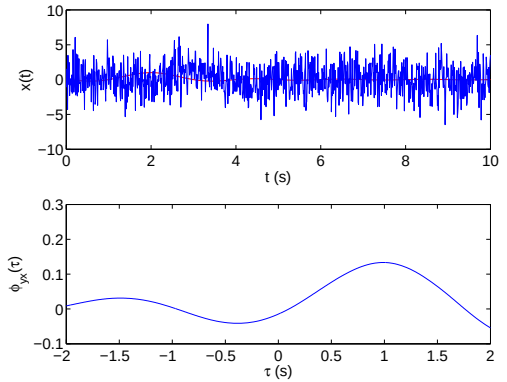


Máximo en $\tau = 1$, tiempo que está retardada la señal.

Ej2: Localizar la señal $x(t) = sinc(t-2)$ en $y(t) = sinc(t-3) + u(t)$ con $u(t) \sim \mathcal{N}_U(u, 0, 4)$

Lo discretizamos con periodo $T_s = 0{,}01$

```
Ts=0.01;t=0:Ts:10;
x=sinc(t-2);y=sinc(t-3)+2*randn(size(t));
subplot(2,1,1);plot(t,x,'r',t,y,'b');
xlabel('t (s)');ylabel('x(t)');
[yxc,lags]=xcorr(y,x,200,'unbias');
subplot(2,1,2);plot(lags*Ts,xyc);
xlabel('\tau (s)');ylabel('\phi_{yx}(\tau)');
```



Máximo en $\tau = 1$, tiempo que está retardada la señal determinista buscada

Potencia de una señal aleatoria

- La potencia de una señal aleatoria se define[1] como el valor esperado de la potencia de una señal:
  $P_X = E(\lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} x^2(n)) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} E(x^2(n))$

[1] Vamos a utilizar las definiciones sobre señales discretas en esta caso. Equivalentemente, se podría utilizar la definición sobre continuas, cambiando el sumatorio por la integral.

Potencia de una señal aleatoria

- La potencia de una señal aleatoria se define[1] como el valor esperado de la potencia de una señal:
  $P_X = E(\lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} x^2(n)) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} E(x^2(n))$
- En los casos en los que $E(x^2(n))$ es una señal aleatoria estacionaria se cumple que:
  - $P_X = E(x^2(n))$ (sumario de 2N+1 términos iguales hace que se cancele el denominador de la expresión).
  - $P_X = \phi_{XX}(0) = \sigma_X^2 + \mu_x^2$.

[1] Vamos a utilizar las definiciones sobre señales discretas en esta caso. Equivalentemente, se podría utilizar la definición sobre continuas, cambiando el sumatorio por la integral.

Potencia de una señal aleatoria

- La potencia de una señal aleatoria se define[1] como el valor esperado de la potencia de una señal:
  $P_X = E(\lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} x^2(n)) = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} E(x^2(n))$
- En los casos en los que $E(x^2(n))$ es una señal aleatoria estacionaria se cumple que:
  - $P_X = E(x^2(n))$ (sumario de 2N+1 términos iguales hace que se cancele el denominador de la expresión).
  - $P_X = \phi_{XX}(0) = \sigma_X^2 + \mu_x^2$.
- Por lo tanto, en el caso de las señales aleatorias estacionarias, la potencia de la señal se encuentra relacionada con la autocorrelación en el instante inicial[2].

---

[1] Vamos a utilizar las definiciones sobre señales discretas en esta caso. Equivalentemente, se podría utilizar la definición sobre continuas, cambiando el sumatorio por la integral.

[2] Este hecho hace que la autocorrelación se entienda como una potencia generalizada variable con τ.

Transformada de Fourier de señales aleatorias

- Las transformadas de Fourier representativas (es decir, que mejor caracterizan) a las señales aleatorias no son la transformada de una muestra/secuencia de la señal, si no las de las señales de autocorrelacion y correlación cruzada.

También se denomina espectro de densidad de potencia o simplemente espectro de potencia.

Transformada de Fourier de señales aleatorias

- Las transformadas de Fourier representativas (es decir, que mejor caracterizan) a las señales aleatorias no son la transformada de una muestra/secuencia de la señal, si no las de las señales de autocorrelacion y correlación cruzada.
- La densidad espectral de potencia[1] es la transformada de Fourier de la señal de autocorrelación:
  - Continuo: $\Phi_{XX}(jw) = \int_{-\infty}^{\infty} \phi_{XX}(\tau) e^{-jw\tau} d\tau$
  - Discreto: $\Phi_{XX}(e^{jw}) = \sum_{l=-\infty}^{\infty} \phi_{XX}(l) e^{-jwl}$
  - El espectro de potencia permite clasificar las señales aleatorias: ruido blanco, señal aleatoria de banda ancha, señal aleatoria de banda estrecha.

También se denomina espectro de densidad de potencia o simplemente espectro de potencia.

Transformada de Fourier de señales aleatorias

- Las transformadas de Fourier representativas (es decir, que mejor caracterizan) a las señales aleatorias no son la transformada de una muestra/secuencia de la señal, si no las de las señales de autocorrelacion y correlación cruzada.
- La densidad espectral de potencia[1] es la transformada de Fourier de la señal de autocorrelación:
  - Continuo: $\Phi_{XX}(jw) = \int_{-\infty}^{\infty} \phi_{XX}(\tau) e^{-jw\tau} d\tau$
  - Discreto: $\Phi_{XX}(e^{jw}) = \sum_{l=-\infty}^{\infty} \phi_{XX}(l) e^{-jwl}$
  - El espectro de potencia permite clasificar las señales aleatorias: ruido blanco, señal aleatoria de banda ancha, señal aleatoria de banda estrecha.
- La densidad espectral cruzada es la transformada de Fourier de la señal de correlación cruzada:
  - Continuo: $\Phi_{XY}(jw) = \int_{-\infty}^{\infty} \phi_{XY}(\tau) e^{-jw\tau} d\tau$
  - Discreto: $\Phi_{XY}(e^{jw}) = \sum_{l=-\infty}^{\infty} \phi_{XY}(l) e^{-jwl}$

También se denomina espectro de densidad de potencia o simplemente espectro de potencia.

Clasificación de las señales aleatorias

- Señal de ruido blanco: aquella cuyo espectro en potencia toma valor constante
  - Continuo: $\Phi_{XX}(jw) = a \rightarrow \phi_{XX}(\tau) = a\delta(\tau)$.

    No es físicamente realizable, ya que tendría que ser una señal de potencia infinita (ya que $P_X = \phi_{XX}(\tau = 0) = \infty$).
  - Discreto: $\Phi_{XX}(e^{jw}) = a \rightarrow \phi_{XX}(l) = a\delta(l)$.
- Señal con bias constante: aquella cuya autocorrelación toma un valor constante:
  - Continuo: $\Phi_{XX}(jw) = \mu_X^2\delta(w) \leftarrow \phi_{XX}(\tau) = \mu_X^2$.
  - Discreto: $\Phi_{XX}(e^{jw}) = \mu_X^2\delta(w) \leftarrow \phi_{XX}(l) = \mu_X^2$.
- Una combinación de las dos anteriores
- Señal aleatoria con espectro en potencia paso baja: es la que su espectro en potencia tiene la forma de un filtro paso bajo ideal.
- Señal aleatoria con espectro en potencia paso banda: es la que su espectro en potencia tiene la forma de un filtro paso banda ideal.
- Señal aleatoria de banda estrecha: aquella cuyo espectro en frecuencia tiene una banda en frecuencias estrecha
- Señal aleatoria de banda ancha: aquella cuyo espectro en frecuencia tiene una banda en frecuencia ancha.

Procesamiento de señales aleatorias I

- Las señales aleatorias, como señales que son, se pueden procesar con todos los sistemas lineales y filtros ideales con los que hemos trabajado a lo largo de la asignatura.
- Pero debido a su aleatoreidad, para caracterizar su comportamiento correctamente necesitamos estudiar que le sucede a la función de probabilidad o a los estadísticos de la señal aleatoria filtrada.
- Esto se pude hacer determinando que le sucede a la media, al valor cuadrático medio, autocorrelación, etc ... de la señal de salida del filtro $H(s)$ o $H(z)$ a partir de los valores de los estadísticos correspondientes de la señal de entrada.
- El análisis se puede realizar tanto en continuo como en discreto. En nuestro caso, realizaremos en discreto el análisis restante del tema.
- Y en todo momento vamos a suponer que los sistemas lineales/filtros son deterministas, y que por lo tanto, la aleatoreidad del proceso se encuentra únicamente asociado a la aleatoreidad de la señal.
- Además, también supondremos que las señales aleatorias son estacionarias (en el sentido amplio).

Procesamiento de señales aleatorias II

- La respuesta de un sistema determinista a cualquier entrada se puede calcular a través de la función de convolución:
  $y(n) = (h * x)(n) = \sum_{k=-\infty}^{\infty} h(k)x(n-k)$

Procesamiento de señales aleatorias II

- La respuesta de un sistema determinista a cualquier entrada se puede calcular a través de la función de convolución:
  $y(n) = (h * x)(n) = \sum_{k=-\infty}^{\infty} h(k)x(n-k)$
- El valor medio de la señal de salida: $\mu_Y = H(e^{j0})\mu_X$
  Se calcula aprovechando las propiedades de la linealidad del sistema
  $\mu_Y = E(y(n)) = E(\sum_{k=-\infty}^{\infty} h(k)x(n-k)) = \sum_{k=-\infty}^{\infty} h(k)E(x(n-k)) =$
  $= \mu_X \sum_{k=-\infty}^{\infty} h(k) = H(e^{j0})\mu_X$

Procesamiento de señales aleatorias II

- La respuesta de un sistema determinista a cualquier entrada se puede calcular a través de la función de convolución:
  $y(n) = (h * x)(n) = \sum_{k=-\infty}^{\infty} h(k)x(n-k)$
- El valor medio de la señal de salida: $\mu_Y = H(e^{j0})\mu_X$
  Se calcula aprovechando las propiedades de la linealidad del sistema
  $\mu_Y = E(y(n)) = E(\sum_{k=-\infty}^{\infty} h(k)x(n-k)) = \sum_{k=-\infty}^{\infty} h(k)E(x(n-k)) =$
  $= \mu_X \sum_{k=-\infty}^{\infty} h(k) = H(e^{j0})\mu_X$
- La señal de autocorrelación (productos aparecen en el dominio de la frecuencia): $\Phi_{YY}(e^{jw}) = |H(e^{jw})H(e^{-jw})|\Phi_{XX}(e^{jw})$

$$\phi_{YY}(l) = E(y(n+l)y(n)) = E\left(\left(\sum_{i=-\infty}^{\infty} h(i)x(n+l-i)\right)\left(\sum_{k=-\infty}^{\infty} h(k)x(n-k)\right)\right) =$$
$$= \sum_{i=-\infty}^{\infty} h(i) \sum_{k=-\infty}^{\infty} h(k)E(x(n+l-i)x(n-k)) =^{1}$$
$$= \sum_{i=-\infty}^{\infty} h(i) \sum_{k=-\infty}^{\infty} h(k)\psi_{XX}(l+k-i) =^{2}$$
$$= \sum_{m=-\infty}^{\infty} \psi_{XX}(l-m) \sum_{k=-\infty}^{\infty} h(k)h(m+k) = (\psi_{XX} * (h(k) * h(-k))(l)$$

En el dominio de la transformada las operaciones son más sencillas: dos convoluciones sucesivas se convierten en dos productos.
$\phi_{YY}(e^{jw}) = |H(e^{jw})H(e^{-jw})|\Phi_{XX}(e^{jw})$

---

[1] Como son señales estacionarias el valor esperado solo depende de la diferencia de los indices: $E(x(n+l-i)x(n-k)) = \psi_{XX}(l+k-i)$
[2] Cambio de variable $m = i - k$

Procesamiento de señales aleatorias III

- La señal de autocorrelacion: $\Phi_{YY}(e^{jw}) = |H(e^{jw})H(e^{-jw})|\Phi_{XX}(e^{jw})$
  - Utilidad: La expresión es especialmente útil para obtener el espectro en frecuencia de un sistema lineal con una función de transferencia desconocida:

Procesamiento de señales aleatorias III

- La señal de autocorrelacion: $\Phi_{YY}(e^{jw}) = |H(e^{jw})H(e^{-jw})|\Phi_{XX}(e^{jw})$
  - Utilidad: La expresión es especialmente útil para obtener el espectro en frecuencia de un sistema lineal con una función de transferencia desconocida:
    - ★ Para eso basta con excitar el sistema con una señal aleatoria estacionaria $x(n)$ de espectro en potencia conocido y observar el espectro en potencia de la señal de salida.
    - ★ El cociente de ambos espectros nos da el cuadrado del módulo del espectro del sistema lineal.

Procesamiento de señales aleatorias III

- La señal de autocorrelacion: $\Phi_{YY}(e^{jw}) = |H(e^{jw})H(e^{-jw})|\Phi_{XX}(e^{jw})$
  - Utilidad: La expresión es especialmente útil para obtener el espectro en frecuencia de un sistema lineal con una función de transferencia desconocida:
    - ★ Para eso basta con excitar el sistema con una señal aleatoria estacionaria $x(n)$ de espectro en potencia conocido y observar el espectro en potencia de la señal de salida.
    - ★ El cociente de ambos espectros nos da el cuadrado del módulo del espectro del sistema lineal.
- La señal de correlación cruzada: $\Phi_{XY}(e^{jw}) = H(e^{jw})\Phi_{XX}(e^{jw})$
  - La demostración es análoga a la anterior, calculando la correlación entre la señal de salida (que pasa una vez por el sistema) y la señal de entrada (que no pasa por el filtro).
  - En este caso, la expresión nos relaciona el espectro de potencia de la señal de entrada con la densidad espectral cruzada de la entrada y la salida.
  - Utilidad similar a la del caso anterior, pero ahora podemos obtener la respuesta en frecuencia completa.