Señales Aleatorias

Ingeniería Electrónica de Comunicaciones

Jesús Chacón Sombría

Departamento de Arquitectura de Computadores y Automática
Universidad Complutense de Madrid

Curso 2024-2025

Objetivos del tema

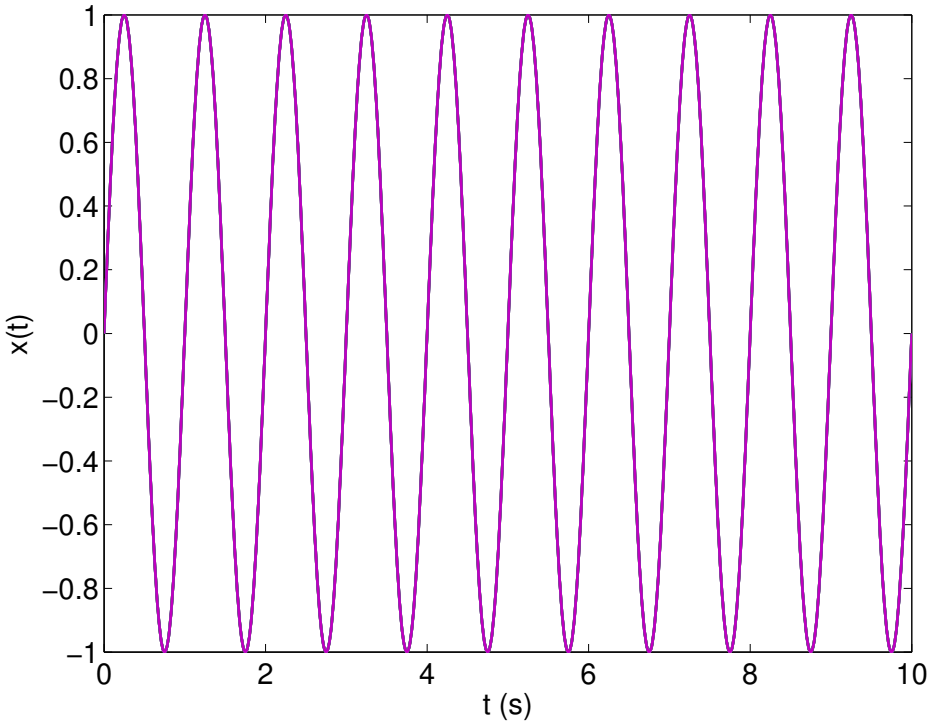
- Modelar el comportamiento de algunas señales aleatorias:
  - estacionarias,
  - ergódicas,
  - proceso de Markov.
- Definir matemáticamente las propiedades más relevantes de:
  - Variables aleatorias:
    - ★ distribución/densidad de probabilidad,
    - ★ valor medio, valor cuadrático medio, varianza,
    - ★ correlación.
  - Señales aleatorias:
    - ★ valor medio, valor cuadrático medio,
    - ★ covarianza, autocorrelación y correlación cruzada,
    - ★ densidad espectral de potencia
- Extender las técnicas de PdS a señales aleatorias

Señales deterministas y estocásticas I

- Señales deterministas:
  - Toman siempre el mismo valor para el mismo instante de tiempo.
  - Se representan por una única secuencia continua/discreta de valores.
  - El valor en cada instante puede ser definido de forma explícita.
  - Función matemática determinista: $t \rightarrow f(t)$
    relaciona el valor de la señal con el valor de variable independiente (tiempo).
- Señales estocásticas/aleatorias:
  - No toman siempre el mismo valor para un mismo instante de tiempo.
  - Colección infinita de secuencias continuas/discretas de valores.
  - El valor en cada instante es una variable aleatoria.
  - El comportamiento se define a través de una función de probabilidad.

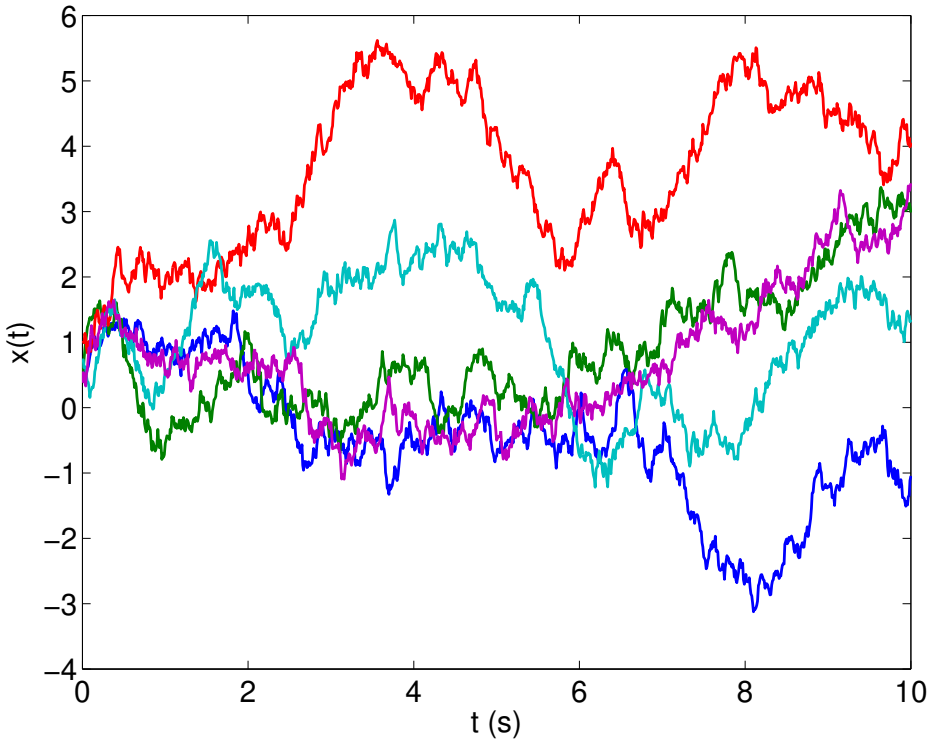
Señales deterministas y estocásticas II

Señal determinista:



$$x(t) = sen(\omega t)$$

Señal estocástica:



$$p(x(t_0), x(t_1), x(t_2), \ldots, x(t_\infty))$$

Señales deterministas y estocásticas III

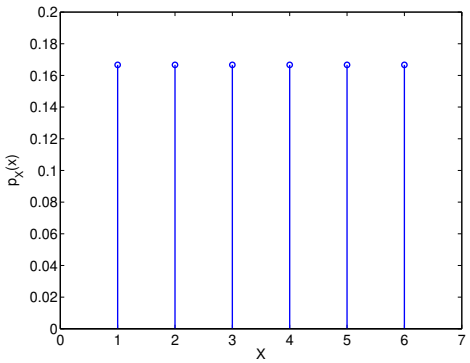
- ¿Las señales reales son deterministas o estocásticas?
  - Argumento 1: No existen señales totalmente deterministas.
    - ★ Puede existir algún fenómeno que no haya sido tenido en cuenta.
    - ★ Los valores de la señal no están totalmente determinados a priori.
  - Argumento 2: Todas las señales son intrínsecamente deterministas.
    - ★ Desconocimiento parcial del proceso que las genera.
    - ★ Por tanto no son realmente aleatorias.
- Clasificación determinista vs. estocástica:
  - Atiende al tratamiento que se le desea dar a la señal,
  - no a la forma en que la señal ha sido generada.

Definición de una variable aleatoria

- Variable aleatoria[1] X (continua o discreta):
  - Representa el resultado de un experimento aleatorio.
  - Su valor no es conocido a priori.
  - ¿Cómo podemos caracterizarla?
    - ¿Que valores puede tomar?
    - ¿Es igual de probable cada valor?

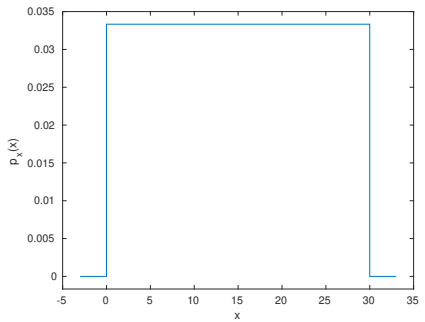
Ejemplo discreto: X valores de un dado

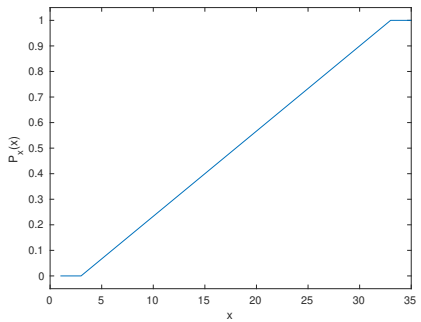
$$p_X(x) = \frac{1}{6}$$



Ejemplo continuo: X tiempo de espera

$$p_X(x) = \mathcal{U}_{X\in[0,30]}(x)$$





[1] En estadística es habitual definir la variable aleatoria con mayúsculas y sus valores con minúsculas.

Definición de una variable aleatoria

- Para variables discretas:
  - Función de *masa de probabilidad*: $p_X(x_i) = Probabilidad(X = x_i)$
  - Propiedades:
    - $0 \leq p_X(x_i) \leq 1$
    - $\sum_{x \in X} p_X(x) = 1$
- Para variables continuas:
  - *Distribución de probabilidad*: $P_X(x) = Probabilidad(X \leq x)$
  - *Densidad de probabilidad*: $p_X(x) = \frac{\partial P_X(x)}{\partial x}$
  - Propiedades:
    - $p_X(x) \geq 0 \rightarrow P_X(x)$ es una función creciente
    - $P_X(x) = \int_{-\infty}^{x} p_X(y)dy \rightarrow P_X(\infty) = 1$

Estadísticos

- Un estadístico es una medida cuantitiva de una muestra.
  - Valor esperado de alguna función $g(x)$.
    - ★ Continuo:

      $E\{g(X)\} = \int_{-\infty}^{\infty} g(x) p_X(x) dx$
    - ★ Discreto:

      $E\{g(X)\} = \sum_{x_i \in X} g(x_i) p_X(x_i)$
  - Respecto a la probabilidad $p_X(x)$.
- Trata de inferir o estimar una propiedad de la población.

Estadísticos de una variable aleatoria

- Estadísticos/características habituales (expresiones continuas[1])
  - Valor medio:

    $\mu_X \triangleq E\{X\} = \int_{-\infty}^{\infty} x p_X(x) dx$
  - Valor cuadrático medio:

    $E\{X^2\} = \int_{-\infty}^{\infty} x^2 p_X(x) dx$
  - Varianza[2]:

    $\sigma_X^2 \triangleq E\{(X-\mu_x)(X-\mu_x)\} = \int_{-\infty}^{\infty}(x-\mu_x)(x-\mu_x)p_X(x)dx$
    $= E\{X^2\} - \mu_x^2$

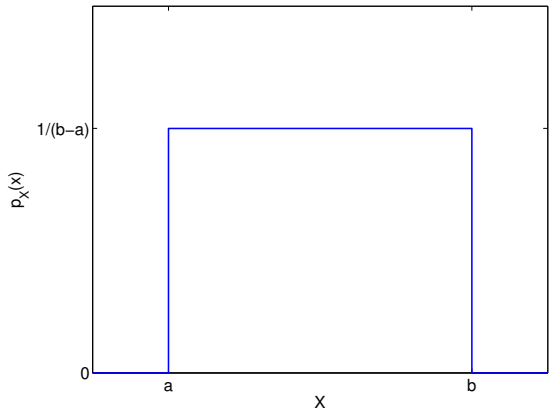
---

[1] La relación discreta se puede sacar de la continua, construyendo una función densidad de probabilidad para la variable aleatoria discreta: $p_{X_C}(x) = \sum_{x_i \in X} p_X(x_i)\delta(x - x_i) \rightarrow E(g(X_C)) = \int_{-\infty}^{\infty} g(x) \sum_{x_i \in X} p_X(x_i)\delta(x-x_i)dx = \sum_{x_i \in X} g(x_i)p_X(x_i) = E(g(X))$. Equivale a sustituir las integrales por sumarios en las relaciones de las variables continuas. Por lo tanto, podemos definir únicamente las relaciones continuas y extrapolar las discretas.

[2] Relación entre σ_X^2, μ_X y $E(X^2)$: $\sigma_X^2 = \int_{-\infty}^{\infty}(x^2 - 2\mu_X x + \mu_X^2)p_X(x)dx =$
$= E(X^2) - 2\mu_X \int_{-\infty}^{\infty} x p_X(x)dx + \mu_X^2 \int_{-\infty}^{\infty} p_X(x)dx = E(X^2) - 2\mu_X^2 + \mu_X^2$

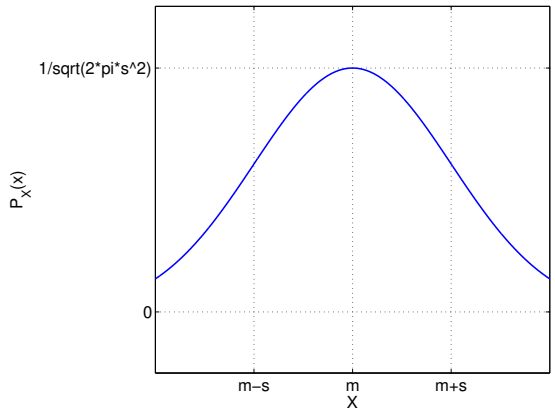
Variables aleatorias comunes

- Distribución uniforme: $p_X(x) = \mathcal{U}_{X\in[a,b]}(x) = \begin{cases} \frac{1}{b-a} & x \in [a,b] \\ 0 & c.c. \end{cases}$
  - $\mu_x = \int_{-\infty}^{\infty} x p_X(x) dx = \frac{b+a}{2}$
    $\int_a^b \frac{x}{b-a} dx = \frac{x^2}{2(b-a)}\Big|_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{b+a}{2}$
  - $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x) dx = \frac{b^2+a^2+ab}{3}$
    $\int_a^b \frac{x^2}{b-a} dx = \frac{x^3}{3(b-a)}\Big|_a^b = \frac{b^3-a^3}{3(b-a)} = \frac{b^2+a^2+ab}{3}$
  - $\sigma_X^2 = E(X^2) - \mu_X^2 = \frac{(b-a)^2}{12}$



Variables aleatorias comunes

- Distribución gaussiana: $p_X(x) = \mathcal{N}_X(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
  - $\mu_x = \int_{-\infty}^{\infty} x p_X(x) dx = \mu$
  - $E(X^2) = \int_{-\infty}^{\infty} x^2 p_X(x) dx = \sigma^2 + \mu_x^2$
  - $\sigma_X^2 = E(X^2) - \mu_X^2 = \sigma^2$



Muestreo de una variable aleatoria

- Muestreo de una variable aleatoria:
  - Obtener sus valores (muestras) de acuerdo con la densidad de probabilidad.
  - Matemáticamente representaremos la función como: $x \sim p_X(x)$
- ¿Cómo generar las muestras?
  - Experimentalmente, excitando/observando la respuesta
    - ★ de un proceso aleatorio
    - ★ de un proceso determinista con una entrada aleatoria
  - Utilizando un generador de números pseudo-aleatorios:
    - ★ Probabilidad discreta: $p_x(x_i)$ con $i \in [1 : N]$
      - Equiprobables con Matlab: `randi(#valores,filas,col)`
      - No equiprobables: método de la ruleta
    - ★ Probabilidad uniforme: $\mathcal{U}_{X\in[a,b]}(x)$
      - Matlab: `a+(b-a)*rand(filas,col)`
      - Secuencias básicas: $x_{i+1} = (a * x_i + c) \mod m$.
        Ejemplo con $a = 65539, m = 2^{29}$
    - ★ Probabilidad gaussiana: $\mathcal{N}_X(x; \mu, \sigma)$
      - Matlab: μ+σ`*randn(filas,col)`
      - Transformada de Box-Muller (a partir de la uniforme)
    - ★ Probabilidades genéricas:
      - Muestreo por rechazo, por importancia
      - Muestreo de mezclas

Muestreo de una variable aleatoria

- Método de la ruleta:
  - $p(x_i)$
  - Muestreo variable auxiliar:
    $y \sim \mathcal{U}_{y\in[0,1]}(y)$
  - $x = \{j | \sum_{i=1}^{j-1} p(x_i) < y < \sum_{i=1}^{j} p(x_i)\}$

```
p=[0.1,0.3,0.2,0.4];
cump=cumsum(p);
N=1000;

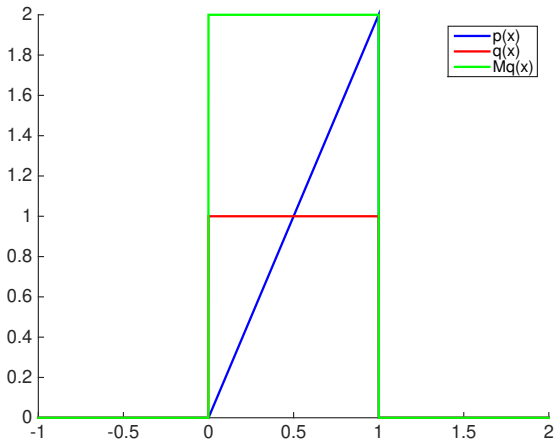
for i=1:N
    v(i)=rand(1);
    x(i)=sum(v(i)>cump)+1;
end
```

- Transformada de Box-Muller:
  - $\mathcal{N}(x, \mu=0, \sigma^2=1)$
  - Muestreo de 2 variables auxiliares:
    $y_1 \sim \mathcal{U}_{y\in[0,1]}(y)$
    $y_2 \sim \mathcal{U}_{y\in[0,1]}(y)$
  - Transformación de las muestras:
    $r = \sqrt{-2\log(y_1)}$
    $\theta = 2\pi y_2$
    $x_1 = r\cos(\theta)$
    $x_2 = r\sin(\theta)$
    Se genera un par, para hacer una guassiana de dos dimensiones o un complejo. Se puede usar solo uno.

```
N=10000;
y = rand(2,N);
r = sqrt(-2*log(y(1,:)));
theta = 2*pi*y(2,:);
x1 = r.*cos(theta); %x1 normal
x2 = r.*sin(theta); %x2 normal
%Sirve para generar una
%bidimensional (x1,x2) o
%complejo z=x1+jx2
```

Muestreo de una variable aleatoria

- Método de muestreo por rechazo:
  - Función de probabilidad genérica $p(x)$
  - Las muestras se obtienen de una $q(x)$ auxiliar que debe cumplir que para algún M que Mq(x)-p(x)>0. Este hecho fuerza a que tengan el mismo soporte (que $q(x) \neq 0$ sobre los mismos puntos x que $p(x) \neq 0$).
  - Las $x \sim q(x)$ son también muestras de $p(x)$ si se cumple que $yMq(x) < p(x)$ con $y \sim \mathcal{U}_{y \in [0,1]}(y)$




```
function x=MuestreoRechazo(N)

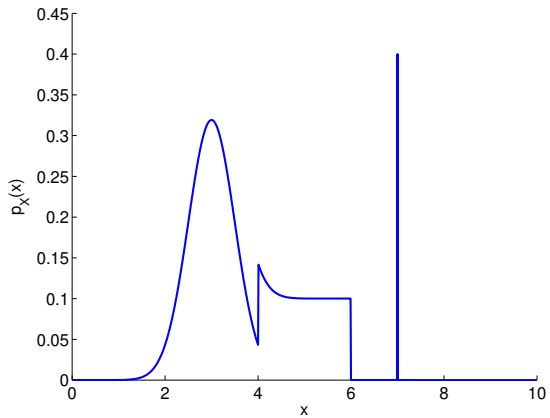
x=[];
M=2; %Valor de M
hm=0;
while hm<N
  y=rand(N-hm,1);
  xp=rand(N-hm,1); %Muestras q(x)
  l=find(y*M.*q(xp)-p(xp)<0)
  x=[x;xp(l)];
  hm=length(x)
end

function val=q(x)
%Densidad prob. q(x)
val=1;

function val=p(x)
%Densidad prob.  p(x)
val=2*x;
```

Muestreo de una variable aleatoria

- Muestreo de una mezcla:
  - Función de probabilidad genérica $p(x) = \sum_{i=1}^{L} a_i p_i(x)$, con $\sum_{i=1}^{L} a_i = 1$
  - Para muestrearla, podemos seguir el siguiente proceso:
    - ★ Elegimos la componente de la mezcla (el valor de la i) utilizando la probabilidad discreta $q(i) = a_i$
    - ★ Muestreamos la x de la componente elegida $x \sim p_i(x)$




```
function [x,aux]=MuestreoMezcla(N)

q_i=[0.4,0.2,0.4];
qsum=cumsum(q_i);
for i=1:N
    %Muestreo ruleta
    index=sum(rand>qsum)+1;
    aux(i)=index;
    switch index
        case 1,
           %gaussiana
           x(i)=3+0.5*randn;
        case 2,
           %uniforme
           x(i)=4+2*rand;
        case 3,
          %Delta centrada en 7
           x(i)=7;
    end
end
```

$$p_X(x) = 0{,}4\mathcal{N}(x, 3, 0{,}5) + 0{,}2\mathcal{U}_{[4,6]}(x) + 0{,}4\delta(x-7)$$

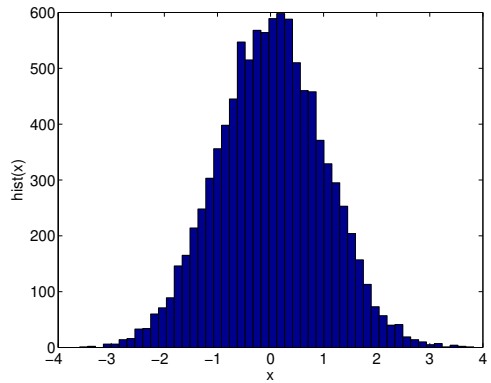
Caracterización de las muestras

- ¿Cómo podemos caracterizar una v.a. a partir de las muestras?
  - Intentar estimar la función de probabilidad:
    1. Determinar el tipo de función de probabilidad: histograma.
    2. Determinar los parámetros de la función de probabilidad.
  - Obtener el valor de los estadísticos a partir:
    - ★ de la muestras: Método de Monte-Carlo[1]
    - ★ de la función de probabilidad que se ha estimado.

[1] Los métodos de Monte-Carlo también se utilizan para estimar los estadísticos de funciones de probabilidad conocidas de las que no se pueden calcular las integrales de forma cerrada. El proceso consiste en utilizar los métodos de muestreo para generar muestras de la función de probabilidad y luego el método de Monte-Carlo para estimar el estadístico sobre las muestras generadas.

Histograma de un conjunto muestral

- El histograma divide el espacio muestral en H segmentos (cubos/bins) continuos de igual tamaño y contabiliza el número de muestras que pertenecen a cada uno de los segmentos.



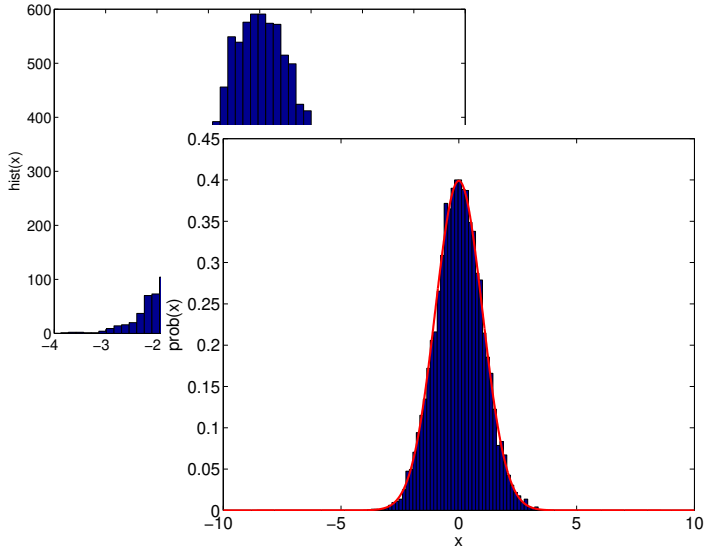
- Podemos utilizarlos para realizar una representación aproximada de la probabilidad de las muestras, siempre y cuando se normalizan las cuentas del histograma de forma que:
  - La suma de los valores normalizados del histograma sea 1 para el caso de trabajar con variables aleatorias discretas.
  - El area recogida por el histograma normalizado sea igual a 1 para el caso de trabajar con variables aleatorias continuas.
- Una análisis de la forma del histograma (o del histograma normalizado), en la que obviemos los escalones introducidos por la segmentación del espacio muestral, nos puede permitir determinar en algunos casos el tipo de función de probabilidad al que pertenecen las muestras[1].

[1] En el caso continuo, es conveniente hacer divisiones suficientemente pequeñas para que los escalones no escondan la función de probabilidad real de las muestras.

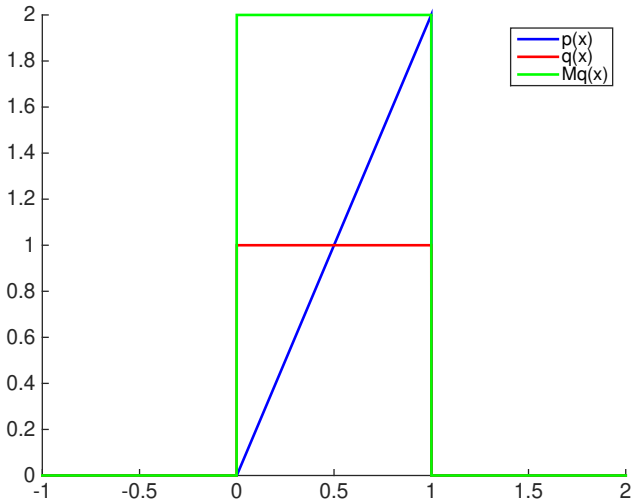
Histograma de un conjunto muestral

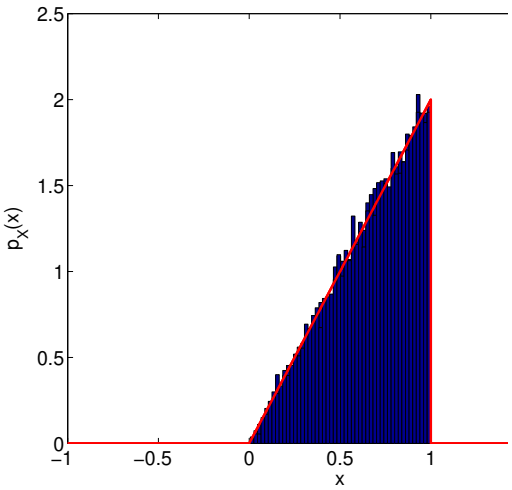
Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

```
N=10000; %10000 muestras
samples=randn(N,1);
hist(samples,50); %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
%Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
%Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```

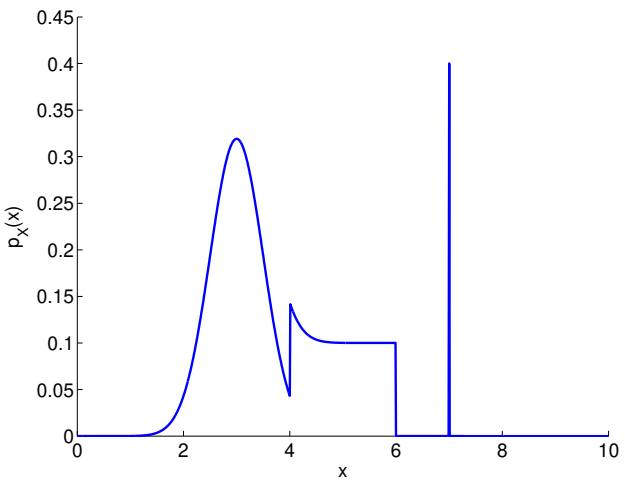


Histograma del ejemplo del rechazo





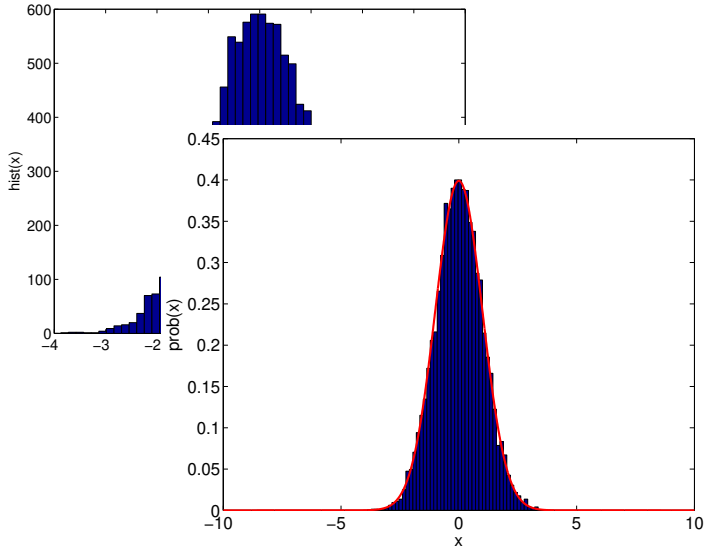
Histograma del ejemplo de la mezcla



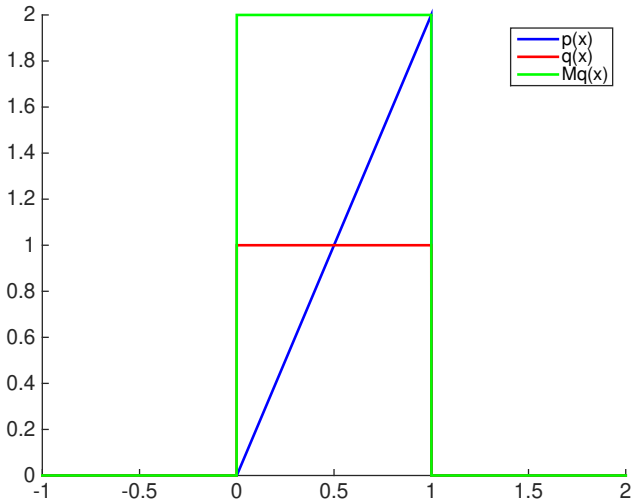
Histograma de un conjunto muestral

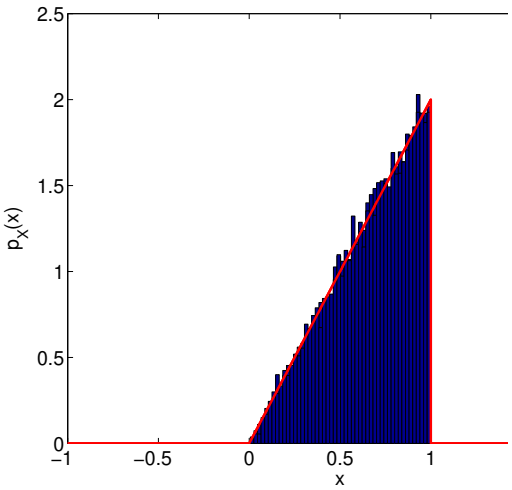
Ejemplo: Histograma de muestras $\sim \mathcal{N}_X(x, 0, 1)$

```
N=10000; %10000 muestras
samples=randn(N,1);
hist(samples,50); %Histograma con 50 bins
xlabel('x');ylabel('hist(x)');
%Normalizar histograma
[h,xbin]=hist(samples,50);
inc=xbin(2)-xbin(1);hnormal=h/N/inc;
bar(xbin,hnormal,1)
%Pintar la probabilidad encima
mu=0;sigma=1;x=-10:0.01:10;
prob=1/sqrt(2*pi*sigma)*exp(-(x-mu).^2/2/sigma^2);
hold on;plot(x,prob,'r');
xlabel('x');ylabel('prob(x)');
```

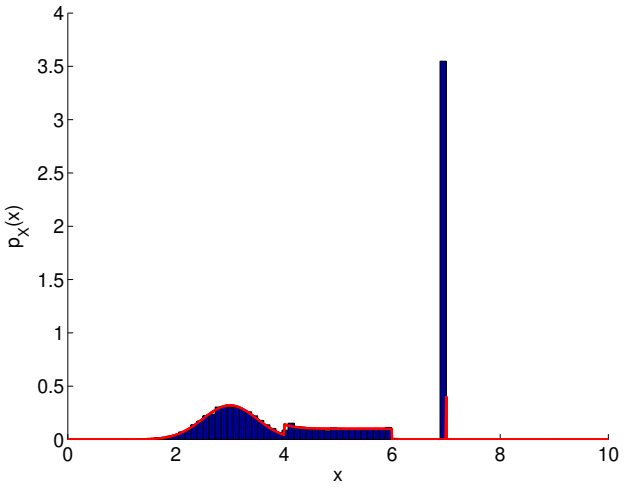


Histograma del ejemplo del rechazo





Histograma del ejemplo de la mezcla



Métodos de Monte-Carlo

¿Como podemos estimar los estadísticos a partir de las muestras?

- Aproximar la probabilidad de las N muestras: $p_X(x) = \frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)$.
- A partir de esa fórmula, podemos obtener los estadísticos directamente:
  - $E\{g(X)\} = \int_{-\infty}^{\infty} g(x)p_X(x)dx = \int_{-\infty}^{\infty} g(x)\frac{1}{N}\sum_{n=1}^{N}\delta(x - x_i)dx = = \frac{1}{N}\sum_{n=1}^{N} g(x_i)$
  - *Valor medio*: $\mu_X = E\{X\} = \frac{1}{N}\sum_{n=1}^{N} x_i$
  - *Valor cuadrático medio*: $E\{X^2\} = \frac{1}{N}\sum_{n=1}^{N} x_i^2$
  - *Varianza*: $\sigma_X^2 = E\{(X - \mu_X)^2\} = \frac{1}{N}\sum_{n=1}^{N}(x_i - \mu_x)^2$
- Los estadísticos básicos se pueden calcular con Matlab:
  - *Valor medio*: `mu=mean(samples)`
  - *Varianza*[1]: `sigma2=var(samples,1)`
  - *Desviación típica*[1] (σ_X): `sigma=std(samples,1)`

[1] El segundo parámetro tiene que tomar el valor de 1 para que se calcule la varianza dividiendo los resultados entre N.