

Señales aleatorias

Tema 6 · Parte 2: varias variables aleatorias

Jesús Chacón Sombría

Departamento de Arquitectura de Computadores y Automática
Universidad Complutense de Madrid

Grado en Ingeniería Electrónica de Comunicaciones
Curso 2026-2027

Contenido

1. Distribución conjunta
2. Correlación y covarianza
3. Vectores aleatorios y gaussiana multivariable
4. Suma de variables y teorema del límite central

Varias variables a la vez

- Muchas magnitudes aleatorias aparecen juntas: los valores de una señal en dos instantes, la entrada y la salida de un sistema, las coordenadas de un punto.
- Se describen con la distribución conjunta:

$$F_{XY}(x,y) = P(X \le x,\ Y \le y), \qquad f_{XY}(x,y) = \frac{\partial^2 F_{XY}}{\partial x\, \partial y},$$

$$P\big((X,Y) \in A\big) = \iint_A f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

  En discreto, $p_{XY}(x_i, y_j) = P(X = x_i,\ Y = y_j)$.

- Para M variables, $f_{X_1 \cdots X_M}(x_1, \ldots, x_M)$, o con notación vectorial $f_{\mathbf{X}}(\mathbf{x})$.

Marginales y condicionadas

- Marginalización: la distribución de una variable se obtiene integrando (o sumando) las demás:

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y)\, dy, \qquad p_X(x_i) = \sum_j p_{XY}(x_i, y_j).$$

- Condicionada: la distribución de Y sabiendo que $X = x$,

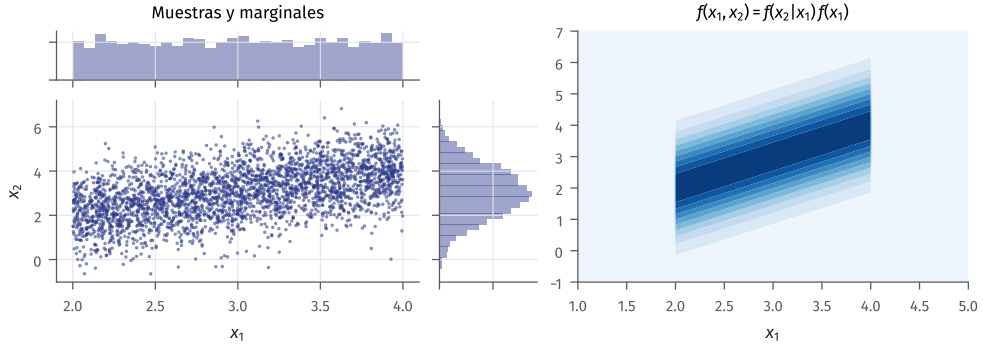
$$f_{Y|X}(y|x) = \frac{f_{XY}(x, y)}{f_X(x)}.$$

- Regla de la cadena: $f_{XY} = f_{Y|X}\, f_X = f_{X|Y}\, f_Y$. Con M variables hay $M!$ órdenes posibles: $f(x_1, \dots, x_M) = f(x_1)\, f(x_2|x_1) \cdots f(x_M|x_1, \dots, x_{M-1})$.

- Teorema de Bayes: $f_{X|Y}(x|y) = \dfrac{f_{Y|X}(y|x)\, f_X(x)}{f_Y(y)}$.

▶ Herramienta interactiva: `T6-gaussiana-bivariante`

Ejemplo: una conjunta construida por partes



$X_1 \sim U[2,4]$ y, dado $X_1 = x_1$, $X_2 \sim N(x_1, 1)$. Por la regla de la cadena, $f(x_1, x_2) = \frac{1}{2} \cdot \frac{1}{\sqrt{2\pi}} e^{-(x_2-x_1)^2/2}$ en $2 \leq x_1 \leq 4$. Para muestrear se sigue el mismo orden: primero x_1, después x_2 con ese x_1.

Independencia

Variables independientes

X e Y son independientes si $f_{XY}(x,y) = f_X(x)\, f_Y(y)$ para todo (x,y), es decir, si $f_{Y|X}(y|x) = f_Y(y)$: saber X no dice nada de Y.

- M variables son independientes si la conjunta es el producto de las M marginales. Entonces basta muestrear cada una por separado.
- Independencia condicional: X e Y son independientes dado Z si $f_{XY|Z} = f_{X|Z}\, f_{Y|Z}$. Es la base de los modelos de Markov (parte 3).
- En el ejemplo anterior X_1 y X_2 *no* son independientes: la media de X_2 depende de X_1.

Contenido

1. Distribución conjunta
2. Correlación y covarianza
3. Vectores aleatorios y gaussiana multivariable
4. Suma de variables y teorema del límite central

Estadísticos de un par de variables

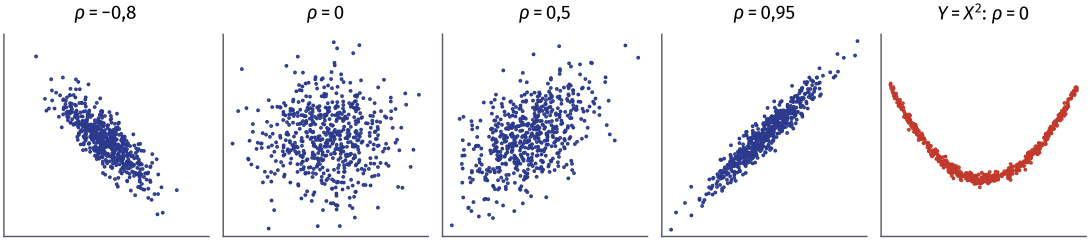
- Correlación: $R_{XY} = E\{XY\} = \iint xy\, f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y$.
- Covarianza: $C_{XY} = E\{(X-\mu_X)(Y-\mu_Y)\} = R_{XY} - \mu_X\mu_Y$. $C_{XX} = \sigma_X^2$.
- Coeficiente de correlación:

$$\rho_{XY} = \frac{C_{XY}}{\sigma_X \sigma_Y}, \qquad -1 \le \rho_{XY} \le 1.$$

  Mide la dependencia *lineal*: $|\rho| = 1$ si y solo si $Y = aX + b$; el signo es el de a.
- X e Y son incorreladas si $C_{XY} = 0$ (es decir, $E\{XY\} = \mu_X\mu_Y$), y ortogonales si $R_{XY} = 0$.
- Varianza de una suma: $\mathrm{Var}\{X+Y\} = \sigma_X^2 + \sigma_Y^2 + 2C_{XY}$.

Las transparencias antiguas usaban ϕ para la correlación y ψ para la covarianza; aquí R y C, porque ϕ queda para las señales y ψ para las wavelets (tema 5).

Incorreladas no es lo mismo que independientes



- Independientes ⇒ incorreladas: $E\{XY\} = \iint xy\, f_X f_Y = \mu_X \mu_Y$.
- Al revés no: con $X \sim U[-1, 1]$ e $Y = X^2$, $C_{XY} = E\{X^3\} - 0 = 0$, aunque Y es función de X.
- Por tanto: correladas ⇒ dependientes, pero la correlación nula no prueba la independencia. Excepción: variables conjuntamente gaussianas.

▶ Herramienta interactiva: `T6-gaussiana-bivariante`

En código: estimar media, covarianza y ρ

Python

```python
import numpy as np

rng = np.random.default_rng(5)
N = 100000
x1 = rng.uniform(2, 4, N)          # U[2,4]
x2 = x1 + rng.standard_normal(N) # N(x1,1)
X = np.c_[x1, x2]                  # N x 2
print(X.mean(axis=0))              # 3, 3
print(np.cov(X.T))       # [1/3 1/3; 1/3 4/3]
print(np.corrcoef(X.T)[0, 1])     # 0.5
```

Matlab

```matlab
N = 100000;
x1 = 2 + 2*rand(N, 1);             % U[2,4]
x2 = x1 + randn(N, 1);             % N(x1,1)
X = [x1, x2];                      % N x 2
disp(mean(X))                      % 3, 3
disp(cov(X))              % [1/3 1/3; 1/3 4/3]
c = corrcoef(X); disp(c(1, 2))    % 0.5
```

Teórico: $\mu_2 = 3$, $\sigma_2^2 = 1 + \frac{1}{3}$, $C_{12} = \mathrm{Var}\{X_1\} = \frac{1}{3}$, $\rho = 0{,}5$. *`cov` divide por N – 1; `corr` de Matlab necesita la Statistics Toolbox, `corrcoef` no.*

Contenido

1. Distribución conjunta
2. Correlación y covarianza
3. Vectores aleatorios y gaussiana multivariable
4. Suma de variables y teorema del límite central

Vector de medias y matriz de covarianza

Con $\mathbf{X} = (X_1, \dots, X_M)^T$:

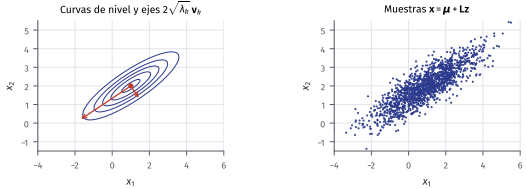
$$\mu = E\{\mathbf{X}\}, \qquad \Sigma = E\{(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T\} = \begin{bmatrix} \sigma_1^2 & C_{12} & \cdots & C_{1M} \\ C_{12} & \sigma_2^2 & \cdots & C_{2M} \\ \vdots & & \ddots & \vdots \\ C_{1M} & C_{2M} & \cdots & \sigma_M^2 \end{bmatrix}$$

- Σ es simétrica y semidefinida positiva; diagonal si las variables están incorreladas.
- Transformación lineal: si $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$, entonces $\mu_Y = \mathbf{A}\mu + \mathbf{b}$ y $\Sigma_Y = \mathbf{A}\Sigma\mathbf{A}^T$.
- Estimación con N muestras en las filas de una matriz $N \times M$: `mean(X)`, `cov(X)`, `corrcoef(X)`. En numpy, `np.cov` espera las variables en las filas.

Gaussiana multivariable

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{e^{-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)}}{\sqrt{(2\pi)^M \det \Sigma}}$$

- Queda determinada por μ y Σ.
- Curvas de nivel: elipses con ejes en los autovectores de $\Sigma = \mathbf{V}\Lambda\mathbf{V}^T$ y semiejes $\propto \sqrt{\lambda_k}$.
- Marginales, condicionadas y transformaciones lineales son gaussianas.
- Incorreladas $\Leftrightarrow$ Σ diagonal $\Leftrightarrow$ independientes.



$\mu = (1, 2)$, $\Sigma = \begin{bmatrix} 2 & 1{,}2 \\ 1{,}2 & 1 \end{bmatrix}$: $\lambda = 0{,}2$ y $2{,}8$, $\rho = 0{,}85$.

▶ Herramienta interactiva: `T6-gaussiana-bivariante`

Muestrear una gaussiana multivariable

- Se generan M gaussianas $N(0,1)$ independientes, $\mathbf{z}$, y se transforman: $\mathbf{x} = \mu + \mathbf{L}\mathbf{z}$, con $\mathbf{L}\mathbf{L}^T = \Sigma$. Por la transformación lineal, $\Sigma_X = \mathbf{L}\mathbf{I}\mathbf{L}^T = \Sigma$.
- **L**: la factorización de Cholesky (`chol`) o $\mathbf{V}\Lambda^{1/2}$ (`eig`): rotar y escalar.

Python

```python
import numpy as np

rng = np.random.default_rng(6)
mu = np.array([1.0, 2.0])
S = np.array([[2.0, 1.2],
              [1.2, 1.0]])      # covarianza
L = np.linalg.cholesky(S)        # S = L L^T
Z = rng.standard_normal((2, 100000))
X = mu[:, None] + L @ Z          # 2 x N
print(X.mean(axis=1))            # ~ mu
print(np.cov(X))                 # ~ S
lam, V = np.linalg.eigh(S)       # ejes
print(lam)                       # 0.2, 2.8
```

Matlab

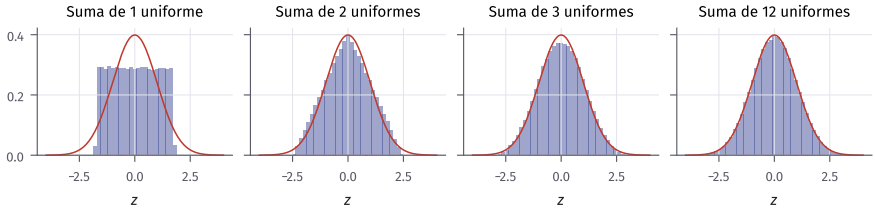
```matlab
mu = [1; 2];
S = [2.0 1.2;
     1.2 1.0];                   % covarianza
L = chol(S, 'lower');            % S = L L'
Z = randn(2, 100000);
X = mu + L*Z;                    % 2 x N
disp(mean(X, 2)')                % ~ mu
disp(cov(X'))                    % ~ S
[V, D] = eig(S);                 % ejes
disp(diag(D)')                   % 0.2, 2.8
```

▶ Herramienta interactiva: `T6-gaussiana-bivariante`

Contenido

1. Distribución conjunta
2. Correlación y covarianza
3. Vectores aleatorios y gaussiana multivariable
4. Suma de variables y teorema del límite central

Suma de variables independientes



$S = X + Y$ con X e Y independientes:

- $\mu_S = \mu_X + \mu_Y$ (siempre); $\sigma_S^2 = \sigma_X^2 + \sigma_Y^2$ (basta incorreladas).
- $f_S = f_X * f_Y$: la densidad de la suma es la convolución de las densidades. Dos $U[0,1]$ dan un triángulo en $[0,2]$.

Teorema del límite central

La suma de muchas variables independientes con varianza finita, normalizada, tiende a una gaussiana, sea cual sea su distribución.

En la figura, $Z = (S - n/2)/\sqrt{n/12}$. Por eso el ruido térmico es gaussiano.

- Herramienta interactiva: `T6-limite-central`

Conceptos importantes

- Conjunta, marginal (integrar), condicionada; cadena y Bayes.
- Independencia: la conjunta es el producto.
- R_{XY}, $C_{XY} = R_{XY} - \mu_X \mu_Y$, $\rho \in [-1, 1]$.
- Independientes $\Rightarrow$ incorreladas; no al revés, salvo gaussianas.
- μ, Σ; $\Sigma_Y = \mathbf{A}\Sigma\mathbf{A}^T$.
- Gaussiana multivariable; muestreo $\mu + \mathbf{L}\mathbf{z}$.
- Suma: medias y varianzas se suman; densidades se convolucionan; TCL.

Apuntes del Tema 6, sección 2 · Hoja de ejercicios, ejercicios 6–10.