

Señales aleatorias

Tema 6 · Parte 4: análisis espectral y sistemas LTI

Jesús Chacón Sombría

Departamento de Arquitectura de Computadores y Automática
Universidad Complutense de Madrid

Grado en Ingeniería Electrónica de Comunicaciones
Curso 2026-2027

Contenido

1. Densidad espectral de potencia
2. Respuesta de un sistema LTI
3. Estimación de la DEP

El espectro de una señal aleatoria

- Una realización de una señal estacionaria no se apaga: tiene energía infinita y su DTFT no existe en sentido ordinario. Además, cada realización tendría un espectro distinto.
- Lo que sí está bien definido es su potencia media:

$$P_x = E\Big\{ \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} x^2[n] \Big\} = E\{x^2[n]\} = \phi_{xx}[0] \quad \text{(ESA)}.$$

- La autocorrelación es una «potencia generalizada» que depende de la separación l. Su transformada dice cómo se reparte la potencia en frecuencia.

Densidad espectral de potencia (DEP)

$$\Phi_{xx}(e^{j\Omega}) = \sum_{l=-\infty}^{\infty} \phi_{xx}[l]\, e^{-j\Omega l}, \qquad \phi_{xx}[l] = \frac{1}{2\pi} \int_{-\pi}^{\pi} \Phi_{xx}(e^{j\Omega})\, e^{j\Omega l}\, d\Omega.$$

Es el teorema de Wiener-Khinchin. En continuo: $\Phi_{xx}(j\omega) = \int \phi_{xx}(\tau) e^{-j\omega\tau}\, d\tau$.

Propiedades

- Potencia: con $l = 0$,
$$P_x = \phi_{xx}[0] = \frac{1}{2\pi}\int_{-\pi}^{\pi} \Phi_{xx}(e^{j\Omega})\,d\Omega.$$
La potencia en una banda $[\Omega_1, \Omega_2]$ es $\frac{1}{2\pi}\int$ sobre $\pm[\Omega_1, \Omega_2]$: por eso es una *densidad*.
- Φ_{xx} es real (porque ϕ_{xx} es par), par si x es real, y no negativa.
- Interpretación: $\Phi_{xx}(e^{j\Omega}) = \lim_{N\to\infty} \frac{1}{N} E\{|X_N(e^{j\Omega})|^2\}$, con X_N la DTFT de N muestras: el módulo al cuadrado del espectro, promediado.
- En continuo: $P_x = \frac{1}{2\pi}\int \Phi_{xx}(j\omega)\,d\omega = \int \Phi_{xx}(j2\pi f)\,df$, en W/Hz si x está en voltios sobre $1\,\Omega$.

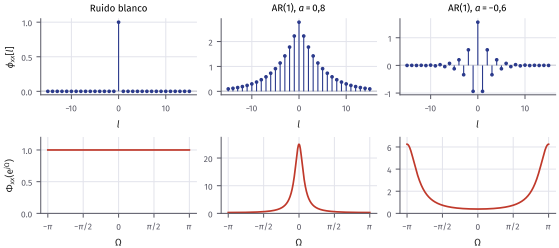
Las transparencias antiguas usaban ω también para la frecuencia discreta; aquí, como en todo el curso, Ω.

Ejemplos

- Ruido blanco: $\phi_{xx}[l] = \sigma^2\delta[l] \Rightarrow \Phi_{xx} = \sigma^2$, plana.
- AR(1): $\phi_{xx}[l] = \frac{\sigma_w^2 a^{|l|}}{1-a^2} \Rightarrow$

$$\Phi_{xx} = \frac{\sigma_w^2}{|1 - ae^{-j\Omega}|^2} = \frac{\sigma_w^2}{1 - 2a\cos\Omega + a^2}.$$

  Paso bajo si $a > 0$, paso alto si $a < 0$.
- Constante: $\phi_{xx}[l] = \mu^2 \Rightarrow \Phi_{xx} = 2\pi\mu^2\delta(\Omega)$ en $[-\pi, \pi]$.
- Sinusoide de fase aleatoria: $\frac{A^2}{2}\cos\Omega_0 l \Rightarrow \frac{\pi A^2}{2}[\delta(\Omega - \Omega_0) + \delta(\Omega + \Omega_0)]$.



Clasificación y ruido blanco continuo

- Según la forma de la DEP: blanca (plana), de banda ancha, de banda estrecha, paso bajo, paso banda. «Coloreada» es cualquiera que no sea blanca.
- Una señal con DEP no nula en todas las frecuencias tiene muestras correladas a corta distancia: la anchura de ϕ_{xx} es inversa al ancho de banda.

Ruido blanco continuo

$\phi_{xx}(\tau) = \frac{N_0}{2}\delta(\tau)$ y $\Phi_{xx} = \frac{N_0}{2}$: tendría potencia $\phi_{xx}(0) = \infty$, así que no existe físicamente. Es un modelo para ruido cuya DEP es plana en toda la banda que interesa, por ejemplo el ruido térmico de una resistencia ($N_0/2 = 2kTR\,\mathrm{V}^2/\mathrm{Hz}$). Tras un paso bajo ideal de ancho B Hz, la potencia es $N_0 B$.

Al muestrear a $f_s = 2B$ ruido blanco limitado a B Hz se obtiene ruido blanco discreto de varianza $N_0 B$.

Densidad espectral cruzada

$$\Phi_{xy}(e^{j\Omega}) = \sum_{l=-\infty}^{\infty} \phi_{xy}[l]\, e^{-j\Omega l}$$

- En general es compleja: ϕ_{xy} no es par. Como $\phi_{yx}[l] = \phi_{xy}[-l]$, $\Phi_{yx} = \Phi_{xy}^*$ para señales reales.
- Su módulo dice en qué frecuencias x e y tienen potencia común; su fase, el desfase entre ellas.
- Coherencia: $C_{xy} = \dfrac{|\Phi_{xy}|^2}{\Phi_{xx}\Phi_{yy}} \in [0, 1]$; vale 1 en las frecuencias donde y es una versión filtrada de x sin ruido.

Contenido

1 Densidad espectral de potencia

2 Respuesta de un sistema LTI

3 Estimación de la DEP

Señal aleatoria a través de un sistema LTI

$y[n] = \sum_k h[k]\, x[n-k]$, con h real y estable y x ESA. La salida también es ESA y:

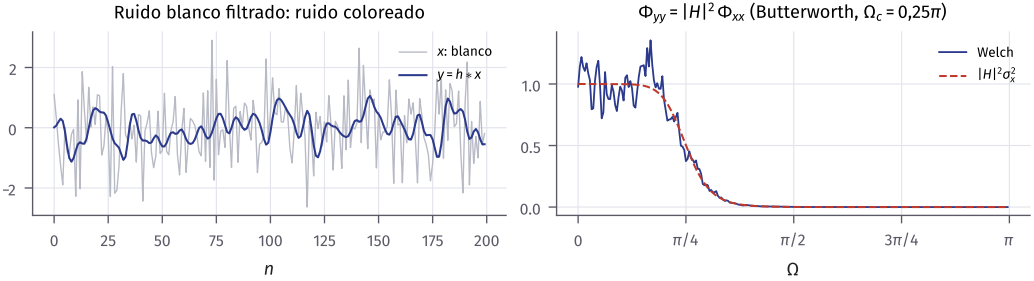
- Media: $\mu_y = E\{\sum_k h[k]x[n-k]\} = \mu_x \sum_k h[k] = H(e^{j0})\,\mu_x$.
- Correlación cruzada: $\phi_{yx}[l] = E\{y[n+l]x[n]\} = \sum_k h[k]\,\phi_{xx}[l-k] = (h * \phi_{xx})[l]$
- Autocorrelación: $\phi_{yy}[l] = \sum_k \sum_r h[k]h[r]\,\phi_{xx}[l-k+r] = (h * \tilde{h} * \phi_{xx})[l], \quad \tilde{h}[n] = h[-n]$.

En frecuencia

$$\Phi_{yx}(e^{j\Omega}) = H(e^{j\Omega})\,\Phi_{xx}(e^{j\Omega}), \qquad \Phi_{yy}(e^{j\Omega}) = |H(e^{j\Omega})|^2\,\Phi_{xx}(e^{j\Omega}).$$

Las convoluciones se convierten en productos y $H(e^{-j\Omega}) = H^*(e^{j\Omega})$. *Potencia de salida:* $\frac{1}{2\pi}\int |H|^2 \Phi_{xx}\, d\Omega$; *con entrada blanca,* $\sigma_x^2 \sum_k h^2[k]$.

Ruido coloreado



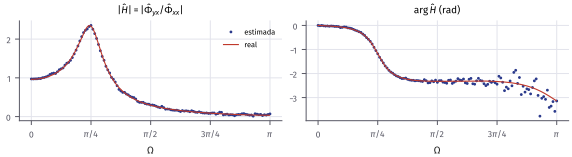
- Filtrar ruido blanco da ruido con la DEP que se quiera: $\Phi_{yy} = \sigma_x^2 |H|^2$. Así se simulan perturbaciones realistas, y el AR(1) es ruido blanco tras $1/(1 - az^{-1})$.
- Al revés, un filtro blanqueador $1/H$ convierte ruido coloreado en blanco.
- El filtro solo cambia la potencia de cada frecuencia; no puede crear frecuencias que no estaban.

Identificación de sistemas

- Se excita un sistema desconocido con ruido de DEP conocida y se miden entrada y salida:

$$\hat{H}(e^{j\Omega}) = \frac{\Phi_{yx}(e^{j\Omega})}{\Phi_{xx}(e^{j\Omega})}$$

  da módulo y fase.
- $|H|^2 = \Phi_{yy}/\Phi_{xx}$ da solo el módulo, y el ruido de medida a la salida lo sesga; en Φ_{yx} ese ruido, incorrelado con x, desaparece al promediar.
- Con entrada blanca, $\phi_{yx}[l] = \sigma_x^2\, h[l]$: la correlación cruzada *es* la respuesta al impulso.



$H(z) = \frac{0{,}2+0{,}3z^{-1}}{1-1{,}2z^{-1}+0{,}72z^{-2}}$, ruido de medida de $\sigma = 0{,}3$. Donde $|H|$ es pequeño, la fase se estima peor.

En código: identificar un sistema

Python

```python
import numpy as np
from scipy import signal

rng = np.random.default_rng(11)
b, a = [0.2, 0.3], [1, -1.2, 0.72]
x = rng.standard_normal(50000)   # blanco
y = signal.lfilter(b, a, x)      # sistema
y += 0.3*rng.standard_normal(x.size)
f, Pxx = signal.welch(x, nperseg=256,
                      detrend=False)
_, Pxy = signal.csd(x, y, nperseg=256,
                    detrend=False)
H = Pxy/Pxx                  # Phi_yx/Phi_xx
_, Hr = signal.freqz(b, a, 2*np.pi*f)
k = [0, 32, 64]              # W=0,pi/4,pi/2
print(abs(H[k]), abs(Hr[k]))
```

Matlab

```matlab
b = [0.2 0.3]; a = [1 -1.2 0.72];
x = randn(1, 50000);              % blanco
y = filter(b, a, x);              % sistema
y = y + 0.3*randn(size(x));
w = hanning(256);
[H, f] = tfestimate(x, y, w, [], 256, 1);
Hr = freqz(b, a, 2*pi*f);
k = [1 33 65];                % W=0,pi/4,pi/2
disp([abs(H(k)), abs(Hr(k))])
```

`scipy.signal.csd(x, y)` calcula X^*Y, que es Φ_{yx} con nuestro convenio.

Contenido

1. Densidad espectral de potencia
2. Respuesta de un sistema LTI
3. Estimación de la DEP

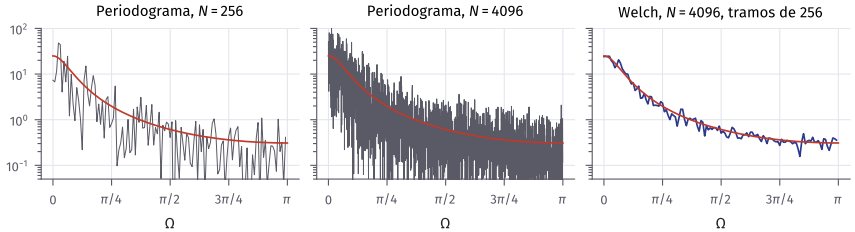
Periodograma

- Con N muestras, lo inmediato es el periodograma:

$$I_N(e^{j\Omega}) = \frac{1}{N}\left|\sum_{n=0}^{N-1} x[n]\, e^{-j\Omega n}\right|^2,$$

que es la DTFT de la autocorrelación estimada con el estimador sesgado. Se calcula con la FFT.

- Es asintóticamente insesgado (su media tiende a Φ_{xx}), pero su varianza no disminuye con N: es del orden de Φ_{xx}^2. Más muestras dan más frecuencias, igual de ruidosas.



Método de Welch

- Se divide la señal en K tramos de L muestras (con solapamiento, típicamente del 50 %), se enventana cada uno, se calcula su periodograma y se promedian.
- La varianza baja aproximadamente en un factor K (algo menos con solapamiento); la resolución en frecuencia empeora a la de una ventana de L muestras. Es el compromiso de la STFT del tema 5.
- Bartlett: lo mismo sin ventana ni solapamiento.
- Matlab: `pwelch`, `cpsd`, `tfestimate`, `mscohere`. Python: `scipy.signal.welch`, `csd`, `coherence`.

Escalas

Por defecto devuelven la DEP *unilateral* (doble en $0 < f < f_s/2$) y por unidad de frecuencia (Hz, o rad/muestra si no se da f_s). Con la opción bilateral y $f_s = 1$ se obtiene $\Phi_{xx}(e^{j2\pi f})$.

En código: DEP de un AR(1) con Welch

Python

```python
import numpy as np
from scipy import signal

rng = np.random.default_rng(10)
a, N = 0.8, 2**14
x = signal.lfilter([1], [1, -a],
                   rng.standard_normal(N))
f, P = signal.welch(x, fs=1, nperseg=256,
                    return_onesided=False,
                    detrend=False)  # Phi
W = 2*np.pi*f                    # f en ciclos
teo = 1/abs(1 - a*np.exp(-1j*W))**2
print(P[0], teo[0])              # ~ 25
print(P[64], teo[64])         # W=pi/2: 0.61
print(np.mean(P), x.var())       # potencia
```

Matlab

```matlab
a = 0.8; N = 2^14;
x = filter(1, [1 -a], randn(1, N));
w = hanning(256);
[P, f] = pwelch(x, w, [], 256, 1, ...
                'twosided');     % Phi
W = 2*pi*f;                    % f en ciclos
teo = 1./abs(1 - a*exp(-1j*W)).^2;
disp([P(1), teo(1)])             % ~ 25
disp([P(65), teo(65)])        % W=pi/2: 0.61
disp([mean(P), var(x)])          % potencia
```

Teórico, con $a = 0{,}8$: $\Phi_{xx}(e^{j0}) = 1/(1-a)^2 = 25$, $\Phi_{xx}(e^{j\pi/2}) = 1/(1+a^2) = 0{,}61$ *y potencia* $1/(1-a^2) = 2{,}78$.

El valor en 0 se estima peor porque la ventana ensancha el pico.

Aplicaciones

- Medir el ruido de un sistema y su relación señal a ruido por bandas.
- Detectar tonos débiles en ruido: tras promediar, un tono destaca sobre un fondo cuya varianza se ha reducido.
- Identificar sistemas y medir su respuesta en frecuencia en funcionamiento, sin desconectarlos.
- Filtro de Wiener: para separar una señal s de un ruido aditivo v incorrelado, el filtro lineal óptimo es

$$H(e^{j\Omega}) = \frac{\Phi_{ss}(e^{j\Omega})}{\Phi_{ss}(e^{j\Omega}) + \Phi_{vv}(e^{j\Omega})} :$$

deja pasar las frecuencias donde domina la señal y atenúa donde domina el ruido.

Conceptos importantes

- DEP: $\Phi_{xx} = \mathrm{DTFT}\{\phi_{xx}\}$; real, par, ≥ 0.
- $P_x = \phi_{xx}[0] = \frac{1}{2\pi}\int \Phi_{xx}\, d\Omega$.
- Blanco: plana. AR(1): $\sigma_w^2/|1 - ae^{-j\Omega}|^2$.
- DEP cruzada Φ_{xy}, compleja; coherencia.
- LTI: $\mu_y = H(e^{j0})\mu_x$, $\Phi_{yx} = H\Phi_{xx}$, $\Phi_{yy} = |H|^2\Phi_{xx}$.
- Identificación: $\hat{H} = \Phi_{yx}/\Phi_{xx}$.
- Periodograma: varianza que no baja; Welch promedia tramos.

Apuntes del Tema 6, sección 4 · Hoja de ejercicios, ejercicios 15–18.