

Grado en Ingeniería Electrónica de Comunicaciones
Procesamiento de Señales · Curso 2026-2027

Apuntes

Tema 6. Señales aleatorias

Jesús Chacón Sombría

Cómo usar estos apuntes

Estos apuntes desarrollan el contenido de las cuatro presentaciones del tema: la sección 1 corresponde a la parte 1 (variables aleatorias, muestreo y análisis), la sección 2 a la parte 2 (varias variables), la sección 3 a la parte 3 (señales aleatorias en el dominio del tiempo) y la sección 4 a la parte 4 (análisis espectral y sistemas LTI). Los ejemplos de código están en `teoría/T6/codigo/`, en Python (`numpy` y `scipy`) y en Matlab, y se pueden ejecutar tal cual; como usan números aleatorios, los resultados cambian ligeramente de una ejecución a otra y entre los dos lenguajes. Al final de cada sección se indican los ejercicios de la hoja del tema que la practican.

Índice general

1 Variables aleatorias 2
- 1.1 Señales deterministas y aleatorias . . . 2
- 1.2 Variable aleatoria . . . 2
- 1.3 Esperanza, media y varianza . . . 3
- 1.4 Distribuciones habituales . . . 4
- 1.5 Muestreo de variables aleatorias . . . 4
- 1.6 Análisis de muestras . . . 8

2 Varias variables aleatorias 9
- 2.1 Distribución conjunta . . . 9
- 2.2 Independencia . . . 10
- 2.3 Correlación y covarianza . . . 11
- 2.4 Vectores aleatorios y gaussiana multivariable . . . 12
- 2.5 Suma de variables y teorema central del límite . . . 14

3 Señales aleatorias 14
- 3.1 Definición y descripción . . . 14
- 3.2 Estacionariedad . . . 16
- 3.3 Ergodicidad . . . 17
- 3.4 Autocorrelación . . . 18
- 3.5 Correlación cruzada . . . 20

4 Análisis espectral de señales aleatorias 21
- 4.1 Densidad espectral de potencia . . . 21
- 4.2 Respuesta de un sistema LTI . . . 23
- 4.3 Estimación de la densidad espectral . . . 25
- 4.4 Aplicaciones . . . 27

Bibliografía 27

1 Variables aleatorias

1.1 Señales deterministas y aleatorias

Hasta ahora todas las señales han sido *deterministas*: su valor en cada instante se conoce exactamente, porque viene dado por una fórmula, una tabla o una grabación. Muchas señales de interés no son así. El ruido térmico de un amplificador, la voz de un locutor, los bits de un mensaje o el error de un sensor no se pueden predecir: si se repite la observación, la señal sale distinta (figura 1). Se llaman señales *aleatorias* o *estocásticas*.

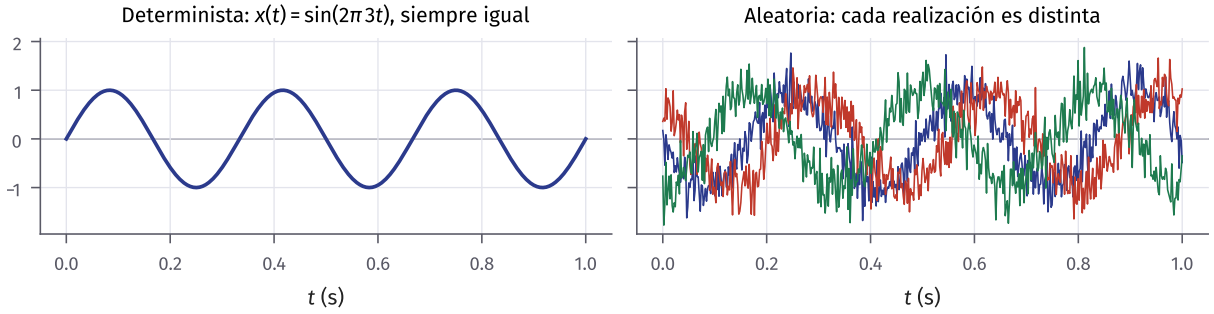


Figura 1. Una señal determinista y tres realizaciones de una señal aleatoria.

Una señal aleatoria no se describe valor a valor, sino estadísticamente: qué valores son más probables, cuánto se alejan de su media, cómo se parecen los valores próximos en el tiempo, cómo se reparte su potencia en frecuencia. Para ello se necesita el lenguaje de la probabilidad, que se repasa en esta sección y en la siguiente. Las dos últimas lo aplican a las señales.

Erratas de versiones anteriores

La introducción antigua tenía varias faltas: «cuantitiva», «guassiana», «area», «Una análisis», «sen» por «seno», y preguntas sin signo de apertura ni tilde («Que», «Como podemos»).

1.2 Variable aleatoria

Definición 1.1: Variable aleatoria

Una *variable aleatoria* X es una función que asigna un número real a cada resultado de un experimento aleatorio. Antes de realizar el experimento solo se sabe con qué probabilidad tomará cada valor; el valor obtenido, x, es una *realización* o *muestra* de X.

Se usan mayúsculas para la variable y minúsculas para sus valores. Una variable es *discreta* si toma valores aislados $x_1, x_2, \ldots$ (la cara de un dado, el número de errores en un paquete) y *continua* si toma valores en un intervalo (la tensión de ruido en un instante).

Una variable discreta se describe con su *función de probabilidad*

$$p_X(x_i) = P(X = x_i), \qquad p_X(x_i) \geq 0, \qquad \sum_i p_X(x_i) = 1.$$

Para una continua, la probabilidad de un valor concreto es nula, y se usa la *función de densidad* $f_X(x) \geq 0$, que da la probabilidad de un intervalo como un área:

$$P(a < X \leq b) = \int_a^b f_X(x)\,\mathrm{d}x, \qquad \int_{-\infty}^{\infty} f_X(x)\,\mathrm{d}x = 1.$$

$f_X(x)\,\mathrm{d}x$ es la probabilidad de que X caiga en un intervalo de anchura $\mathrm{d}x$ alrededor de x. La densidad no es una probabilidad y puede valer más que 1: la de $\mathcal{U}[0;0{,}5]$ vale 2.

Las dos descripciones se unifican con la *función de distribución*

$$F_X(x) = P(X \le x),$$

que es no decreciente, va de $F_X(-\infty) = 0$ a $F_X(\infty) = 1$ y cumple $P(a < X \le b) = F_X(b) - F_X(a)$. Para una variable continua, $F_X(x) = \int_{-\infty}^{x} f_X(u)\,\mathrm{d}u$ y $f_X = \mathrm{d}F_X/\,\mathrm{d}x$; para una discreta, F_X es una escalera con un salto de altura $p_X(x_i)$ en cada x_i (figura 2).

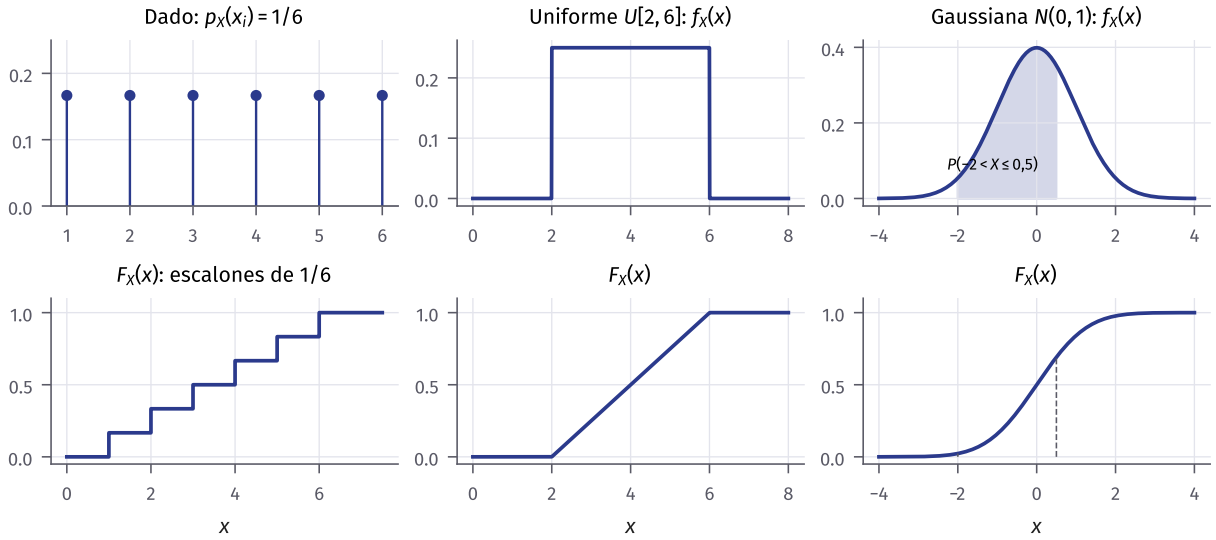


Figura 2. Función de probabilidad, de densidad y de distribución de un dado, de una uniforme y de una gaussiana.

1.3 Esperanza, media y varianza

Definición 1.2: Esperanza

La *esperanza* o valor esperado de $g(X)$ es

$$E\{g(X)\} = \sum_i g(x_i)\,p_X(x_i) \qquad \text{o} \qquad E\{g(X)\} = \int_{-\infty}^{\infty} g(x)\,f_X(x)\,\mathrm{d}x.$$

Es el promedio de $g(X)$ ponderado por la probabilidad. Los casos más usados son:

- la *media* $\mu_X = E\{X\}$, el centro de gravedad de la distribución;
- el *valor cuadrático medio* $E\{X^2\}$, que, si X es una tensión aplicada a una resistencia de 1 Ω, es la potencia media;
- la *varianza* $\sigma_X^2 = E\{(X-\mu_X)^2\}$, que mide la dispersión alrededor de la media. Desarrollando el cuadrado, $\sigma_X^2 = E\{X^2\} - \mu_X^2$. Su raíz σ_X es la *desviación típica*, con las mismas unidades que X.

La esperanza es lineal: $E\{aX+b\} = a\mu_X + b$, y de ahí $\mathrm{Var}\{aX+b\} = a^2\sigma_X^2$. Por ejemplo, para un dado equilibrado $\mu_X = 3{,}5$, $E\{X^2\} = \frac{1+4+\cdots+36}{6} = \frac{91}{6}$ y $\sigma_X^2 = \frac{91}{6} - \frac{49}{4} = \frac{35}{12}$.

1.4 Distribuciones habituales

Uniforme. $X \sim \mathcal{U}[a,b]$ si su densidad es constante en $[a,b]$:

$$f_X(x) = \begin{cases} \dfrac{1}{b-a}, & a \le x \le b, \\ 0, & \text{en otro caso,} \end{cases} \qquad \mu_X = \frac{a+b}{2}, \quad E\{X^2\} = \frac{a^2+ab+b^2}{3}, \quad \sigma_X^2 = \frac{(b-a)^2}{12}.$$

Modela el error de cuantificación (Tema 2), la fase de una portadora desconocida y los números aleatorios que genera un ordenador.

Gaussiana o normal. $X \sim \mathcal{N}(\mu, \sigma^2)$ si

$$f_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \, \mathrm{e}^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Su media es μ y su varianza σ^2. La variable $Z = (X-\mu)/\sigma$ es $\mathcal{N}(0,1)$, cuya función de distribución $\Phi(z)$ está tabulada; así $P(X \le x) = \Phi\big((x-\mu)/\sigma\big)$. A una, dos y tres desviaciones típicas de la media queda el 68,3, el 95,4 y el 99,7 % de la probabilidad (figura 3). Una transformación lineal de una gaussiana es gaussiana: $aX+b \sim \mathcal{N}(a\mu+b,\, a^2\sigma^2)$. Su importancia se debe al teorema central del límite (sección 2.5): el ruido que resulta de sumar muchas contribuciones pequeñas e independientes, como el ruido térmico, es gaussiano.

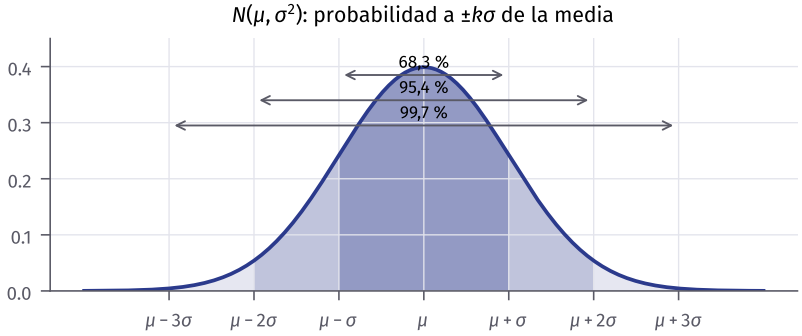


Figura 3. Densidad gaussiana y probabilidad a $\pm\sigma$, $\pm 2\sigma$ y $\pm 3\sigma$ de la media.

Exponencial. $f_X(x) = \lambda \mathrm{e}^{-\lambda x}$ para $x \ge 0$, con $\mu_X = 1/\lambda$ y $\sigma_X^2 = 1/\lambda^2$. Modela tiempos de espera entre sucesos independientes.

Ejercicios 1–3.

1.5 Muestreo de variables aleatorias

Los generadores de números pseudoaleatorios de Matlab (`rand`) y de Python (`rng.random`, con `rng = np.random.default_rng()`) producen muestras de $\mathcal{U}[0,1)$ que se comportan como independientes. A partir de ellas se pueden obtener muestras de cualquier distribución. Esto permite *simular*: repetir muchas veces un experimento con entradas aleatorias y estimar a partir de los resultados lo que sería difícil de calcular. Es el *método de Monte Carlo*. Fijando la semilla del generador (`rng(0)` en Matlab, `default_rng(0)` en Python) los resultados son reproducibles.

Método de la ruleta. Para una variable discreta se reparte $[0,1)$ en tramos consecutivos de longitudes $p_X(x_1), p_X(x_2), \ldots$, como los sectores de una ruleta, se genera $u \sim \mathcal{U}[0,1)$ y se devuelve el valor cuyo tramo contiene a u:

$$x = x_i \qquad \text{si} \qquad F_X(x_{i-1}) \le u < F_X(x_i).$$

Como el tramo i mide $p_X(x_i)$, el valor x_i sale con esa probabilidad.

En código

Dado cargado con $p = (0{,}1;\ 0{,}1;\ 0{,}1;\ 0{,}1;\ 0{,}1;\ 0{,}5)$. Las frecuencias relativas se acercan a p y la media a 4,5.

Python

```python
import numpy as np

rng = np.random.default_rng(1)
p = np.array([.1, .1, .1, .1, .1, .5])
F = np.cumsum(p)                  # 0.1 ... 1
u = rng.random(60000)
x = np.searchsorted(F, u, 'right') + 1
frec = np.bincount(x, minlength=7)[1:]
print(frec/u.size)                # ~ p
print(x.mean(), np.sum(np.arange(1, 7)*p))
```

Matlab

```matlab
p = [.1 .1 .1 .1 .1 .5];          % dado
F = cumsum(p);                    % 0.1 ... 1
u = rand(1, 60000);
x = zeros(size(u));
for i = 1:numel(u)
  x(i) = find(u(i) < F, 1);  % 1er F > u
end
frec = accumarray(x', 1)'/numel(u);
disp(frec)                        % ~ p
disp([mean(x), sum((1:6).*p)])
```

Inversa de la función de distribución. Si $U \sim \mathcal{U}[0,1]$ y F_X es continua y estrictamente creciente, la variable $X = F_X^{-1}(U)$ tiene función de distribución F_X, porque

$$P(X \le x) = P\big(F_X^{-1}(U) \le x\big) = P\big(U \le F_X(x)\big) = F_X(x).$$

Para la exponencial, despejando $u = 1 - \mathrm{e}^{-\lambda x}$ se obtiene $x = -\frac{1}{\lambda}\ln(1-u)$ (figura 4). El método de la ruleta es la versión discreta de este. El resultado también funciona al revés: si X tiene distribución continua F_X, la variable $F_X(X)$ es uniforme en $[0,1]$. Es la base de la ecualización del histograma del Tema 5.

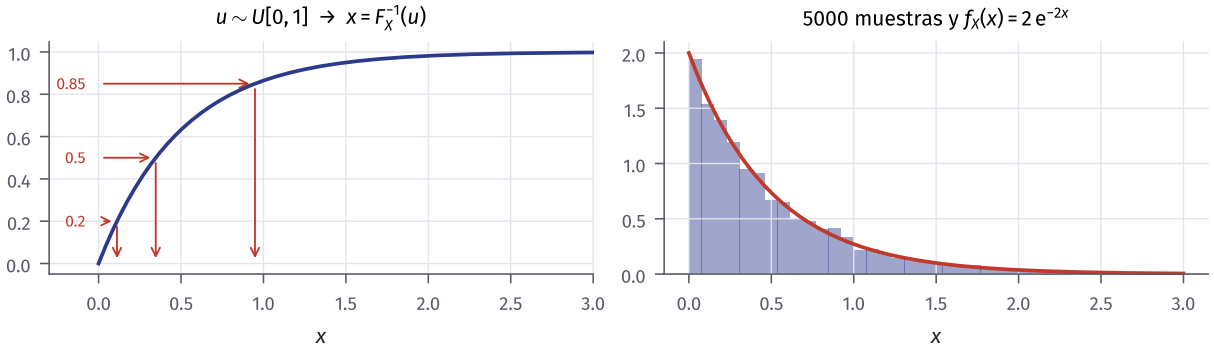


Figura 4. Método de la inversa para la exponencial de $\lambda = 2$: tres valores de u y su x, y el histograma de 5000 muestras.

En código

Muestras exponenciales con $\lambda = 2$: la media se acerca a $1/\lambda = 0{,}5$, la varianza a $1/\lambda^2 = 0{,}25$ y la fracción de muestras mayores que 1 a $\mathrm{e}^{-2} = 0{,}135$.

Python

```python
import numpy as np

rng = np.random.default_rng(0)
lam, N = 2.0, 100000
u = rng.random(N)                # U[0,1)
x = -np.log(1 - u)/lam           # F^-1(u)
print(x.mean(), 1/lam)           # media
print(x.var(ddof=1), 1/lam**2)   # varianza
print(np.mean(x > 1), np.exp(-lam))
```

Matlab

```matlab
lam = 2; N = 100000;
u = rand(1, N);                  % U[0,1)
x = -log(1 - u)/lam;             % F^-1(u)
disp([mean(x), 1/lam])           % media
disp([var(x), 1/lam^2])          % varianza
disp([mean(x > 1), exp(-lam)])
```

Box-Muller. La función de distribución de la gaussiana no tiene inversa explícita. Pero un par (Z_1, Z_2) de gaussianas $\mathcal{N}(0,1)$ independientes, escrito en coordenadas polares, tiene un ángulo Θ uniforme en $[0, 2\pi)$ y un radio R independiente con $F_R(r) = 1 - \mathrm{e}^{-r^2/2}$ (una distribución de Rayleigh), que sí se puede invertir. Por tanto, con $u_1, u_2 \sim \mathcal{U}[0,1)$ independientes,

$$r = \sqrt{-2\ln(1-u_1)}, \quad \theta = 2\pi u_2, \qquad z_1 = r\cos\theta, \quad z_2 = r\sin\theta$$

son dos muestras $\mathcal{N}(0,1)$ independientes, y $x = \mu + \sigma z$ es $\mathcal{N}(\mu, \sigma^2)$. En la práctica se usan `randn` (Matlab) y `rng.standard_normal` (Python), que emplean métodos más rápidos.

En código

Box-Muller: las dos salidas tienen media 0, desviación típica 1 y están incorreladas; el 68,3 % de las muestras cae a menos de una desviación típica.

Python

```python
import numpy as np

rng = np.random.default_rng(2)
N = 50000
u1, u2 = rng.random(N), rng.random(N)
r = np.sqrt(-2*np.log(1 - u1))   # radio
th = 2*np.pi*u2                  # ángulo
z1, z2 = r*np.cos(th), r*np.sin(th)
x = 5 + 2*z1                     # N(5, 4)
print(z1.mean(), z1.std(), z2.std())
print(np.corrcoef(z1, z2)[0, 1]) # ~ 0
print(x.mean(), x.var())         # ~ 5, 4
print(np.mean(abs(z1) < 1))      # ~ 0.683
```

Matlab

```matlab
N = 50000;
u1 = rand(1, N); u2 = rand(1, N);
r = sqrt(-2*log(1 - u1));        % radio
th = 2*pi*u2;                    % ángulo
z1 = r.*cos(th); z2 = r.*sin(th);
x = 5 + 2*z1;                    % N(5, 4)
disp([mean(z1), std(z1), std(z2)])
c = corrcoef(z1, z2); disp(c(1, 2))  % ~ 0
disp([mean(x), var(x)])          % ~ 5, 4
disp(mean(abs(z1) < 1))          % ~ 0.683
```

Aceptación y rechazo. Cuando F_X no se puede invertir, se busca una densidad $q(x)$ fácil de muestrear y una constante M tales que $Mq(x) \geq f(x)$ para todo x. Se genera un candidato $x \sim q$ y un $u \sim \mathcal{U}[0,1)$, y se *acepta* x si $u\,Mq(x) \leq f(x)$; si no, se descarta. Los puntos $(x, uMq(x))$ se reparten uniformemente bajo la curva Mq, y los aceptados, uniformemente bajo f, así que sus abscisas siguen la densidad f (figura 5). La fracción aceptada es el cociente de áreas, $1/M$: conviene que Mq se ajuste a f.

En código

Aceptación y rechazo para $f(x) = 6x(1-x)$: se acepta un 67 % de los candidatos y las muestras tienen media 0,5 y varianza 0,05, las de f.

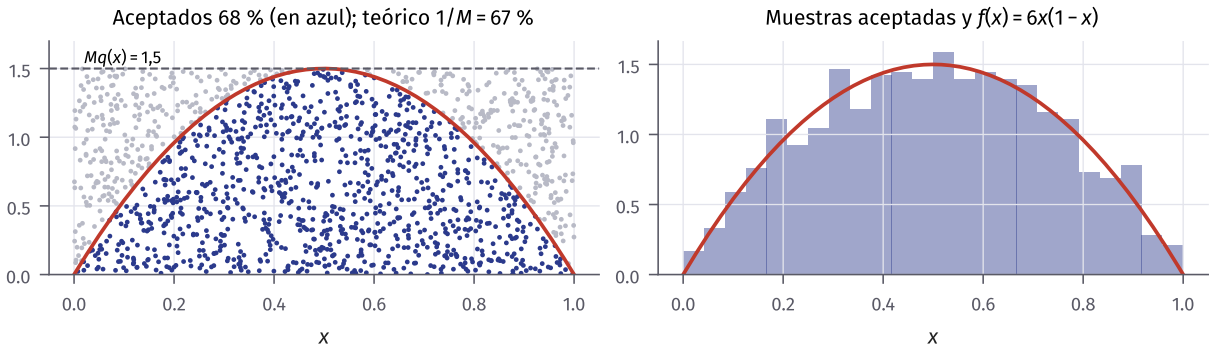


Figura 5. Aceptación y rechazo para $f(x) = 6x(1-x)$ en $[0,1]$ con q uniforme y $M = 1{,}5$.

Python

```python
import numpy as np

rng = np.random.default_rng(3)
f = lambda x: 6*x*(1 - x)        # objetivo
M = 1.5                  # f <= M*q, q=U[0,1]
N = 100000
x = rng.random(N)          # candidatos de q
u = rng.random(N)
acept = u*M <= f(x)
xs = x[acept]
print(acept.mean(), 1/M)         # ~ 0.667
print(xs.mean(), xs.var())       # 0.5, 0.05
```

Matlab

```matlab
f = @(x) 6*x.*(1 - x);           % objetivo
M = 1.5;                % f <= M*q, q=U[0,1]
N = 100000;
x = rand(1, N);            % candidatos de q
u = rand(1, N);
acept = u*M <= f(x);
xs = x(acept);
disp([mean(acept), 1/M])         % ~ 0.667
disp([mean(xs), var(xs)])        % 0.5, 0.05
```

Mezclas. Una *mezcla* es una combinación convexa de densidades,

$$f_X(x) = \sum_{k=1}^{K} \pi_k \, f_k(x), \qquad \pi_k \geq 0, \qquad \sum_k \pi_k = 1,$$

que modela poblaciones formadas por varios grupos. Se muestrea en dos pasos: se elige la componente k con probabilidad π_k (por el método de la ruleta) y se genera una muestra de f_k (figura 6).

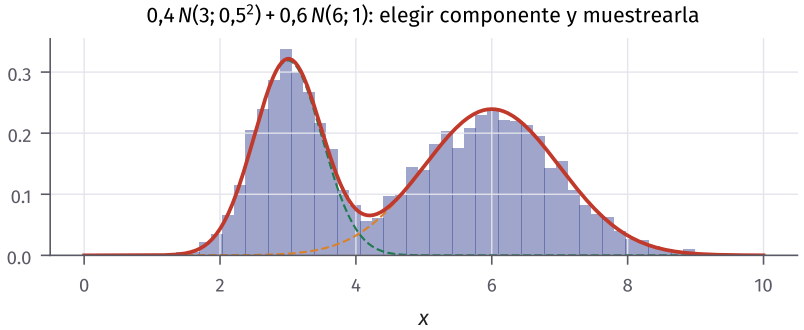


Figura 6. Histograma de 5000 muestras de una mezcla de dos gaussianas.

Erratas de versiones anteriores

En la ruleta la condición se escribía con desigualdades estrictas en los dos extremos, de modo que un u igual a un $F_X(x_i)$ no tenía valor asignado. La condición de aceptación y rechazo se escribía $Mq(x) - p(x) > 0$; basta $Mq(x) \geq f(x)$. La frase de Box-Muller («Se genera un par…») quedaba sin

terminar, y la mezcla del ejemplo, también: «$p_X(x) = 0{,}4\mathcal{N}(x, 3, 0{,}5)+$».

1.6 Análisis de muestras

Histograma. Dadas N muestras, se divide el eje en intervalos de anchura Δ y se cuenta cuántas, n_j, caen en cada uno. La altura

$$\hat{f}_X(x) = \frac{n_j}{N\Delta} \qquad \text{para } x \text{ en el intervalo } j$$

estima la densidad, porque n_j/N estima la probabilidad del intervalo, que es aproximadamente $f_X(x)\Delta$. Con esta normalización el área total es 1 y el histograma se puede comparar con la densidad (figura 7). Intervalos estrechos dan más detalle pero más ruido, porque cada uno recibe menos muestras. En Matlab, `histogram(x, 'Normalization', 'pdf')`; en Python, `plt.hist(x, density=True)`.

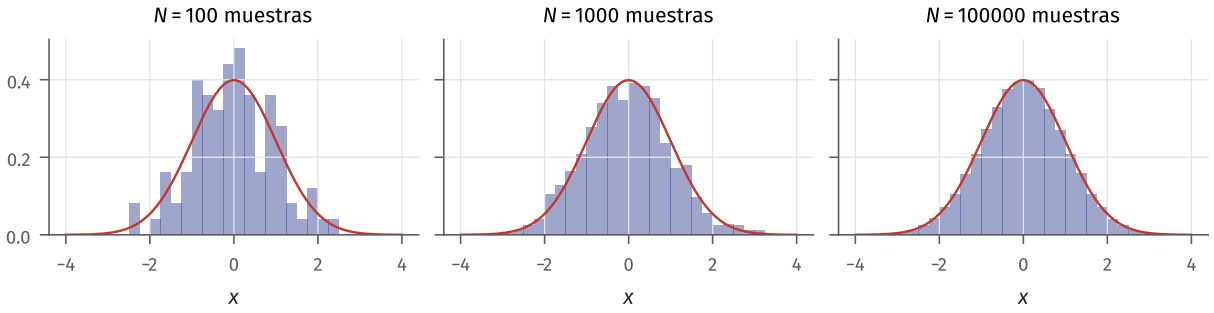


Figura 7. Histogramas normalizados de muestras $\mathcal{N}(0, 1)$ y la densidad teórica.

Estimadores. Con N muestras independientes $x_1, \ldots, x_N$ de X, la media y la varianza se estiman con

$$\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} x_i, \qquad \hat{\sigma}^2 = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \hat{\mu})^2.$$

Un estimador es una variable aleatoria: con otras muestras sale otro valor. $\hat{\mu}$ es *insesgado*, $E\{\hat{\mu}\} = \mu$, y su varianza es σ^2/N; su desviación típica, el error típico de la estimación, decrece como $1/\sqrt{N}$. Para la varianza se divide por $N-1$ porque las desviaciones se miden respecto a $\hat{\mu}$, que está más cerca de las muestras que la media verdadera; dividiendo por N el estimador se queda corto en media en un factor $(N-1)/N$. `var` de Matlab y `np.var(x, ddof=1)` dividen por $N-1$; `np.var(x)` y `var(x, 1)`, por N.

Monte Carlo. De la misma forma, cualquier esperanza se estima con la media de las muestras:

$$E\{g(X)\} = \int g(x)\, f_X(x)\, \mathrm{d}x \;\approx\; \frac{1}{N}\sum_{i=1}^{N} g(x_i),$$

con un error típico de $\sigma_g/\sqrt{N}$. Así se calculan integrales sin solución cerrada, probabilidades (con g una función indicadora) y el comportamiento de sistemas complejos con entradas aleatorias. La figura 8 estima π como cuatro veces la fracción de puntos uniformes del cuadrado unidad que caen dentro del cuarto de círculo: para ganar una cifra decimal hace falta cien veces más muestras.

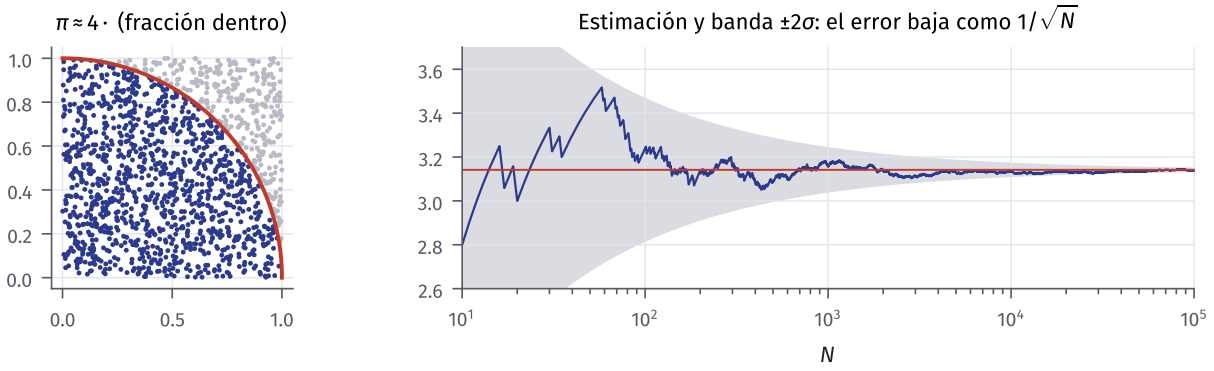


Figura 8. Estimación de π por Monte Carlo y banda de ± 2 errores típicos.

En código

$E\{\cos X\}$ con $X \sim \mathcal{N}(0,1)$ vale $\mathrm{e}^{-1/2} = 0{,}6065$. El error típico estimado baja diez veces al multiplicar N por cien.

Python

```python
import numpy as np

rng = np.random.default_rng(4)
for N in (100, 10000, 1000000):
    x = rng.standard_normal(N)  # X ~ N(0,1)
    g = np.cos(x)               # E{cos X}?
    est = g.mean()
    err = g.std(ddof=1)/np.sqrt(N)
    print(N, est, err)
print(np.exp(-0.5))             # exacto
```

Matlab

```matlab
for N = [100 10000 1000000]
  x = randn(1, N);              % X ~ N(0,1)
  g = cos(x);                   % E{cos X}?
  est = mean(g);
  err = std(g)/sqrt(N);
  disp([N, est, err])
end
disp(exp(-0.5))                 % exacto
```

Erratas de versiones anteriores

La suma de Monte Carlo antigua usaba el índice n y escribía x_i dentro, y el estimador de la varianza dividía por N sin advertir que es sesgado.

Ejercicios 4–5.

2 Varias variables aleatorias

2.1 Distribución conjunta

Muchas magnitudes aleatorias aparecen juntas: el valor de una señal en dos instantes, la entrada y la salida de un sistema, las dos coordenadas de un punto. Para describirlas no basta con cada una por separado; hace falta su *distribución conjunta*:

$$F_{XY}(x,y) = P(X \le x,\ Y \le y), \qquad f_{XY}(x,y) = \frac{\partial^2 F_{XY}(x,y)}{\partial x\, \partial y},$$

con $P\big((X,Y) \in A\big) = \iint_A f_{XY}\, \mathrm{d}x\, \mathrm{d}y$ para cualquier región A del plano. Para variables discretas se usa la probabilidad conjunta $p_{XY}(x_i, y_j) = P(X = x_i,\ Y = y_j)$. Con M variables se escribe $f_{X_1 \cdots X_M}(x_1, \ldots, x_M)$, o $f_{\mathbf{X}}(\mathbf{x})$ con notación vectorial. Cuando no hay confusión se omiten los subíndices: $f(x,y)$.

Marginales. La distribución de una sola variable se recupera integrando (o sumando) la conjunta en las demás:

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y)\,\mathrm{d}y, \qquad p_X(x_i) = \sum_j p_{XY}(x_i, y_j).$$

Con más variables, para obtener la marginal de un subconjunto se integran todas las que no están en él.

Condicionadas. La densidad de Y sabiendo que $X = x$ es

$$f_{Y|X}(y|x) = \frac{f_{XY}(x, y)}{f_X(x)} \qquad (f_X(x) > 0).$$

De aquí salen dos reglas fundamentales:

- la *regla de la cadena*, $f_{XY}(x, y) = f_{Y|X}(y|x)\, f_X(x) = f_{X|Y}(x|y)\, f_Y(y)$, que con M variables se escribe

  $$f(x_1, \dots, x_M) = f(x_1)\, f(x_2|x_1)\, f(x_3|x_1, x_2) \cdots f(x_M|x_1, \dots, x_{M-1}),$$

  y admite $M!$ factorizaciones, una por cada orden de las variables;
- el *teorema de Bayes*, que se obtiene igualando las dos factorizaciones:

  $$f_{X|Y}(x|y) = \frac{f_{Y|X}(y|x)\, f_X(x)}{f_Y(y)}.$$

Ejemplo 2.1: Una conjunta construida por partes

Sea $X_1 \sim \mathcal{U}[2, 4]$ y, dado $X_1 = x_1$, $X_2 \sim \mathcal{N}(x_1, 1)$. Por la regla de la cadena,

$$f(x_1, x_2) = f(x_2|x_1)\, f(x_1) = \frac{1}{2} \cdot \frac{1}{\sqrt{2\pi}}\, \mathrm{e}^{-(x_2 - x_1)^2/2}, \qquad 2 \le x_1 \le 4,$$

y cero fuera (figura 9). Para muestrearla se sigue el mismo orden: se genera x_1 uniforme y después $x_2 = x_1 + z$ con $z \sim \mathcal{N}(0, 1)$. Este *muestreo ordenado* según una factorización sirve para cualquier conjunta cuyas condicionadas se sepan muestrear.

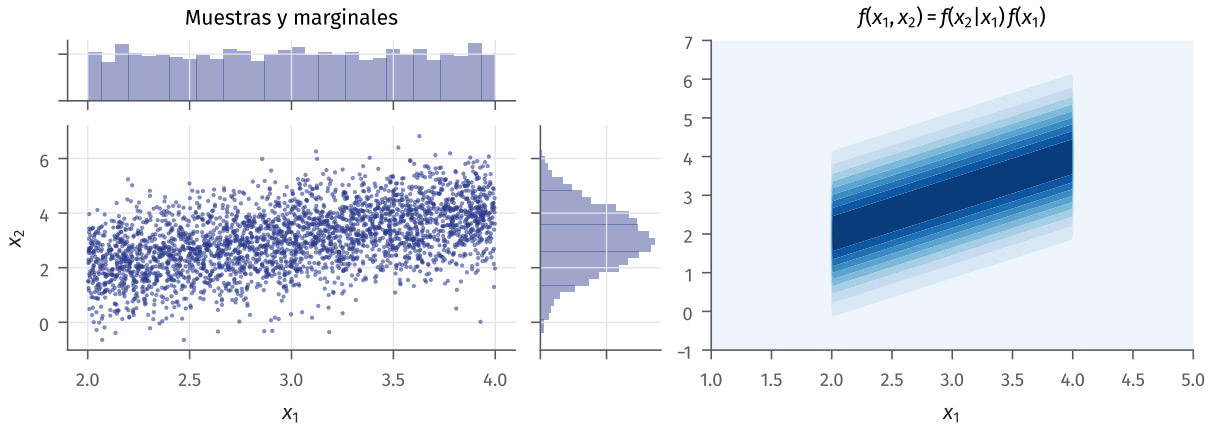


Figura 9. Muestras de la conjunta del ejemplo 2.1, sus histogramas marginales y la densidad conjunta.

2.2 Independencia

Definición 2.2: Independencia

X e Y son *independientes* si $f_{XY}(x,y) = f_X(x)\,f_Y(y)$ para todo (x,y), o, equivalentemente, si $f_{Y|X}(y|x) = f_Y(y)$: conocer el valor de X no cambia la distribución de Y. M variables son independientes si su conjunta es el producto de las M marginales.

Si las variables son independientes, para muestrearlas basta generar cada una por separado. En el ejemplo 2.1, X_1 y X_2 no son independientes: la media de X_2 depende de X_1. Se dice que X e Y son *condicionalmente independientes* dado Z si $f_{XY|Z}(x,y|z) = f_{X|Z}(x|z)\,f_{Y|Z}(y|z)$: una vez conocido Z, X no aporta nada sobre Y. Es la propiedad que define las señales de Markov (sección 3).

2.3 Correlación y covarianza

Definición 2.3: Estadísticos de un par de variables

- *Correlación*: $R_{XY} = E\{XY\} = \iint xy\, f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y$.
- *Covarianza*: $C_{XY} = E\{(X-\mu_X)(Y-\mu_Y)\} = R_{XY} - \mu_X\mu_Y$. Con $Y = X$ es la varianza.
- *Coeficiente de correlación*: $\rho_{XY} = \dfrac{C_{XY}}{\sigma_X\,\sigma_Y}$.

Por la desigualdad de Cauchy-Schwarz, $-1 \le \rho_{XY} \le 1$, y $|\rho_{XY}| = 1$ si y solo si $Y = aX + b$, con ρ del signo de a. El coeficiente mide, por tanto, el grado de dependencia *lineal* (figura 10). Se dice que X e Y son *incorreladas* si $C_{XY} = 0$, es decir, si $E\{XY\} = \mu_X\mu_Y$, y *ortogonales* si $R_{XY} = 0$. La varianza de una suma es

$$\mathrm{Var}\{X+Y\} = \sigma_X^2 + \sigma_Y^2 + 2C_{XY},$$

así que las varianzas se suman cuando las variables están incorreladas.

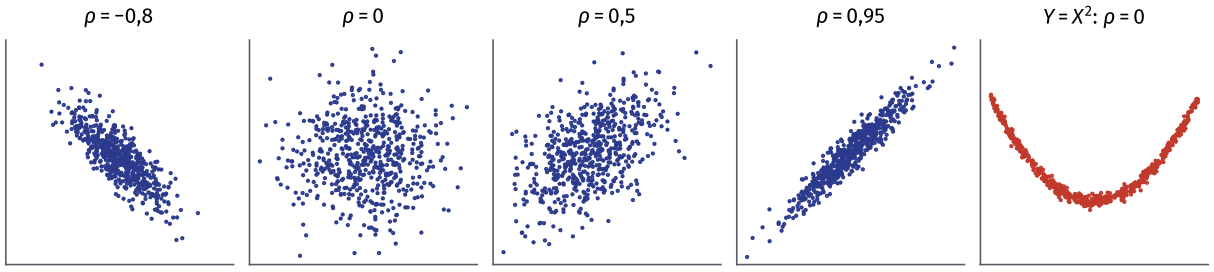


Figura 10. Pares de variables con distintos coeficientes de correlación. En el último, Y depende de X por completo y sin embargo $\rho = 0$.

Propiedad 2.4: Independencia y correlación

Si X e Y son independientes, están incorreladas:

$$E\{XY\} = \iint xy\, f_X(x) f_Y(y)\,\mathrm{d}x\,\mathrm{d}y = \int x f_X(x)\,\mathrm{d}x \int y f_Y(y)\,\mathrm{d}y = \mu_X\mu_Y.$$

El recíproco es falso en general.

Con $X \sim \mathcal{U}[-1,1]$ e $Y = X^2$, $C_{XY} = E\{X^3\} - \mu_X E\{X^2\} = 0 - 0 = 0$, aunque Y es función de X. Por tanto, una correlación distinta de cero prueba que hay dependencia, pero una correlación nula no prueba la independencia. La excepción importante son las variables conjuntamente gaussianas, para las que incorrelación e independencia son equivalentes.

Notación y erratas de versiones anteriores

Las transparencias antiguas usaban $\phi_{X_iX_j}$ para la correlación y $\psi_{X_iX_j}$ para la covarianza. Aquí se usan R y C, porque ϕ se reserva para las señales (sección 3) y ψ es la wavelet del Tema 5. Llamaban «independencia lineal» a la incorrelación, que no debe confundirse con la independencia lineal de vectores del álgebra, y escribían $E(X_i, X_j)$ con una coma. La función `corr` de Matlab que citaban necesita la Statistics Toolbox; `corrcoef` no.

En código

Estimación de medias, matriz de covarianza y coeficiente de correlación del ejemplo 2.1. Teóricamente $\mu_1 = \mu_2 = 3$, $\sigma_1^2 = \frac{1}{3}$, $\sigma_2^2 = 1 + \frac{1}{3}$ (la varianza de X_1 más la del ruido), $C_{12} = E\{(X_1 - 3)(X_1 - 3 + Z)\} = \frac{1}{3}$ y $\rho = \dfrac{1/3}{\sqrt{1/3 \cdot 4/3}} = 0{,}5$.

Python

```python
import numpy as np

rng = np.random.default_rng(5)
N = 100000
x1 = rng.uniform(2, 4, N)          # U[2,4]
x2 = x1 + rng.standard_normal(N) # N(x1,1)
X = np.c_[x1, x2]                  # N x 2
print(X.mean(axis=0))              # 3, 3
print(np.cov(X.T))       # [1/3 1/3; 1/3 4/3]
print(np.corrcoef(X.T)[0, 1])    # 0.5
```

Matlab

```matlab
N = 100000;
x1 = 2 + 2*rand(N, 1);             % U[2,4]
x2 = x1 + randn(N, 1);             % N(x1,1)
X = [x1, x2];                      % N x 2
disp(mean(X))                      % 3, 3
disp(cov(X))             % [1/3 1/3; 1/3 4/3]
c = corrcoef(X); disp(c(1, 2))    % 0.5
```

2.4 Vectores aleatorios y gaussiana multivariable

Con M variables agrupadas en un vector columna $\mathbf{X} = (X_1, \ldots, X_M)^T$, los estadísticos de primer y segundo orden son el *vector de medias* y la *matriz de covarianza*:

$$\mu = E\{\mathbf{X}\}, \qquad \Sigma = E\{(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T\}, \qquad \Sigma_{ij} = C_{X_iX_j}, \quad \Sigma_{ii} = \sigma_i^2.$$

Σ es simétrica y semidefinida positiva, y diagonal si las variables están incorreladas. Si $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$, por la linealidad de la esperanza

$$\mu_Y = \mathbf{A}\mu + \mathbf{b}, \qquad \Sigma_Y = \mathbf{A}\Sigma\mathbf{A}^T.$$

Para estimarlos a partir de N muestras se colocan en una matriz de $N \times M$ (una muestra por fila) y se usan `mean`, `cov` y `corrcoef` en Matlab; `np.cov` y `np.corrcoef` esperan, por defecto, una variable por fila, de ahí la traspuesta del ejemplo anterior.

Definición 2.5: Gaussiana multivariable

$\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$ si

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^M \det \Sigma}} \exp\Big(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \Big).$$

Queda determinada por su media y su covarianza. Sus curvas de nivel son elipses (elipsoides en más dimensiones) centradas en μ, con los ejes en la dirección de los autovectores de $\Sigma = \mathbf{V}\Lambda\mathbf{V}^T$ y semiejes proporcionales a $\sqrt{\lambda_k}$ (figura 11). Las marginales, las condicionadas y cualquier transformación lineal de una gaussiana son gaussianas. Si Σ es diagonal, la exponencial se factoriza en un producto: incorreladas implica independientes.

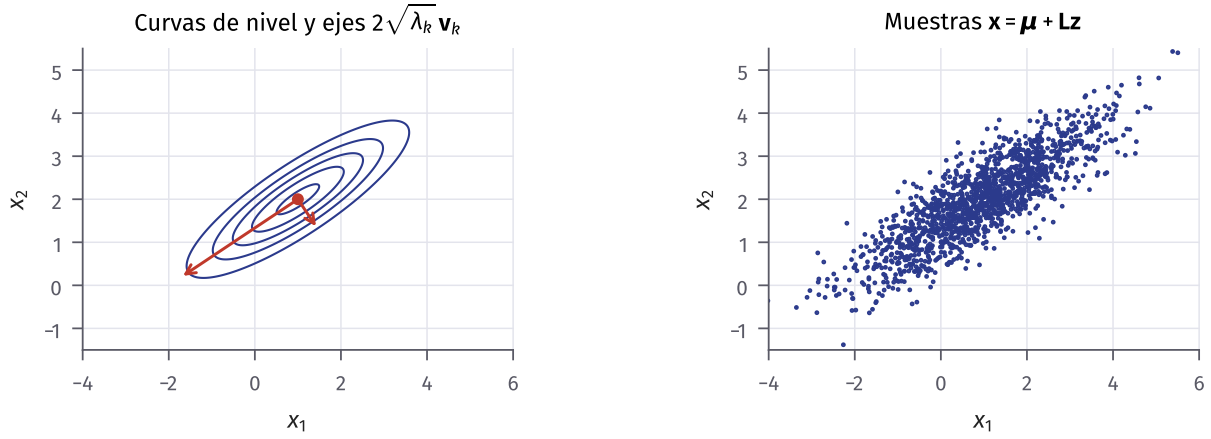


Figura 11. Gaussiana bidimensional con $\mu = (1, 2)^T$ y $\Sigma = \left[\begin{smallmatrix} 2 & 1{,}2 \\ 1{,}2 & 1 \end{smallmatrix}\right]$: curvas de nivel con sus ejes, y muestras.

Para muestrearla se generan M gaussianas independientes $\mathcal{N}(0, 1)$, que forman un vector $\mathbf{z}$ con covarianza $\mathbf{I}$, y se transforman:

$$\mathbf{x} = \mu + \mathbf{Lz}, \qquad \mathbf{LL}^T = \Sigma,$$

porque entonces $\Sigma_X = \mathbf{LIL}^T = \Sigma$. $\mathbf{L}$ puede ser el factor de Cholesky, que se calcula con `chol(S, 'lower')` en Matlab y con `np.linalg.cholesky` en Python, o $\mathbf{V}\Lambda^{1/2}$, que primero escala cada eje y después gira.

En código

Gaussiana bidimensional muestreada con Cholesky. Los autovalores de Σ, 0,2 y 2,8, son las varianzas a lo largo de los ejes de la elipse.

Python

```python
import numpy as np

rng = np.random.default_rng(6)
mu = np.array([1.0, 2.0])
S = np.array([[2.0, 1.2],
              [1.2, 1.0]])      # covarianza
L = np.linalg.cholesky(S)        # S = L L^T
Z = rng.standard_normal((2, 100000))
X = mu[:, None] + L @ Z          # 2 x N
print(X.mean(axis=1))            # ~ mu
print(np.cov(X))                 # ~ S
lam, V = np.linalg.eigh(S)       # ejes
print(lam)                      # 0.2, 2.8
```

Matlab

```matlab
mu = [1; 2];
S = [2.0 1.2;
     1.2 1.0];                   % covarianza
L = chol(S, 'lower');            % S = L L'
Z = randn(2, 100000);
X = mu + L*Z;                    % 2 x N
disp(mean(X, 2)')                % ~ mu
disp(cov(X'))                    % ~ S
[V, D] = eig(S);                 % ejes
disp(diag(D)')                   % 0.2, 2.8
```

Erratas de versiones anteriores

La gaussiana multivariable se escribía con $\mathbf{x}$ como vector fila, $(\mathbf{x} - \boldsymbol{\mu})\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})^T$, y la descomposición de $\boldsymbol{\Sigma}$ con `svd`, sin explicar que para una matriz simétrica definida positiva coincide con la de autovalores. Se decía que la matriz de rotación $\mathbf{R}$ y la diagonal $\mathbf{D}$ dan $\boldsymbol{\Sigma} = \mathbf{RDR}'$, pero no cómo muestrear con ellas: hace falta $\mathbf{RD}^{1/2}$.

2.5 Suma de variables y teorema central del límite

Sea $S = X + Y$. Por la linealidad, $\mu_S = \mu_X + \mu_Y$ siempre, y $\sigma_S^2 = \sigma_X^2 + \sigma_Y^2$ si las variables están incorreladas. Si además son independientes, la densidad de la suma es la *convolución* de las densidades:

$$f_S(s) = \int_{-\infty}^{\infty} f_X(x)\, f_Y(s-x)\, \mathrm{d}x = (f_X * f_Y)(s),$$

porque para que la suma valga s con $X = x$ tiene que ser $Y = s - x$. Por ejemplo, la suma de dos $\mathcal{U}[0,1]$ independientes tiene densidad triangular en $[0,2]$, la convolución de dos pulsos.

Propiedad 2.6: Teorema central del límite

Si $X_1, \ldots, X_n$ son independientes, con la misma distribución, media μ y varianza σ^2 finita, la suma normalizada

$$Z_n = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\,\sigma}$$

tiende a $\mathcal{N}(0,1)$ cuando $n \to \infty$, cualquiera que sea la distribución de las X_i.

La convergencia es rápida (figura 12): la suma de doce uniformes $\mathcal{U}[0,1]$ menos 6 tiene media 0 y varianza 1, y ya es casi gaussiana. El teorema se cumple también, con condiciones, para variables no idénticas, y explica por qué el ruido que resulta de sumar muchas contribuciones independientes, como el movimiento de los electrones en una resistencia, es gaussiano.

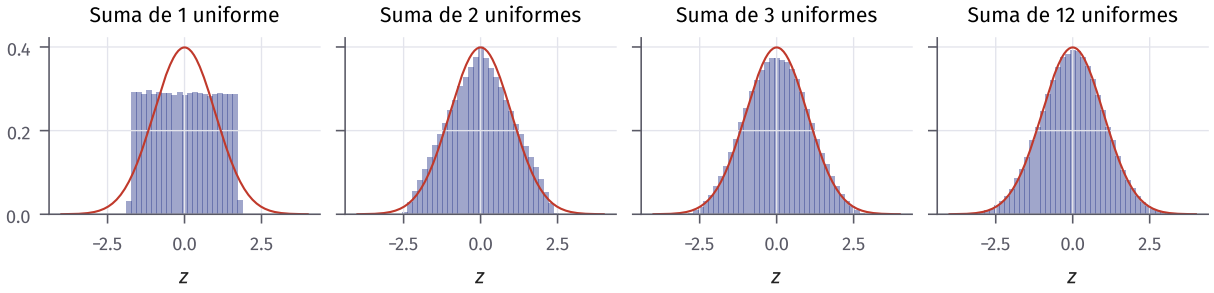


Figura 12. Histograma de la suma normalizada de n uniformes y la densidad $\mathcal{N}(0,1)$.

Ejercicios 6–10.

3 Señales aleatorias

3.1 Definición y descripción

Definición 3.1: Señal aleatoria

Una *señal aleatoria* o *proceso estocástico* es una familia de variables aleatorias indexadas por el tiempo: $x[n]$, $n \in \mathbb{Z}$, en tiempo discreto, o $x(t)$, $t \in \mathbb{R}$, en tiempo continuo.

Hay dos formas de verla (figura 13). Fijado el resultado del experimento, se obtiene una señal determinista, una *realización*; fijado el instante n, $x[n]$ es una variable aleatoria. El conjunto de todas las realizaciones posibles se llama *conjunto* (*ensemble*). Siguiendo la notación del curso, escribimos la señal aleatoria con minúscula, como sus realizaciones; el contexto aclara de qué se habla.

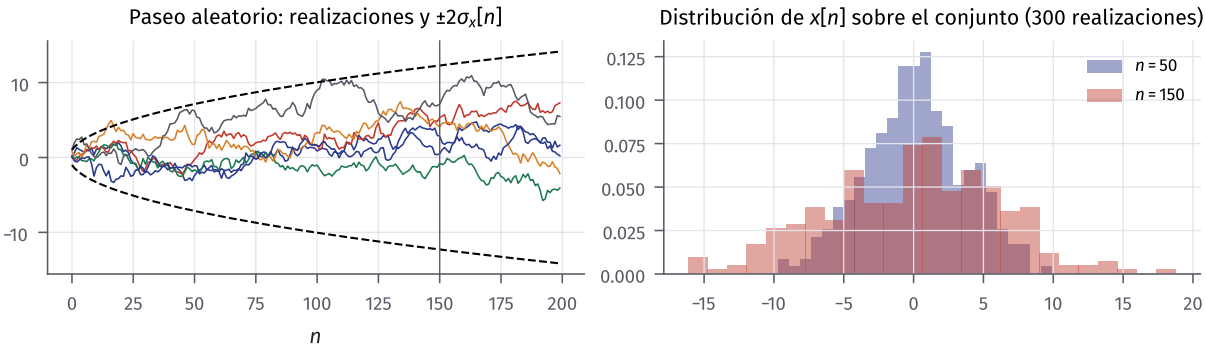


Figura 13. Seis realizaciones de un paseo aleatorio y la distribución de $x[n]$ en dos instantes, estimada con 300 realizaciones.

Una señal aleatoria queda completamente descrita por las distribuciones conjuntas de $x[n_1], \dots, x[n_k]$ para cualesquiera k instantes, algo que casi nunca se conoce. En la práctica se usan los momentos de primer y segundo orden, que son los estadísticos de la sección 2 aplicados a los valores de la señal en uno o dos instantes:

- media: $\mu_x[n] = E\{x[n]\}$;
- valor cuadrático medio o potencia instantánea: $E\{x^2[n]\}$, y varianza $\sigma_x^2[n] = E\{x^2[n]\} - \mu_x^2[n]$;
- autocorrelación: $\phi_{xx}[n_1, n_2] = E\{x[n_1]\, x[n_2]\}$;
- autocovarianza: $\gamma_{xx}[n_1, n_2] = E\{(x[n_1] - \mu_x[n_1])(x[n_2] - \mu_x[n_2])\} = \phi_{xx}[n_1, n_2] - \mu_x[n_1]\mu_x[n_2]$;
- correlación cruzada de dos señales: $\phi_{xy}[n_1, n_2] = E\{x[n_1]\, y[n_2]\}$, y covarianza cruzada γ_{xy}.

En tiempo continuo se definen igual con $x(t_1)$ y $x(t_2)$. Si la señal es *gaussiana*, es decir, si todas sus distribuciones conjuntas son gaussianas, la media y la autocorrelación la describen por completo.

Algunos tipos de señales.

- *I.i.d.*: las $x[n]$ son independientes e idénticamente distribuidas. Si además tienen media nula, son *ruido blanco* (el nombre se explica en la sección 4): $\phi_{xx}[n_1, n_2] = \sigma^2 \delta[n_1 - n_2]$.
- *De Markov* de primer orden: el futuro solo depende del pasado a través del presente,

  $$f(x[n] \,|\, x[n-1], x[n-2], \dots) = f(x[n] \,|\, x[n-1]),$$

  de modo que la conjunta se factoriza como $f(x[0], \dots, x[n]) = f(x[0]) \prod_{k=1}^{n} f(x[k] \,|\, x[k-1])$, y se muestrea generando cada valor a partir del anterior. Dos ejemplos, con $w[n]$ ruido blanco:
  - el *paseo aleatorio* $x[n] = x[n-1] + w[n]$, en el que $f(x[n]|x[n-1]) = \mathcal{N}(x[n-1], \sigma_w^2)$ si w es gaussiano;
  - la señal *autorregresiva de orden 1*, AR(1): $x[n] = a\, x[n-1] + w[n]$, con $|a| < 1$, que es ruido blanco filtrado por $H(z) = 1/(1 - az^{-1})$.
- En tiempo continuo el papel del retardo lo hace la derivada. El equivalente del AR(1) es la señal que cumple $\frac{\mathrm{d}x}{\mathrm{d}t} = -\alpha x(t) + w(t)$ (proceso de Ornstein-Uhlenbeck): ruido blanco a través de un sistema de primer orden.

Erratas de versiones anteriores

La factorización de la señal de Markov omitía el factor $f(x[0])$, y la versión continua se presentaba como «$p(\dot{x}(t)|x(t))$» sin decir de qué modelo provenía. La primera transparencia decía que la conjunta $p(x(0), \dots, x(10))$ define la señal; hacen falta las conjuntas de cualquier número de instantes.

3.2 Estacionariedad

Definición 3.2: Señal estacionaria

Una señal es *estacionaria en sentido estricto* si sus distribuciones conjuntas no cambian al desplazar el origen de tiempos. Es *estacionaria en sentido amplio* (ESA) si su media es constante y su autocorrelación solo depende de la separación entre los instantes:

$$\mu_x[n] = \mu_x, \qquad \phi_{xx}[n+l,\, n] = \phi_{xx}[l] \quad \text{para todo } n.$$

Dos señales son *conjuntamente* ESA si cada una lo es y $\phi_{xy}[n+l, n]$ solo depende de l.

La estacionariedad estricta implica la amplia si los momentos existen; para señales gaussianas las dos son equivalentes. En una señal ESA también son constantes la potencia $E\{x^2[n]\} = \phi_{xx}[0]$ y la varianza. Para señales ESA usaremos, como Oppenheim y Schafer y como la función `xcorr` de Matlab,

$$\phi_{xx}[l] = E\{x[n+l]\, x[n]\}, \qquad \phi_{xy}[l] = E\{x[n+l]\, y[n]\}, \qquad \gamma_{xx}[l] = \phi_{xx}[l] - \mu_x^2,$$

y en tiempo continuo $\phi_{xx}(\tau) = E\{x(t+\tau)\, x(t)\}$.

Ejemplo 3.3: ¿Cuáles son estacionarias?

(Figura 14.)

1. i.i.d. $\mathcal{U}[0,1]$: estacionaria. $\mu_x = \frac{1}{2}$, $\phi_{xx}[0] = E\{x^2\} = \frac{1}{3}$ y $\phi_{xx}[l] = \mu_x^2 = \frac{1}{4}$ para $l \neq 0$, porque valores distintos son independientes.
2. Independientes $\mathcal{N}(0, \sigma^2[n])$ con $\sigma[n] = 0{,}97^n$: no estacionaria, porque la varianza depende de n, aunque los valores sean independientes.
3. Paseo aleatorio con $x[0] = 0$: $x[n] = \sum_{k=1}^{n} w[k]$, así que $\mu_x = 0$ pero $\mathrm{Var}\{x[n]\} = n\sigma_w^2$ crece con n: no estacionaria.
4. Constante aleatoria $x[n] = A$ con $A \sim \mathcal{U}[0,1]$: estacionaria, con $\mu_x = \frac{1}{2}$ y $\phi_{xx}[l] = E\{A^2\} = \frac{1}{3}$ para todo l.

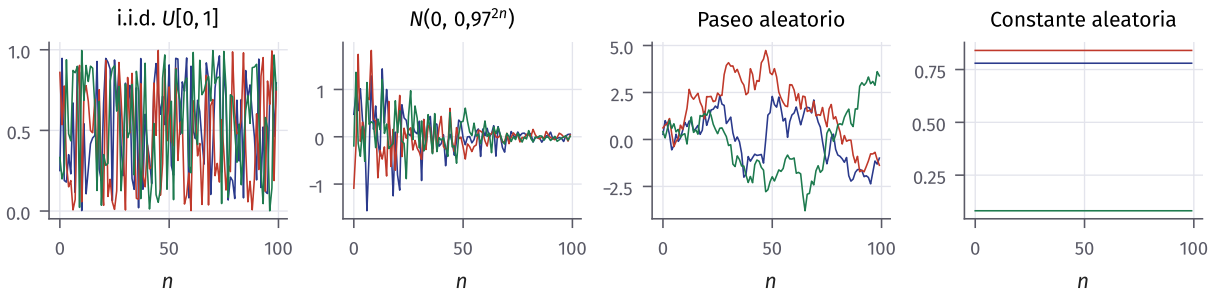


Figura 14. Tres realizaciones de las cuatro señales del ejemplo 3.3.

Ejemplo 3.4: Sinusoide de fase aleatoria

Sea $x[n] = A\cos(\Omega_0 n + \theta)$ con A y Ω_0 fijos y $\theta \sim \mathcal{U}[0, 2\pi)$. Su media es $\frac{A}{2\pi}\int_0^{2\pi} \cos(\Omega_0 n + \theta)\,\mathrm{d}\theta = 0$, y, usando $\cos\alpha\cos\beta = \frac{1}{2}[\cos(\alpha+\beta) + \cos(\alpha-\beta)]$,

$$\phi_{xx}[n+l, n] = \frac{A^2}{2} E\{\cos(\Omega_0(2n+l) + 2\theta)\} + \frac{A^2}{2}\cos(\Omega_0 l) = \frac{A^2}{2}\cos(\Omega_0 l),$$

porque el primer término promedia un coseno sobre una fase uniforme. Es ESA, y su autocorrelación es periódica y no se amortigua (figura 15).

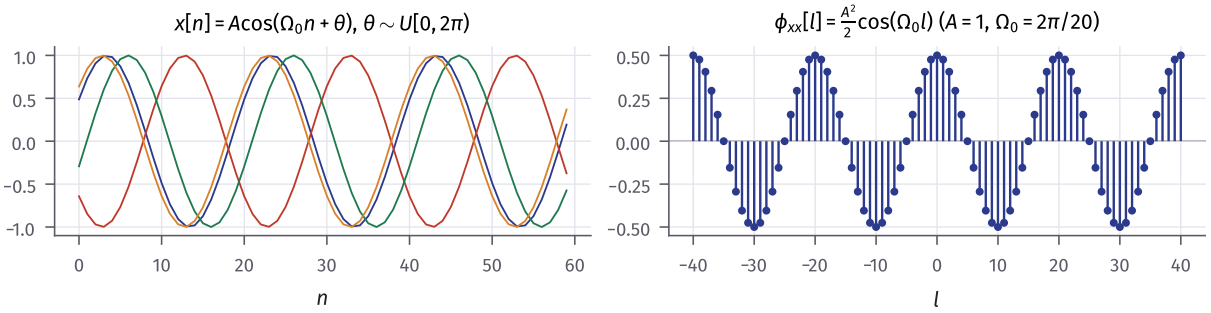


Figura 15. Realizaciones de una sinusoide de fase aleatoria y su autocorrelación.

Erratas de versiones anteriores

La definición antigua de estacionariedad en sentido amplio era «la función de probabilidad no depende del tiempo: $p(x(t_1)) = p(x(t_2))$». Eso es una condición sobre la distribución de primer orden completa, que no basta para la ESA (no dice nada de la autocorrelación) ni es necesaria (una señal ESA puede cambiar de distribución si conserva media y varianza). Los ejemplos hablaban de «sistema discreto» donde querían decir señal.

3.3 Ergodicidad

En la práctica casi nunca se dispone de muchas realizaciones, sino de una sola grabación. La pregunta es si los estadísticos, que son promedios sobre el conjunto, se pueden obtener promediando en el tiempo una única realización.

Definición 3.5: Ergodicidad

Una señal ESA es *ergódica* (en media y en autocorrelación) si, para casi todas sus realizaciones,

$$\lim_{N\to\infty} \frac{1}{2N+1}\sum_{n=-N}^{N} x[n] = \mu_x, \qquad \lim_{N\to\infty} \frac{1}{2N+1}\sum_{n=-N}^{N} x[n+l]\,x[n] = \phi_{xx}[l].$$

En tiempo continuo, igual con $\frac{1}{2T}\int_{-T}^{T}$ y $T \to \infty$.

Intuitivamente, una realización larga recorre todos los comportamientos posibles de la señal. Las señales i.i.d., las AR(1) estacionarias y la sinusoide de fase aleatoria son ergódicas. La constante aleatoria del ejemplo 3.3 es estacionaria pero no ergódica: el promedio temporal de una realización es el valor A que le tocó, no $\frac{1}{2}$. Una condición suficiente para la ergodicidad en media es que $\gamma_{xx}[l] \to 0$ cuando $|l| \to \infty$. Salvo que se diga lo contrario, supondremos que las señales estacionarias son ergódicas, y estimaremos sus estadísticos a partir de una realización.

3.4 Autocorrelación

Propiedad 3.6: Propiedades de la autocorrelación de una señal ESA real

- $\phi_{xx}[0] = E\{x^2[n]\} = \sigma_x^2 + \mu_x^2$ es la potencia media de la señal.
- Es par: $\phi_{xx}[-l] = E\{x[n-l]\,x[n]\} = \phi_{xx}[l]$ (basta cambiar n por $n+l$).
- Tiene el máximo en el origen: $|\phi_{xx}[l]| \leq \phi_{xx}[0]$, por Cauchy-Schwarz.
- Si la señal no tiene componentes periódicas ni constantes aleatorias, los valores muy separados son incorrelados: $\gamma_{xx}[l] \to 0$ y $\phi_{xx}[l] \to \mu_x^2$ cuando $|l| \to \infty$.

La última propiedad sirve para detectar componentes deterministas: si la autocorrelación no tiende a μ_x^2, la señal tiene una parte determinista, y si esta es periódica, ϕ_{xx} oscila con el mismo periodo. La figura 16 muestra cuatro casos con $T_s = 0{,}01$ s y 10 s de señal: ruido i.i.d. $\mathcal{N}(5,1)$, con un pico de $\sigma^2 + \mu^2 = 26$ en el origen y $\mu^2 = 25$ fuera; ruido i.i.d. $\mathcal{U}[2,6]$, con $E\{x^2\} = \frac{4+12+36}{3} = 17{,}3$ y $\mu^2 = 16$; un seno, cuya autocorrelación oscila sin amortiguarse, y un AR(1) con $a = 0{,}95$, cuya autocorrelación decae exponencialmente.

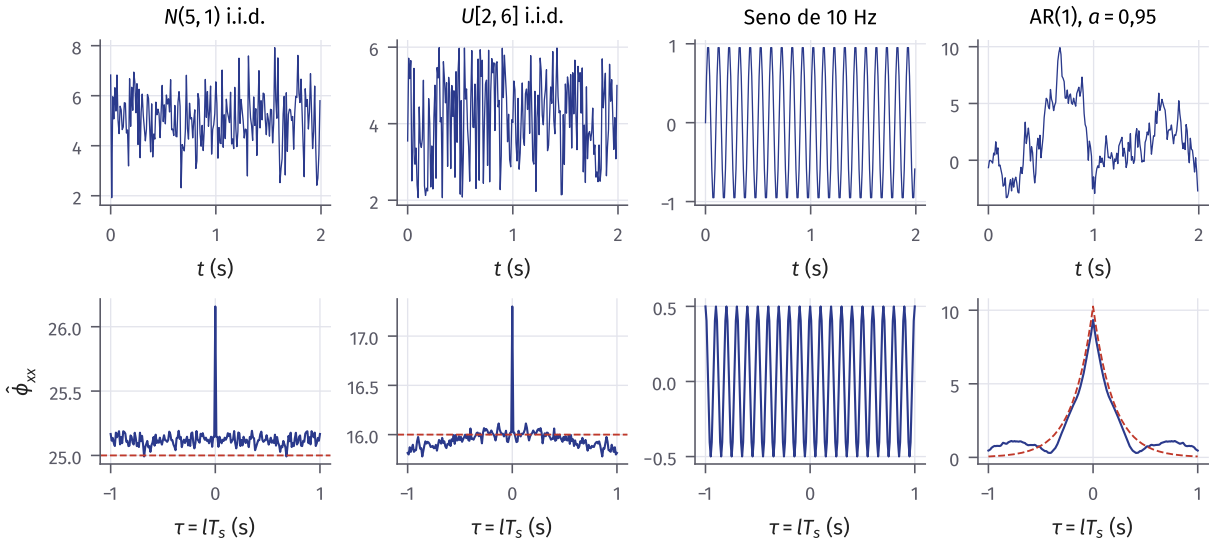


Figura 16. Cuatro señales y su autocorrelación estimada. En rojo, los valores teóricos.

Erratas de versiones anteriores

Se escribía «$\phi_{XX}(0) > \phi_{XX}(\tau)$»; la desigualdad correcta es $\phi_{xx}(0) \geq |\phi_{xx}(\tau)|$, con igualdad posible (una sinusoide la alcanza en cada periodo). El límite $\phi_{xx} \to \mu_x^2$ se daba «para $t \gg 0$» en lugar de para $|\tau| \to \infty$, se presentaba como una propiedad de toda señal estacionaria, y la nota de la deducción de la salida de un sistema LTI llamaba ψ_{XX} a la autocorrelación.

Estimación. Con una realización de N muestras $x[0], \ldots, x[N-1]$ de una señal ergódica, hay $N - |l|$ productos $x[n+|l|]\,x[n]$ disponibles para la separación l. Su media es el estimador *insesgado*

$$\hat{\phi}_{xx}[l] = \frac{1}{N-|l|} \sum_{n=0}^{N-1-|l|} x[n+|l|]\,x[n],$$

y si se divide por N se obtiene el estimador *sesgado* $\check{\phi}_{xx}[l] = \frac{N-|l|}{N}\hat{\phi}_{xx}[l]$. El insesgado acierta en media, pero para $|l|$ cercano a N promedia muy pocos productos y es muy ruidoso; el sesgado se amortigua hacia

los extremos y tiene menos varianza, y su transformada de Fourier es siempre no negativa (sección 4). En cualquier caso, solo tiene sentido para $|l|$ bastante menor que N. En Matlab, `xcorr(x, L, 'unbiased')` o `'biased'` calculan los valores para $|l| \le L$; en Python se usa `np.correlate(x, x, 'full')` y se divide por el número de productos.

En código

Autocorrelación estimada de ruido i.i.d. $\mathcal{N}(5,1)$ y $\mathcal{U}[2,6]$ con 1001 muestras: en el origen, unos 26 y 17,3; a 50 muestras, unos 25 y 16.

Python

```python
import numpy as np

def xcorr(x, y, L):
    """Media de x[n+l]y[n] (insesgada)."""
    N = len(x)
    c = np.correlate(x, y, "full")
    c = c[N-1-L:N+L]
    l = np.arange(-L, L + 1)
    return l, c/(N - abs(l))

rng = np.random.default_rng(7)
N = 1001
x = 5 + rng.standard_normal(N)  # N(5,1) iid
u = 2 + 4*rng.random(N)         # U[2,6] iid
l, px = xcorr(x, x, 100)
_, pu = xcorr(u, u, 100)
print(px[100], px[150])         # ~ 26, ~ 25
print(pu[100], pu[150])       # ~ 17.3, ~ 16
```

Matlab

```matlab
N = 1001;
x = 5 + randn(1, N);            % N(5,1) iid
u = 2 + 4*rand(1, N);           % U[2,6] iid
[px, l] = xcorr(x, 100, 'unbiased');
pu = xcorr(u, 100, 'unbiased');
disp([px(101), px(151)])        % ~ 26, ~ 25
disp([pu(101), pu(151)])      % ~ 17.3, ~ 16
```

Ejemplo 3.7: Autocorrelación de un AR(1)

Sea $x[n] = a\,x[n-1] + w[n]$, con $|a| < 1$ y w ruido blanco de varianza σ_w^2, en régimen estacionario. Como $x[n-1]$ solo depende de $w[n-1], w[n-2], \ldots$, es independiente de $w[n]$, y

$$\sigma_x^2 = E\{(ax[n-1] + w[n])^2\} = a^2\sigma_x^2 + \sigma_w^2 \;\Rightarrow\; \sigma_x^2 = \frac{\sigma_w^2}{1-a^2}.$$

Para $l > 0$, $\phi_{xx}[l] = E\{(ax[n+l-1] + w[n+l])\,x[n]\} = a\,\phi_{xx}[l-1]$, y por ser par,

$$\phi_{xx}[l] = \frac{\sigma_w^2}{1-a^2}\,a^{|l|}.$$

Con a cerca de 1 los valores están muy correlados y la señal varía despacio; con $a < 0$ la autocorrelación alterna de signo y la señal cambia de signo con frecuencia.

En código

Autocorrelación de un AR(1) con $a = 0{,}9$ comparada con la teórica. La potencia, $1/(1-0{,}81) = 5{,}26$, es cinco veces la del ruido de entrada.

Python

```python
import numpy as np
from scipy import signal

rng = np.random.default_rng(8)
a, N = 0.9, 200000
w = rng.standard_normal(N)    # blanco, s2=1
x = signal.lfilter([1], [1, -a], w)
x = x[1000:]                  # sin transitorio
for l in (0, 1, 5, 10):
    est = np.mean(x[l:]*x[:len(x)-l])
    teo = a**l/(1 - a**2)
    print(l, est, teo)
```

Matlab

```matlab
a = 0.9; N = 200000;
w = randn(1, N);                % blanco, s2=1
x = filter(1, [1 -a], w);
x = x(1001:end);              % sin transitorio
for l = [0 1 5 10]
  est = mean(x(1+l:end).*x(1:end-l));
  teo = a^l/(1 - a^2);
  disp([l, est, teo])
end
```

3.5 Correlación cruzada

$\phi_{xy}[l] = E\{x[n+l]\, y[n]\}$ mide cuánto se parece x, adelantada l muestras, a y. A diferencia de la autocorrelación, no tiene por qué ser par ni tener el máximo en el origen.

Propiedad 3.8: Propiedades de la correlación cruzada

Para dos señales reales conjuntamente ESA:

- $\phi_{xy}[l] = \phi_{yx}[-l]$;
- $|\phi_{xy}[l]|^2 \le \phi_{xx}[0]\,\phi_{yy}[0]$ y $|\phi_{xy}[l]| \le \frac{1}{2}\big(\phi_{xx}[0] + \phi_{yy}[0]\big)$;
- si x e y son independientes (o incorreladas), $\phi_{xy}[l] = \mu_x\mu_y$ para todo l.

Ejemplo 3.9: Eco

Una señal x blanca de varianza σ_x^2 se recibe con un retardo D, atenuada y con ruido v independiente: $y[n] = \alpha\, x[n-D] + v[n]$. Entonces

$$\phi_{yx}[l] = E\{y[n+l]\, x[n]\} = \alpha\, E\{x[n+l-D]\, x[n]\} + E\{v[n+l]\}E\{x[n]\} = \alpha\sigma_x^2\, \delta[l-D]\ :$$

la correlación cruzada tiene un pico en el retardo. Si x no es blanca, el pico tiene la forma de ϕ_{xx} centrada en D.

Esta es la base de muchas aplicaciones: medir distancias con radar o sonar (se correla el eco con el pulso emitido), localizar una fuente con dos micrófonos, detectar los caminos de propagación de un canal (un pico por camino) o sincronizar un receptor con una trama conocida. En la figura 17 se busca $x(t) = \mathrm{sinc}(t-2)$ dentro de $y(t) = \mathrm{sinc}(t-3)$ más ruido gaussiano de desviación típica 1; aunque el pulso apenas se distingue, la correlación cruzada tiene el máximo en $\tau \approx 1$ s.

En código

Estimación del retardo. `xcorr(y, x)` y `np.correlate(y, x, 'full')` calculan $\sum_n y[n+l]\, x[n]$, es decir, ϕ_{yx} salvo el factor de normalización.

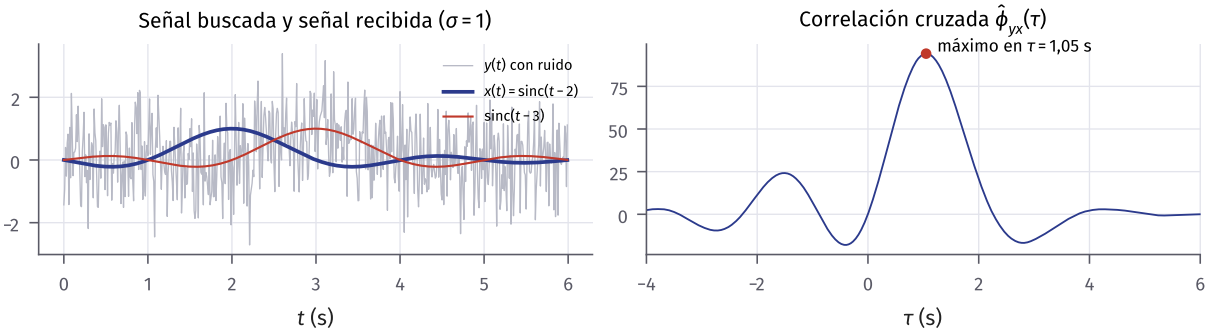


Figura 17. Estimación de un retardo con la correlación cruzada.

Python

```python
import numpy as np

rng = np.random.default_rng(9)
Ts = 0.01
t = np.arange(0, 6, Ts)
x = np.sinc(t - 2)                  # buscada
y = np.sinc(t - 3) \
    + rng.standard_normal(t.size) # recibida
c = np.correlate(y, x, "full")  # y[n+l]x[n]
lags = np.arange(-len(x) + 1, len(y))
tau = lags[np.argmax(c)]*Ts
print(tau)                          # ~ 1 s
```

Matlab

```matlab
Ts = 0.01;
t = 0:Ts:6-Ts;
x = sinc(t - 2);                    % buscada
y = sinc(t - 3) ...
    + randn(size(t));               % recibida
[c, lags] = xcorr(y, x);          % y[n+l]x[n]
[~, k] = max(c);
disp(lags(k)*Ts)                    % ~ 1 s
```

Convenio de la correlación cruzada

Las transparencias antiguas, y otros textos, definen $\phi_{xy}(\tau) = E\{x(t)\, y(t+\tau)\}$, que es la función de estos apuntes reflejada, $\phi_{xy}(-\tau)$, o lo que es lo mismo, $\phi_{yx}(\tau)$. Con aquel convenio la relación de un sistema LTI se escribe $\Phi_{xy} = H\Phi_{xx}$; con este, $\Phi_{yx} = H\Phi_{xx}$. Seguimos el de Oppenheim y Schafer y Matlab.

Ejercicios 11–14.

4 Análisis espectral de señales aleatorias

4.1 Densidad espectral de potencia

Una realización de una señal estacionaria no decae: tiene energía infinita, y su DTFT no existe en sentido ordinario. Además, cada realización tendría una transformada distinta. Lo que sí está bien definido es la potencia media,

$$P_x = E\left\{ \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} x^2[n] \right\} = \lim_{N\to\infty} \frac{1}{2N+1} \sum_{n=-N}^{N} E\{x^2[n]\} = \phi_{xx}[0] \quad \text{(señal ESA)},$$

y, más en general, la autocorrelación, que es como una potencia que depende de la separación l. Su transformada de Fourier describe cómo se reparte la potencia en frecuencia.

Definición 4.1: Densidad espectral de potencia

La *densidad espectral de potencia* (DEP), o espectro de potencia, de una señal ESA es la DTFT de su autocorrelación:

$$\Phi_{xx}(e^{j\Omega}) = \sum_{l=-\infty}^{\infty} \phi_{xx}[l]\, e^{-j\Omega l}, \qquad \phi_{xx}[l] = \frac{1}{2\pi}\int_{-\pi}^{\pi} \Phi_{xx}(e^{j\Omega})\, e^{j\Omega l}\, d\Omega.$$

En tiempo continuo, $\Phi_{xx}(j\omega) = \int_{-\infty}^{\infty} \phi_{xx}(\tau)\, e^{-j\omega\tau}\, d\tau$.

Propiedad 4.2: Propiedades de la DEP

- La potencia es el área: $P_x = \phi_{xx}[0] = \frac{1}{2\pi}\int_{-\pi}^{\pi} \Phi_{xx}(e^{j\Omega})\, d\Omega$.
- Es real, porque ϕ_{xx} es par; par en Ω si x es real; y no negativa.
- Teorema de Wiener-Khinchin: si $X_N(e^{j\Omega})$ es la DTFT de $2N+1$ muestras de una realización,

$$\Phi_{xx}(e^{j\Omega}) = \lim_{N\to\infty} \frac{1}{2N+1} E\{|X_N(e^{j\Omega})|^2\}.$$

El tercer punto justifica el nombre: Φ_{xx} es el cuadrado del módulo del espectro, por unidad de tiempo y promediado sobre las realizaciones. La potencia contenida en la banda $\Omega_1 \le |\Omega| \le \Omega_2$ es $\frac{1}{2\pi}$ por la integral de Φ_{xx} en esa banda, contando las frecuencias positivas y negativas. En tiempo continuo, $P_x = \frac{1}{2\pi}\int \Phi_{xx}(j\omega)\, d\omega = \int \Phi_{xx}(j2\pi f)\, df$, de modo que Φ_{xx} se mide en W/Hz si x es una tensión sobre $1\,\Omega$.

Ejemplo 4.3: Densidades espectrales

- *Ruido blanco* de varianza σ^2: $\phi_{xx}[l] = \sigma^2\delta[l]$ y $\Phi_{xx}(e^{j\Omega}) = \sigma^2$. Todas las frecuencias tienen la misma potencia, como la luz blanca contiene todos los colores; de ahí el nombre.
- *AR(1)*: de $\phi_{xx}[l] = \frac{\sigma_w^2}{1-a^2}a^{|l|}$,

$$\Phi_{xx}(e^{j\Omega}) = \frac{\sigma_w^2}{1-a^2}\left(\frac{1}{1-ae^{-j\Omega}} + \frac{1}{1-ae^{j\Omega}} - 1\right) = \frac{\sigma_w^2}{|1-ae^{-j\Omega}|^2} = \frac{\sigma_w^2}{1-2a\cos\Omega + a^2}.$$

  Paso bajo si $a > 0$ y paso alto si $a < 0$ (figura 18).
- *Constante* μ (o componente continua): $\phi_{xx}[l] = \mu^2$ y $\Phi_{xx} = 2\pi\mu^2\delta(\Omega)$ en $[-\pi, \pi]$, repetida con periodo 2π.
- *Sinusoide de fase aleatoria*: $\phi_{xx}[l] = \frac{A^2}{2}\cos\Omega_0 l$ y $\Phi_{xx} = \frac{\pi A^2}{2}\big[\delta(\Omega-\Omega_0) + \delta(\Omega+\Omega_0)\big]$: toda la potencia, $A^2/2$, en $\pm\Omega_0$.

Según la forma de su DEP, las señales se clasifican en *blancas* (DEP plana), *coloreadas* (cualquier otra), de *banda ancha* o de *banda estrecha*, *paso bajo* o *paso banda*. Como en cualquier par transformado, la anchura de la autocorrelación es inversa al ancho de banda: una señal de banda estrecha tiene valores correlados a gran distancia.

Ruido blanco en tiempo continuo

El ruido blanco continuo tiene $\phi_{xx}(\tau) = \frac{N_0}{2}\delta(\tau)$ y $\Phi_{xx}(j\omega) = \frac{N_0}{2}$. Su potencia, $\phi_{xx}(0)$, es infinita, así que no existe físicamente: es un modelo de un ruido cuya DEP es plana en toda la banda que

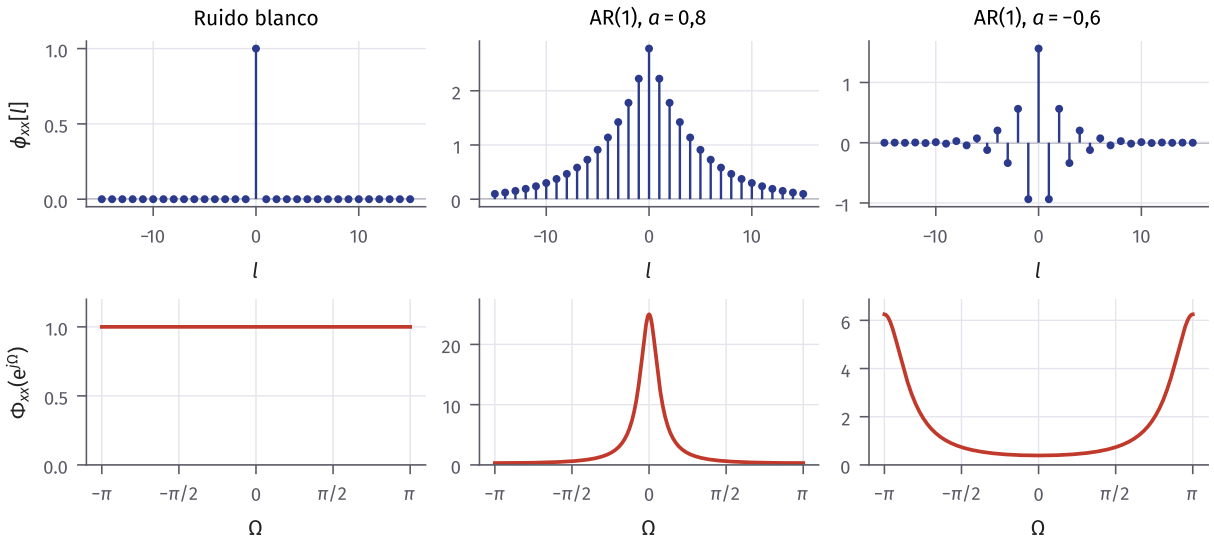


Figura 18. Autocorrelación y densidad espectral de potencia de ruido blanco y de dos AR(1), con $\sigma_w^2 = 1$.

interesa. El ruido térmico de una resistencia R a temperatura T tiene $N_0/2 = 2kTR\,\mathrm{V^2/Hz}$ hasta frecuencias de teraherzios. Tras un paso bajo ideal de B Hz la potencia es $\frac{N_0}{2} \cdot 2B = N_0 B$, y si esa señal se muestrea a $f_s = 2B$ resulta ruido blanco discreto de varianza $N_0 B$.

Erratas de versiones anteriores

Las transparencias antiguas usaban ω para la frecuencia discreta, escribían la DEP de una constante como $\mu^2\delta(\omega)$, sin el factor 2π, y llamaban «bias constante» a la componente continua.

Densidad espectral cruzada. Es la DTFT de la correlación cruzada:

$$\Phi_{xy}(e^{j\Omega}) = \sum_{l=-\infty}^{\infty} \phi_{xy}[l]\, e^{-j\Omega l}.$$

En general es compleja, porque ϕ_{xy} no es par; como $\phi_{yx}[l] = \phi_{xy}[-l]$, para señales reales $\Phi_{yx} = \Phi_{xy}^*$. Su módulo indica en qué frecuencias tienen x e y potencia en común, y su fase, el desfase entre ellas. La *coherencia*

$$C_{xy}(e^{j\Omega}) = \frac{|\Phi_{xy}(e^{j\Omega})|^2}{\Phi_{xx}(e^{j\Omega})\,\Phi_{yy}(e^{j\Omega})} \in [0,1]$$

vale 1 en las frecuencias en las que y es una versión filtrada de x sin ruido y 0 donde no tienen nada en común.

4.2 Respuesta de un sistema LTI

Sea $y[n] = \sum_k h[k]\,x[n-k]$ la salida de un sistema LTI estable, con h real y determinista, a una entrada x ESA. Toda la aleatoriedad está en la señal. Por la linealidad de la esperanza:

- *Media*:

$$\mu_y = E\Big\{\sum_k h[k]\,x[n-k]\Big\} = \sum_k h[k]\,E\{x[n-k]\} = \mu_x \sum_k h[k] = H(e^{j0})\,\mu_x.$$

- *Correlación cruzada salida-entrada*:

$$\phi_{yx}[l] = E\{y[n+l]\,x[n]\} = \sum_k h[k]\,E\{x[n+l-k]\,x[n]\} = \sum_k h[k]\,\phi_{xx}[l-k] = (h * \phi_{xx})[l].$$

- *Autocorrelación de la salida*:

$$\phi_{yy}[l] = E\Big\{\sum_k h[k]x[n+l-k]\sum_r h[r]x[n-r]\Big\} = \sum_k\sum_r h[k]\,h[r]\,\phi_{xx}[l-k+r].$$

Con $c[m] = \sum_r h[r]\,h[r+m] = (h * \tilde{h})[m]$, $\tilde{h}[n] = h[-n]$, y el cambio $m = k - r$, queda $\phi_{yy}[l] = \sum_m c[m]\,\phi_{xx}[l-m] = (h * \tilde{h} * \phi_{xx})[l]$.

Ninguno depende de n: la salida es ESA, y conjuntamente ESA con la entrada. En frecuencia las convoluciones se convierten en productos, y como la DTFT de $\tilde{h}$ es $H(\mathrm{e}^{-j\Omega}) = H^*(\mathrm{e}^{j\Omega})$:

Propiedad 4.4: Señal aleatoria a través de un sistema LTI

$$\mu_y = H(\mathrm{e}^{j0})\,\mu_x, \qquad \Phi_{yx}(\mathrm{e}^{j\Omega}) = H(\mathrm{e}^{j\Omega})\,\Phi_{xx}(\mathrm{e}^{j\Omega}), \qquad \Phi_{yy}(\mathrm{e}^{j\Omega}) = |H(\mathrm{e}^{j\Omega})|^2\,\Phi_{xx}(\mathrm{e}^{j\Omega}).$$

La potencia de salida es $P_y = \frac{1}{2\pi}\int_{-\pi}^{\pi}|H(\mathrm{e}^{j\Omega})|^2\,\Phi_{xx}(\mathrm{e}^{j\Omega})\,\mathrm{d}\Omega$; con entrada blanca de varianza σ_x^2, $P_y = \sigma_x^2\sum_k h^2[k]$.

En tiempo continuo se cumple lo mismo con $H(j\omega)$. Un filtro no crea potencia en frecuencias donde no la había: solo multiplica la de cada frecuencia por $|H|^2$. Al revés, filtrando ruido blanco con el H adecuado se obtiene ruido con la DEP que se quiera, $\Phi_{yy} = \sigma_x^2|H|^2$ (figura 19): es como se simulan perturbaciones realistas, y el AR(1) no es más que ruido blanco tras $1/(1-az^{-1})$. Un filtro *blanqueador* $1/H$, si es estable, convierte ese ruido coloreado otra vez en blanco.

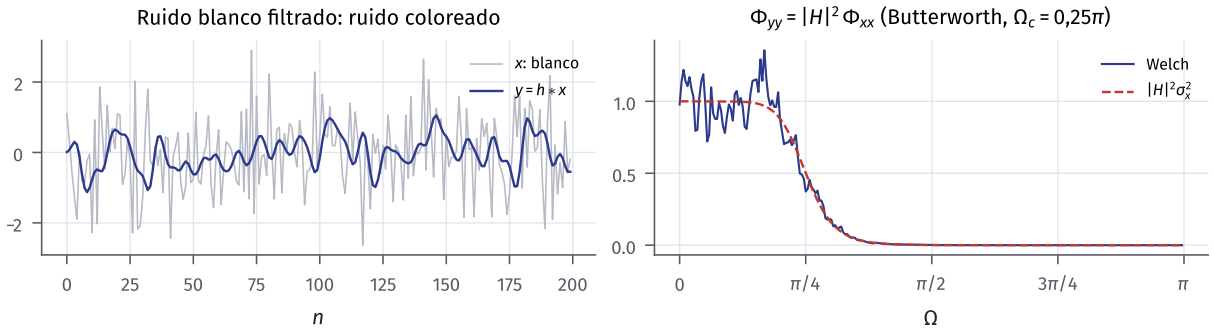


Figura 19. Ruido blanco a través de un Butterworth discreto de orden 4: realización y DEP de la salida estimada con el método de Welch.

Erratas de versiones anteriores

La relación se escribía $\Phi_{YY} = |H(\mathrm{e}^{j\omega})H(\mathrm{e}^{-j\omega})|\Phi_{XX}$: el resultado es correcto para h real, pero el valor absoluto sobra y oculta que $H(\mathrm{e}^{-j\Omega}) = H^*(\mathrm{e}^{j\Omega})$. La deducción usaba ψ_{XX} para la autocorrelación, y la diapositiva decía «Ss pueden procesar» y «aleatoreidad».

Identificación de sistemas. Las relaciones anteriores permiten medir la respuesta en frecuencia de un sistema desconocido: se le aplica una entrada aleatoria y se miden entrada y salida. De $\Phi_{yx} = H\Phi_{xx}$,

$$\hat{H}(\mathrm{e}^{j\Omega}) = \frac{\Phi_{yx}(\mathrm{e}^{j\Omega})}{\Phi_{xx}(\mathrm{e}^{j\Omega})},$$

que da el módulo y la fase. Si la salida se mide con un ruido v incorrelado con la entrada, Φ_{yx} no cambia, porque $\phi_{vx} = 0$; en cambio Φ_{yy} aumenta en Φ_{vv}, así que $|H|^2 = \Phi_{yy}/\Phi_{xx}$ daría un resultado sesgado, y además sin fase. Con entrada blanca, $\phi_{yx}[l] = \sigma_x^2 h[l]$: la correlación cruzada es la respuesta al impulso. La figura 20 muestra el resultado para un sistema de segundo orden.

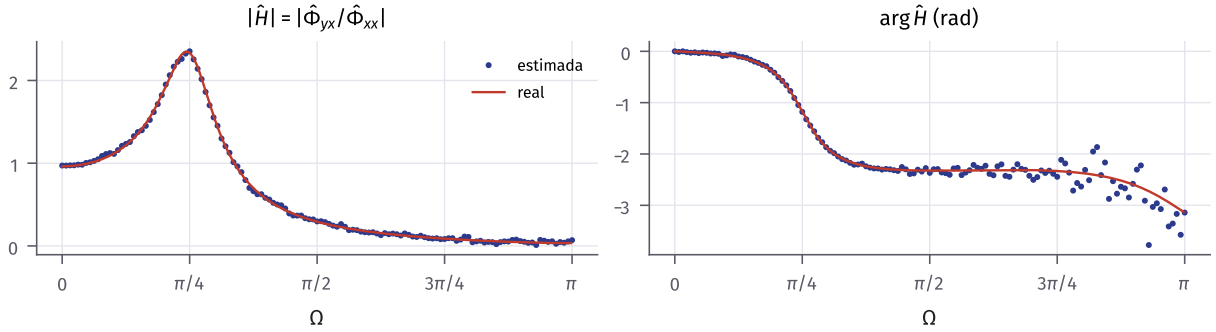


Figura 20. Respuesta en frecuencia de $H(z) = (0{,}2 + 0{,}3z^{-1})/(1 - 1{,}2z^{-1} + 0{,}72z^{-2})$ estimada con 20 000 muestras de ruido blanco y ruido de medida de desviación típica 0,3.

En código

Identificación con `tfestimate` (Matlab) y con `csd`/`welch` (Python). `scipy.signal.csd(x, y)` promedia X^*Y, que con nuestro convenio estima Φ_{yx}.

Python

```python
import numpy as np
from scipy import signal

rng = np.random.default_rng(11)
b, a = [0.2, 0.3], [1, -1.2, 0.72]
x = rng.standard_normal(50000)   # blanco
y = signal.lfilter(b, a, x)      # sistema
y += 0.3*rng.standard_normal(x.size)
f, Pxx = signal.welch(x, nperseg=256,
                      detrend=False)
_, Pxy = signal.csd(x, y, nperseg=256,
                    detrend=False)
H = Pxy/Pxx                  # Phi_yx/Phi_xx
_, Hr = signal.freqz(b, a, 2*np.pi*f)
k = [0, 32, 64]              # W=0,pi/4,pi/2
print(abs(H[k]), abs(Hr[k]))
```

Matlab

```matlab
b = [0.2 0.3]; a = [1 -1.2 0.72];
x = randn(1, 50000);             % blanco
y = filter(b, a, x);             % sistema
y = y + 0.3*randn(size(x));
w = hanning(256);
[H, f] = tfestimate(x, y, w, [], 256, 1);
Hr = freqz(b, a, 2*pi*f);
k = [1 33 65];                % W=0,pi/4,pi/2
disp([abs(H(k)), abs(Hr(k))])
```

4.3 Estimación de la densidad espectral

Periodograma. Con N muestras de una realización, la estimación inmediata, sugerida por el teorema de Wiener-Khinchin, es el *periodograma*

$$I_N(e^{j\Omega}) = \frac{1}{N}\left|\sum_{n=0}^{N-1} x[n]\, e^{-j\Omega n}\right|^2,$$

que se calcula en las frecuencias $\Omega_k = 2\pi k/N$ con la FFT. Se puede comprobar que es la DTFT del estimador sesgado de la autocorrelación. Es asintóticamente insesgado: su media tiende a Φ_{xx} cuando N crece. Pero su varianza no disminuye con N, sino que es del orden de Φ_{xx}^2: con más muestras se obtienen más frecuencias, cada una tan ruidosa como antes (figura 21). Además, al truncar la señal, su media es la convolución de Φ_{xx} con el espectro de la ventana rectangular, con las fugas del Tema 3.

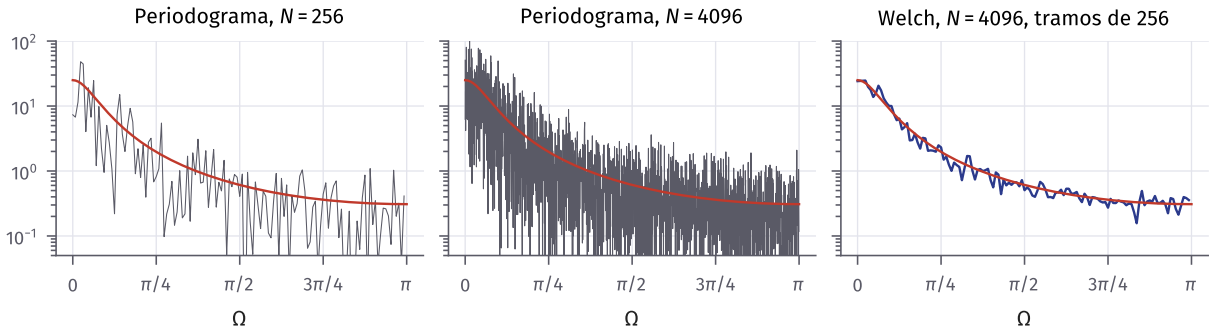


Figura 21. Periodogramas de un AR(1) con $a = 0{,}8$ y $N = 256$ y 4096 muestras, y estimación de Welch. En rojo, la DEP teórica.

Métodos de Bartlett y Welch. Para reducir la varianza se promedia. El método de *Bartlett* divide la señal en K tramos de L muestras, calcula el periodograma de cada uno y los promedia; si los tramos son aproximadamente independientes, la varianza baja en un factor K, a cambio de una resolución en frecuencia de $\approx 2\pi/L$ en lugar de $2\pi/N$. El de *Welch* enventana cada tramo (Hann, Hamming), para reducir las fugas, y los solapa, típicamente un 50 %, para aprovechar mejor los datos. Es el mismo compromiso entre resolución y estabilidad que el del espectrograma del Tema 5. Las densidades cruzadas se estiman igual promediando $X_m^*(e^{j\Omega})Y_m(e^{j\Omega})$ de cada tramo.

En Matlab: `periodogram`, `pwelch`, `cpsd`, `tfestimate` y `mscohere`; en Python, las funciones de mismo nombre de `scipy.signal`: `periodogram`, `welch`, `csd` y `coherence`. Por defecto devuelven la DEP *unilateral* (el doble de Φ_{xx} entre 0 y $f_s/2$, para que la integral en ese intervalo dé la potencia) y por unidad de frecuencia: por hercio si se da f_s, y en Matlab por rad/muestra si no se da. Con la opción bilateral (`'twosided'`, `return_onesided=False`) y $f_s = 1$, el resultado es directamente $\Phi_{xx}(e^{j2\pi f})$ con f en ciclos por muestra. Además, `scipy.signal.welch` resta por defecto la media de cada tramo (`detrend='constant'`), que elimina la componente continua; con `detrend=False` se conserva. El solapamiento se indica en muestras en Matlab y como fracción en Octave; dejándolo vacío (`[]`) ambos usan el 50 %.

En código

DEP de un AR(1) con $a = 0{,}8$ estimada con Welch y comparada con la teórica: $\Phi_{xx}(e^{j0}) = 1/(1-a)^2 = 25$, $\Phi_{xx}(e^{j\pi/2}) = 1/(1+a^2) = 0{,}61$ y potencia $1/(1-a^2) = 2{,}78$. El valor en $\Omega = 0$, donde hay un pico estrecho, es el que peor se estima.

Python

```python
import numpy as np
from scipy import signal

rng = np.random.default_rng(10)
a, N = 0.8, 2**14
x = signal.lfilter([1], [1, -a],
                   rng.standard_normal(N))
f, P = signal.welch(x, fs=1, nperseg=256,
                    return_onesided=False,
                    detrend=False)  # Phi
W = 2*np.pi*f                   # f en ciclos
teo = 1/abs(1 - a*np.exp(-1j*W))**2
print(P[0], teo[0])               # ~ 25
print(P[64], teo[64])          # W=pi/2: 0.61
print(np.mean(P), x.var())        # potencia
```

Matlab

```matlab
a = 0.8; N = 2^14;
x = filter(1, [1 -a], randn(1, N));
w = hanning(256);
[P, f] = pwelch(x, w, [], 256, 1, ...
                'twosided');      % Phi
W = 2*pi*f;                      % f en ciclos
teo = 1./abs(1 - a*exp(-1j*W)).^2;
disp([P(1), teo(1)])              % ~ 25
disp([P(65), teo(65)])         % W=pi/2: 0.61
disp([mean(P), var(x)])           % potencia
```

4.4 Aplicaciones

- *Medida de ruido*: la DEP del ruido de un sistema y su relación señal a ruido en cada banda.
- *Detección de tonos* débiles: al promediar, la varianza del fondo de ruido disminuye y un tono que estaba oculto en un periodograma aislado destaca.
- *Identificación* de sistemas en funcionamiento, añadiendo una pequeña señal aleatoria a la entrada.
- *Filtro de Wiener*: si una señal s se observa con un ruido aditivo v incorrelado, $x = s + v$, el filtro lineal que minimiza el error cuadrático medio de la estimación de s es

$$H(\mathrm{e}^{j\Omega}) = \frac{\Phi_{ss}(\mathrm{e}^{j\Omega})}{\Phi_{ss}(\mathrm{e}^{j\Omega}) + \Phi_{vv}(\mathrm{e}^{j\Omega})},$$

  que deja pasar las frecuencias en las que domina la señal y atenúa aquellas en las que domina el ruido. Es la idea de los reductores de ruido y de la restauración de imágenes del Tema 5.

Ejercicios 15–18.

Bibliografía

- A. V. Oppenheim y R. W. Schafer, *Tratamiento de señales en tiempo discreto*, 3.ª ed. Pearson, 2011. Apéndice A (señales aleatorias) y capítulo 10 (estimación espectral). De aquí procede el convenio de la correlación cruzada.
- J. G. Proakis y D. G. Manolakis, *Tratamiento digital de señales*, 4.ª ed. Pearson Prentice Hall, 2007. Capítulos de señales aleatorias y de estimación del espectro de potencia.
- A. Papoulis y S. U. Pillai, *Probability, Random Variables and Stochastic Processes*, 4.ª ed. McGraw-Hill, 2002. Referencia completa de probabilidad y procesos estocásticos.
- A. Gelb (ed.), *Applied Optimal Estimation*. MIT Press, 1974. Capítulo de repaso de probabilidad y procesos aleatorios, con la notación ϕ y Φ de las versiones anteriores de este tema.
- C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006. Capítulos 2 (distribuciones) y 11 (métodos de muestreo: inversa, rechazo, Monte Carlo).